

LỜI CẢM ƠN

Trải qua gần bốn năm học tập và rèn luyện tại Khoa Công nghệ thông tin, Trường Đại học Khoa học – Đại học Huế, chúng tôi đã nhận được rất nhiều sự quan tâm, giúp đỡ và đồng hành quý báu từ quý thầy cô, gia đình và bạn bè để có thể hoàn thành khóa luận tốt nghiệp này.

Trước hết, chúng tôi xin bày tỏ lòng biết ơn chân thành và sâu sắc đến Ban Giám hiệu Trường Đại học Khoa học – Đại học Huế cùng toàn thể quý thầy cô Khoa Công nghệ thông tin, đặc biệt là các thầy cô thuộc chuyên ngành Khoa học máy tính, đã tận tình giảng dạy, truyền đạt kiến thức, kinh nghiệm quý báu và tạo điều kiện thuận lợi cho chúng tôi trong suốt quá trình học tập và nghiên cứu tại trường.

Đặc biệt, chúng tôi xin gửi lời cảm ơn chân thành nhất đến thầy TS. Nguyễn Ngọc Thủy đã luôn tận tâm chỉ bảo, định hướng, hỗ trợ và góp ý cho chúng tôi trong suốt quá trình thực hiện đề tài khóa luận tốt nghiệp. Những kiến thức chuyên môn, tinh thần trách nhiệm và sự tận tình của thầy không chỉ giúp chúng tôi hoàn thiện đề tài mà còn là hành trang quý giá cho chặng đường học tập và làm việc sau này.

Chúng tôi cũng xin gửi lời cảm ơn sâu sắc đến gia đình, người thân và bạn bè – những người luôn ở bên động viên, khích lệ và hỗ trợ chúng tôi cả về tinh thần lẫn vật chất trong suốt quá trình học tập cũng như thực hiện khóa luận. Sự tin tưởng và yêu thương của mọi người chính là nguồn động lực to lớn giúp chúng tôi vượt qua những khó khăn và thử thách để hoàn thành tốt đề tài này.

Bên cạnh đó, chúng tôi xin chân thành cảm ơn các anh/chị, bạn bè và những cá nhân đã nhiệt tình hỗ trợ, đóng góp ý kiến, chia sẻ tài liệu và kinh nghiệm trong quá trình nghiên cứu và thực hiện đề tài.

Mặc dù nhóm đã cố gắng hoàn thành khóa luận với tất cả sự nỗ lực và tinh thần trách nhiệm, tuy nhiên do hạn chế về thời gian, kiến thức và kinh nghiệm thực tiễn nên đề tài khó tránh khỏi những thiếu sót. Chúng tôi rất mong nhận được những ý kiến đóng góp quý báu từ quý thầy cô và các bạn để đề tài được hoàn thiện hơn.

Một lần nữa, chúng tôi xin chân thành cảm ơn!

Mục lục

LỜI CẢM ƠN	1
DANH MỤC HÌNH ẢNH	6
DANH MỤC BẢNG BIỂU	7
MỞ ĐẦU	8
Lý do chọn đề tài	8
Mục tiêu nghiên cứu	9
Đối tượng nghiên cứu	9
Phương pháp nghiên cứu	9
Đóng góp của nghiên cứu	11
Cấu trúc báo cáo	11
1 TỔNG QUAN BÀI TOÁN CHẨN ĐOÁN VIÊM PHỔI TỪ ẢNH X-QUANG	13
1.1 Giới thiệu bài toán chẩn đoán viêm phổi bằng ảnh X-quang lồng ngực	13
1.1.1 Giới thiệu hình ảnh X-quang	13
1.1.2 Đặc điểm ảnh X-quang viêm phổi	14
1.1.3 Bài toán chẩn đoán viêm phổi	15
1.2 Xu hướng trích xuất đặc trưng trong ảnh y tế	16
1.2.1 Các phương pháp truyền thống	16
1.2.2 Các phương pháp học sâu	17
1.2.3 Xu hướng kết hợp đặc trưng	18
1.2.4 Một số nghiên cứu liên quan	19
1.3 Mô tả tập dữ liệu	20
1.3.1 Nguồn dữ liệu	20
1.3.2 Tiền xử lý dữ liệu	21
1.3.3 Phân chia tập dữ liệu	22
1.4 Các chỉ số đánh giá mô hình	22
1.4.1 Định nghĩa các khái niệm cơ bản	22
1.4.2 Các chỉ số đánh giá	23

1.5	Tiểu kết chương 1	24
2	PHƯƠNG PHÁP TRÍCH XUẤT ĐẶC TRƯNG	25
2.1	Các phương pháp trích xuất đặc trưng truyền thống	25
2.1.1	Mô hình WST	25
2.1.2	Mô hình Statistical Features	30
2.1.3	Mô hình Radiomics	38
2.2	Các mô hình trích xuất đặc trưng dựa trên Transformer	43
2.2.1	Tổng quan về Transformer	43
2.2.2	Mô hình Vision Transformer (ViT)	48
2.2.3	Mô hình Swin Transformer-T	51
2.3	Các mô hình trích xuất đặc trưng dựa trên Mạng nơ-ron tích chập CNN	55
2.3.1	Tổng quan về Mạng nơ-ron tích chập CNN	55
2.3.2	Mô hình VGG-16	58
2.3.3	Mô hình DenseNet-169	60
2.4	Thực nghiệm và thảo luận	63
2.4.1	Thực nghiệm	63
2.4.2	Thảo luận	73
2.5	Tiểu kết chương 2	73
3	PHƯƠNG PHÁP KẾT HỢP ĐẶC TRƯNG	74
3.1	Phương pháp Feature Concatenation	74
3.2	Phương pháp Gated Fusion	77
3.3	Xây dựng mô hình kết hợp đặc trưng Gated Fusion	82
3.4	Thực nghiệm và thảo luận	84
3.4.1	Thực nghiệm	84
3.4.2	Thảo luận	84
3.5	Tiểu kết chương 3	84
4	XÂY DỰNG HỆ THỐNG CHẨN ĐOÁN VIÊM PHỔI	85
4.1	Giới thiệu hệ thống	85
4.1.1	Tổng quan hệ thống	85
4.1.2	Công nghệ sử dụng	86
4.1.3	Mô tả cơ sở dữ liệu của hệ thống	86
4.2	Quy trình tương tác người dùng với hệ thống	87
4.3	Triển khai chức năng chính - chẩn đoán viêm phổi thông qua ảnh X-quang	90
4.3.1	Mô tả chức năng	90
4.3.2	Quy trình chẩn đoán	92
4.3.3	Thiết kế giao diện chẩn đoán	92
4.4	Triển khai các chức năng phụ	94

4.4.1	Chức năng chọn mô hình chẩn đoán	94
4.4.2	Chức năng so sánh các mô hình chẩn đoán	95
4.4.3	Chức năng xem lịch sử chẩn đoán	96
4.4.4	Chức năng xuất kết quả chẩn đoán	97
4.5	Đánh giá hệ thống	98
4.6	Tiểu kết chương 4	98
KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN		99
TÀI LIỆU THAM KHẢO		100
A PHỤ LỤC		102

Danh sách hình vẽ

1.1	Một số hình ảnh từ bộ dữ liệu chẩn đoán viêm phổi.	22
2.1	Sơ đồ quy trình trích xuất đặc trưng bằng phương pháp WST bậc hai .	29
2.2	Ví dụ histogram mức xám của ảnh X-quang lồng ngực	32
2.3	Quy trình trích xuất đặc trưng Statistical	33
2.4	Quy trình trích xuất đặc trưng Radiomics	40
2.5	Scaled Dot-Product Attention	44
2.6	Multi-Head Attention	46
2.7	Kiến trúc tổng thể của mô hình Transformer	47
2.8	Kiến trúc tổng quát của Vision Transformer (ViT)	50
2.9	Minh họa lớp Convolutional Layer	56
2.10	Minh họa lớp Pooling Layer	57
2.11	Minh họa lớp Fully Connected Layer	57
2.12	Minh họa quy trình hoạt động CNN	58
2.13	Kiến trúc mô hình VGG-16	59
2.14	Quy trình hoạt động mô hình VGG-16	59
2.15	Minh họa Dense Block và Transition Layer trong DenseNet-169	61
2.16	Minh họa quy trình hoạt động DenseNet-169	62
2.17	Minh họa xây dựng mô hình WST	64
2.18	Xây dựng mô hình Statistical	66
2.19	Minh họa xây dựng mô hình Radiomics	67
2.20	Minh họa xây dựng mô hình ViT	68
2.21	Minh họa xây dựng mô hình Swin-T	69
2.22	Minh họa xây dựng mô hình VGG16	71
2.23	Minh họa xây dựng mô hình DenseNet169	72
3.1	Minh họa quá trình kết hợp đặc trưng	76
3.2	Minh họa quá trình kết hợp vector đặc trưng	77
4.1	Sơ đồ quan hệ thực thể của cơ sở dữ liệu hệ thống web chẩn đoán viêm phổi.	87
4.2	Quy trình tương tác giữa người dùng với hệ thống	90

4.3	Minh họa đầu vào (input), đầu ra (output) của các chức năng chẩn đoán X-qaung	91
4.4	Minh họa giao diện tải ảnh	93
4.5	Minh họa giao diện tải ảnh	93
4.6	Minh họa giao diện hiển thị kết quả	94
4.7	Minh họa giao diện lựa chọn mô hình chẩn đoán	95
4.8	Minh họa giao diện so sánh các mô hình chẩn đoán.	96
4.9	Minh họa giao diện lịch sử khám và tra cứu kết quả chẩn đoán.	97

Danh sách bảng

1.1	Thống kê tập dữ liệu	21
1.2	Bảng phân chia tập dữ liệu chẩn đoán viêm phổi.	22
2.1	Các đặc trưng thống kê sử dụng trong nghiên cứu	36

MỞ ĐẦU

Lý do chọn đề tài

Trong những năm gần đây, trí tuệ nhân tạo (Artificial Intelligence – AI) đang phát triển mạnh mẽ và trở thành xu hướng công nghệ nổi bật trong nhiều lĩnh vực của đời sống, đặc biệt là trong lĩnh vực y tế. Nhờ khả năng xử lý dữ liệu nhanh chóng, học hỏi từ dữ liệu lớn và hỗ trợ đưa ra quyết định chính xác, AI đã góp phần hỗ trợ giảm tải áp lực cho đội ngũ bác sĩ, nâng cao hiệu quả công việc lâm sàng cũng như cải thiện chất lượng chẩn đoán và điều trị bệnh.

Trong lĩnh vực chẩn đoán hình ảnh y khoa, đặc biệt là chẩn đoán bệnh viêm phổi dựa trên ảnh chụp X-quang lồng ngực, AI đang được nghiên cứu và ứng dụng rộng rãi nhằm hỗ trợ bác sĩ trong quá trình phát hiện và đánh giá bệnh. Viêm phổi là một trong những bệnh lý nguy hiểm về đường hô hấp, có thể gây ra nhiều biến chứng nghiêm trọng nếu không được phát hiện và điều trị kịp thời. Tuy nhiên, việc chẩn đoán bệnh thông qua ảnh X-quang đòi hỏi nhiều kinh nghiệm chuyên môn và dễ bị ảnh hưởng bởi yếu tố chủ quan của người đọc ảnh. Vì vậy, việc xây dựng các hệ thống hỗ trợ chẩn đoán tự động bằng AI mang ý nghĩa thực tiễn rất lớn.

Bên cạnh đó, sự phát triển của các phương pháp học máy và học sâu đã mở ra nhiều hướng tiếp cận hiệu quả trong bài toán phân loại và chẩn đoán bệnh. Các mô hình học sâu có khả năng tự động học đặc trưng từ dữ liệu ảnh, trong khi các đặc trưng truyền thống vẫn mang nhiều thông tin quan trọng liên quan đến kết cấu và hình thái ảnh y khoa. Do đó, phương pháp kết hợp đa đặc trưng nhằm khai thác đồng thời ưu điểm của đặc trưng học sâu và đặc trưng truyền thống được xem là hướng nghiên cứu phù hợp và tiềm năng.

Xuất phát từ những lý do trên, nhóm chúng em quyết định lựa chọn đề tài: **“Nghiên cứu phương pháp kết hợp đặc trưng đa nguồn dựa trên Gated Fusion cho bài toán chẩn đoán bệnh viêm phổi từ ảnh X-quang”** nhằm góp phần xây dựng mô hình hỗ trợ chẩn đoán có độ chính xác cao, hỗ trợ bác sĩ trong quá trình đánh giá bệnh, đồng thời nâng cao hiệu quả ứng dụng trí tuệ nhân tạo trong lĩnh vực y tế.

Mục tiêu nghiên cứu

Mục tiêu chính của đề tài là nghiên cứu và xây dựng phương pháp kết hợp đa đặc trưng nhằm nâng cao hiệu quả chẩn đoán viêm phổi dựa trên ảnh X-quang lồng ngực. Cụ thể, đề tài tập trung vào các mục tiêu sau:

- Nghiên cứu và thực hiện các phương pháp trích xuất đặc trưng truyền thống từ ảnh X-quang lồng ngực, đồng thời áp dụng các mô hình học sâu để trích xuất đặc trưng tự động phục vụ bài toán chẩn đoán viêm phổi.
- Đề xuất phương pháp kết hợp đặc trưng truyền thống và đặc trưng học sâu nhằm khai thác tối đa thông tin từ dữ liệu ảnh, từ đó nâng cao hiệu quả phân loại và chẩn đoán bệnh.
- Xây dựng và đánh giá mô hình chẩn đoán viêm phổi dựa trên từng loại đặc trưng riêng lẻ cũng như đặc trưng kết hợp.
- So sánh hiệu quả giữa phương pháp sử dụng đặc trưng riêng lẻ và phương pháp kết hợp đa đặc trưng thông qua các độ đo đánh giá, từ đó xác định tính hiệu quả và khả năng ứng dụng của phương pháp đề xuất.

Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là các phương pháp trích xuất và kết hợp đặc trưng trong bài toán chẩn đoán viêm phổi dựa trên hình ảnh X-quang lồng ngực. Đề tài tập trung nghiên cứu các đặc trưng truyền thống và các đặc trưng học sâu được học thông qua các mô hình mạng nơ-ron tích chập (CNN) được trích xuất từ ảnh y khoa.

Bên cạnh đó, đề tài khảo sát và đánh giá hiệu quả của phương pháp kết hợp đa đặc trưng nhằm khai thác đồng thời ưu điểm của đặc trưng truyền thống và đặc trưng học sâu trong quá trình phân loại và chẩn đoán bệnh viêm phổi. Dữ liệu nghiên cứu chủ yếu là tập ảnh X-quang lồng ngực phục vụ cho bài toán phát hiện và chẩn đoán viêm phổi.

Phương pháp nghiên cứu

Để thực hiện đề tài, nhóm nghiên cứu tiến hành khảo sát, xây dựng và đánh giá các phương pháp trích xuất và kết hợp đặc trưng trong bài toán chẩn đoán viêm phổi dựa trên ảnh X-quang lồng ngực. Quá trình nghiên cứu được thực hiện theo các bước sau:

1. Nghiên cứu lý thuyết và tổng quan tài liệu

Nhóm tiến hành tìm hiểu các tài liệu, bài báo khoa học và các công trình nghiên cứu liên quan đến bài toán chẩn đoán viêm phổi bằng trí tuệ nhân tạo, đặc biệt là trên dữ liệu ảnh X-quang lồng ngực. Nội dung nghiên cứu tập trung vào:

- Tìm hiểu đặc điểm của ảnh X-quang lồng ngực và các dấu hiệu thường gặp trong chẩn đoán bệnh viêm phổi.
- Nghiên cứu các phương pháp trích xuất đặc trưng truyền thống như WST (Wavelet Scattering Transform), Radiomics, Statistical Features và các mô hình học sâu như ViT, Swin-T, VGG16 và DenseNet169.
- Tìm hiểu phương pháp kết hợp đặc trưng Gated Fusion nhằm khai thác hiệu quả thông tin từ nhiều nguồn đặc trưng khác nhau.

2. Nghiên cứu phương pháp trích xuất đặc trưng và bộ phân lớp

Đề tài tiến hành khảo sát các phương pháp trích xuất đặc trưng truyền thống và học sâu để thu nhận các thông tin quan trọng từ ảnh X-quang vùng phổi. Cụ thể:

- Áp dụng các phương pháp WST, Radiomics và Statistical Features để trích xuất đặc trưng truyền thống từ ảnh X-quang.
- Sử dụng các mô hình học sâu gồm ViT, Swin-T, VGG16 và DenseNet169 để học và trích xuất đặc trưng từ dữ liệu ảnh.
- Sau khi thu được các vector đặc trưng, dữ liệu được đưa vào các bộ phân loại truyền thống như K-Nearest Neighbors (KNN), Logistic Regression (LR) và bộ phân loại học sâu Multi-Layer Perceptron (MLP) nhằm thực hiện bài toán phân loại và chẩn đoán viêm phổi.

3. Nghiên cứu và khảo sát phương pháp kết hợp đặc trưng Gated Fusion

Đề tài sử dụng phương pháp kết hợp đặc trưng Gated Fusion để kết hợp các đặc trưng truyền thống và đặc trưng học sâu. Phương pháp này cho phép mô hình học được mức độ đóng góp của từng loại đặc trưng thông qua các cơ chế cổng (gate), từ đó:

- Tự động nhấn mạnh các thông tin quan trọng phục vụ cho việc chẩn đoán.
- Hạn chế ảnh hưởng của các đặc trưng không liên quan hoặc nhiễu.
- Tạo ra vector đặc trưng kết hợp có khả năng biểu diễn dữ liệu tốt hơn.

Sau khi kết hợp đặc trưng, các vector đặc trưng tiếp tục được đưa vào các bộ phân loại để đánh giá hiệu quả mô hình.

4. Đánh giá hiệu quả mô hình

Sau quá trình huấn luyện và kiểm thử, nhóm tiến hành đánh giá hiệu quả của các phương pháp thông qua nhiều độ đo khác nhau như: Accuracy, Precision, Recall, F1-Score,...

Từ các kết quả thực nghiệm, nhóm thực hiện so sánh và đánh giá hiệu suất giữa các phương pháp trích xuất đặc trưng riêng lẻ và phương pháp kết hợp đặc trưng, qua đó đưa ra nhận xét về tính hiệu quả cũng như khả năng ứng dụng thực tế của mô hình trong hỗ trợ chẩn đoán viêm phổi.

Đóng góp của nghiên cứu

Nghiên cứu này đã đóng góp cả về mặt lý thuyết lẫn thực tiễn trong bài toán chẩn đoán viêm phổi dựa trên ảnh X-quang lồng ngực. Các đóng góp chính của đề tài bao gồm:

- Đề xuất pipeline chẩn đoán viêm phổi dựa trên phương pháp kết hợp đa đặc trưng giữa đặc trưng truyền thống và học sâu.
- Áp dụng phương pháp Gated Fusion để kết hợp đặc trưng, góp phần nâng cao hiệu quả phân loại và chẩn đoán bệnh.
- Khảo sát và đánh giá các phương pháp trích xuất đặc trưng truyền thống (WST, Radiomics, Statistical Features) và học sâu (ViT, Swin-T, VGG16, DenseNet169).
- So sánh hiệu quả giữa phương pháp sử dụng đặc trưng riêng lẻ và phương pháp kết hợp đặc trưng.
- Xây dựng hệ thống hỗ trợ chẩn đoán viêm phổi dựa trên ảnh X-quang lồng ngực.

Cấu trúc báo cáo

Báo cáo khóa luận được chia thành 4 chương chính với nội dung như sau:

Chương 1: Tổng quan bài toán chẩn đoán viêm phổi từ ảnh X-quang

Chương này trình bày tổng quan về bài toán chẩn đoán viêm phổi dựa trên ảnh X-quang lồng ngực, bao gồm giới thiệu về hình ảnh X-quang, đặc điểm của ảnh X-quang viêm phổi và bài toán chẩn đoán viêm phổi. Bên cạnh đó, chương cũng trình bày xu hướng trích xuất đặc trưng trong ảnh y tế với các phương pháp truyền thống, học sâu

và kết hợp đặc trưng. Ngoài ra, chương còn mô tả tập dữ liệu sử dụng, các bước tiền xử lý dữ liệu và các chỉ số đánh giá mô hình được sử dụng trong quá trình thực nghiệm.

Chương 2: Phương pháp trích xuất đặc trưng

Chương này tập trung trình bày cơ sở lý thuyết và các phương pháp trích xuất đặc trưng được sử dụng trong đề tài. Nội dung bao gồm các phương pháp trích xuất đặc trưng truyền thống như WST, Radiomics, Statistical Features và các mô hình học sâu dựa trên Transformer và CNN như ViT, Swin Transformer-T, VGG16 và DenseNet169. Đồng thời, chương cũng trình bày quá trình thực nghiệm, đánh giá và thảo luận kết quả của các phương pháp trích xuất đặc trưng riêng lẻ.

Chương 3: Phương pháp kết hợp đặc trưng

Chương này trình bày các phương pháp kết hợp đặc trưng, đặc biệt là phương pháp Gated Fusion. Nội dung bao gồm cơ sở lý thuyết của các phương pháp kết hợp đặc trưng, kiến trúc mô hình kết hợp, chiến lược kết hợp và quá trình huấn luyện mô hình. Ngoài ra, chương còn thực hiện thực nghiệm, đánh giá và so sánh hiệu quả giữa các phương pháp sử dụng đặc trưng riêng lẻ và phương pháp kết hợp đặc trưng.

Chương 4: Xây dựng hệ thống chẩn đoán viêm phổi

Chương này trình bày quá trình xây dựng hệ thống hỗ trợ chẩn đoán viêm phổi dựa trên ảnh X-quang lồng ngực. Nội dung bao gồm phân tích yêu cầu hệ thống, kiến trúc tổng thể, thiết kế cơ sở dữ liệu, công nghệ sử dụng và xây dựng giao diện website. Bên cạnh đó, chương cũng mô tả quá trình xây dựng backend, tích hợp mô hình học máy, triển khai hệ thống và đánh giá kết quả hoạt động của hệ thống.

CHƯƠNG 1

TỔNG QUAN BÀI TOÁN CHẨN ĐOÁN VIÊM PHỔI TỪ ẢNH X-QUANG

1.1 Giới thiệu bài toán chẩn đoán viêm phổi bằng ảnh X-quang lồng ngực ngược

1.1.1 Giới thiệu hình ảnh X-quang

Hình ảnh X-quang (X-ray image) là một phương pháp chẩn đoán hình ảnh được sử dụng phổ biến trong y học nhằm hỗ trợ quan sát cấu trúc bên trong cơ thể mà không cần can thiệp phẫu thuật. Phương pháp này được sử dụng bằng tia X – một dạng bức xạ điện từ có bước sóng ngắn và năng lượng cao để xuyên qua các mô trong cơ thể và tạo ra hình ảnh trên thiết bị thu nhận.(1)

Nguyên lý tạo ảnh X-quang dựa trên sự khác nhau về khả năng hấp thụ tia X của các loại mô trong cơ thể. Các mô có mật độ cao như xương thường hấp thụ tia X nhiều hơn nên xuất hiện sáng trên ảnh. Trong khi đó, các mô mềm hấp thụ tia X ở mức thấp hơn và được biểu diễn dưới các mức xám khác nhau. Đối với các vùng chứa không khí như phổi, khả năng hấp thụ tia X thấp nên thường xuất hiện tối hơn trên hình ảnh. Sự khác biệt về khả năng hấp thụ tia X giữa các loại mô giúp thể hiện cấu trúc bên trong cơ thể và hỗ trợ quá trình quan sát, đánh giá các dấu hiệu bất thường.

Trong các phương pháp chẩn đoán hình ảnh vùng ngực, ảnh X-quang lồng ngực (Chest X-ray – CXR) là một trong những kỹ thuật thường được sử dụng trong thực hành lâm sàng. Theo các nghiên cứu cho thấy ảnh X-quang lồng ngực có thể cung cấp thông tin phục vụ quá trình đánh giá tình trạng bệnh trong thời gian tương đối ngắn, đồng thời có chi phí thực hiện và mức phơi nhiễm bức xạ thấp hơn so với một số kỹ

thuật chẩn đoán hình ảnh khác. Chi phí thực hiện chụp X-quang có thể khác nhau giữa các cơ sở và hệ thống y tế, tuy nhiên nhìn chung phương pháp này thường có chi phí thấp hơn so với các kỹ thuật như chụp cắt lớp vi tính (Computed Tomography – CT) hoặc chụp cộng hưởng từ (Magnetic Resonance Imaging – MRI).

Ngoài các yếu tố về chi phí, hình ảnh X-quang lồng ngực cũng có mức phơi nhiễm bức xạ tương đối thấp. Một lần chụp X-quang lồng ngực thường tạo ra liều bức xạ khoảng 0,01–0,02 mSv, tương đương với mức phơi nhiễm bức xạ tự nhiên trong khoảng một ngày trong môi trường sống thông thường. So với kỹ thuật chụp cắt lớp vi tính (CT) vùng ngực thì liều bức xạ từ hình ảnh X-quang thấp hơn. Tuy nhiên, việc sử dụng phương pháp này vẫn cần được thực hiện theo các chỉ định và hướng dẫn lâm sàng phù hợp nhằm hạn chế các trường hợp chụp không cần thiết.

Các phương pháp chẩn đoán hình ảnh vùng ngực hiện nay bao gồm nhiều kỹ thuật khác nhau như ảnh X-quang, chụp cắt lớp vi tính (CT), siêu âm, cộng hưởng từ (MRI), chụp cắt lớp phát xạ positron (PET) và các phương pháp khác. Mỗi phương pháp có những ưu điểm và hạn chế riêng về chi phí, thời gian thực hiện, độ phân giải hình ảnh và khả năng quan sát cấu trúc bệnh lý. Trong đó, hình ảnh X-quang thường được sử dụng như phương pháp khảo sát ban đầu trong nhiều tình huống lâm sàng liên quan đến hệ hô hấp.

Đối với các bệnh lý phổi, ảnh X-quang lồng ngực có thể được sử dụng để hỗ trợ quan sát các dấu hiệu bất thường như vùng mờ, đông đặc phổi, tràn dịch màng phổi hoặc thay đổi cấu trúc mô phổi. Đối với bệnh viêm phổi, hình ảnh X-quang có thể xuất hiện các vùng tổn thương có mật độ tăng bất thường trong nhu mô phổi. Tuy nhiên đối với việc đánh giá hình ảnh có thể chịu ảnh hưởng bởi nhiều yếu tố như chất lượng ảnh, tư thế chụp hoặc kinh nghiệm của người thực hiện chẩn đoán.

Trong những năm gần đây, cùng với sự phát triển của học máy (Machine Learning) và học sâu (Deep Learning), ảnh X-quang được sử dụng trong nhiều nghiên cứu nhằm hỗ trợ quá trình phân tích và phát hiện bất thường tự động. Các phương pháp này có khả năng học đặc trưng từ dữ liệu hình ảnh và hỗ trợ quá trình phân loại bệnh lý. Trong đề tài này, ảnh X-quang lồng ngực được sử dụng làm dữ liệu đầu vào để thực hiện trích xuất đặc trưng và xây dựng mô hình hỗ trợ phát hiện bệnh viêm phổi.

1.1.2 Đặc điểm ảnh X-quang viêm phổi

Viêm phổi là tình trạng nhiễm trùng xảy ra tại nhu mô phổi, có thể do vi khuẩn, virus hoặc các tác nhân khác gây ra. Khi xuất hiện các tình trạng viêm, các phế nang có thể chứa dịch, mủ hoặc các tế bào viêm thay vì chứa không khí như ở trạng thái bình thường. Sự thay đổi này làm thay đổi cấu trúc mô phổi và tạo ra các dấu hiệu bất thường trên ảnh X-quang lồng ngực.(2)

Trên hình ảnh X-quang, viêm phổi thường xuất hiện dưới dạng các vùng mờ bất thường (Opacity) trong nhu mô phổi. Các vùng này xuất hiện do sự tích tụ dịch hoặc các thành phần viêm trong phổi, làm thay đổi mật độ mô tại khu vực tổn thương. So với vùng phổi bình thường chứa nhiều không khí và thường hiển thị tối hơn trên ảnh, vùng viêm thường xuất hiện dưới dạng các vùng mờ sáng hơn.

Một trong những dấu hiệu thường gặp là hiện tượng đông đặc phổi (Consolidation). Hiện tượng này xảy ra khi các phế nang chứa dịch hoặc các thành phần viêm, làm giảm lượng không khí trong mô phổi. Trên ảnh X-quang, vùng đông đặc thường xuất hiện với mật độ tăng và có thể xuất hiện ở một hoặc nhiều khu vực khác nhau trong phổi.

Ngoài hiện tượng đông đặc, ảnh X-quang viêm phổi có thể xuất hiện tình trạng thâm nhiễm phổi (Infiltration). Dấu hiệu này thường biểu hiện dưới dạng các vùng mờ phân bố không đồng nhất hoặc lan tỏa trong nhu mô phổi. Phạm vi và hình dạng của các vùng tổn thương có thể thay đổi tùy thuộc vào mức độ tiến triển của bệnh.

Trong một số trường hợp, bệnh nhân viêm phổi có thể xuất hiện tràn dịch màng phổi (Pleural effusion), là tình trạng tích tụ dịch trong khoang màng phổi. Ngoài ra, dấu hiệu khí phế quản đổ (Air bronchogram) cũng có thể xuất hiện khi các phế quản vẫn chứa không khí trong khi vùng mô xung quanh bị đông đặc.

Các đặc điểm trên ảnh X-quang của bệnh viêm phổi có thể khác nhau giữa các bệnh nhân do ảnh hưởng của nguyên nhân gây bệnh, mức độ tổn thương và tình trạng lâm sàng. Trong một số trường hợp, các tổn thương có thể nhỏ hoặc có đặc điểm tương tự với các bệnh lý khác của phổi, gây khó khăn cho quá trình đánh giá hình ảnh.

Trong đề tài này, các đặc điểm bất thường trên ảnh X-quang được sử dụng làm cơ sở cho quá trình trích xuất đặc trưng và xây dựng mô hình hỗ trợ phát hiện bệnh viêm phổi.

1.1.3 Bài toán chẩn đoán viêm phổi

Bài toán chẩn đoán viêm phổi trong đề tài này được xây dựng dựa trên dữ liệu ảnh X-quang lồng ngực (Chest X-ray – CXR). Đầu vào của hệ thống là ảnh X-quang phổi dưới dạng ảnh xám (Gray-scale), chứa thông tin về cấu trúc vùng phổi và các dấu hiệu bất thường liên quan đến bệnh lý hô hấp. Thông qua quá trình xử lý và trích xuất đặc trưng, hệ thống sẽ đưa ra dự đoán về tình trạng của bệnh nhân thuộc một trong hai lớp: NORMAL (bình thường) hoặc PNEUMONIA (mắc bệnh viêm phổi).

Bài toán được tiếp cận theo hướng phân loại nhị phân (Binary Classification), với mục tiêu xác định mỗi ảnh X-quang thuộc vào một trong hai nhóm dữ liệu đã được định nghĩa trước. Trong quá trình xây dựng mô hình, ảnh đầu vào được xử lý thông qua nhiều phương pháp trích xuất đặc trưng khác nhau nhằm khai thác thông tin từ nhiều góc độ. Cụ thể, đề tài sử dụng các đặc trưng được trích xuất từ mô hình ViT

kết hợp với các đặc trưng Radiomics, Statistical và WST để biểu diễn thông tin hình ảnh.

Sau quá trình trích xuất đặc trưng, các đặc trưng từ nhiều nguồn được kết hợp thông qua cơ chế Gated Fusion nhằm học và lựa chọn mức độ đóng góp của từng đặc trưng vào quá trình biểu diễn dữ liệu. Cơ chế này giúp tạo ra biểu diễn đặc trưng hợp nhất, làm đầu vào cho giai đoạn phân loại.

Trên tập đặc trưng đã được hợp nhất, đề tài tiến hành sử dụng nhiều thuật toán phân loại khác nhau như KNN, LR, Support Vector Machine (SVM) và MLP để thực hiện dự đoán nhãn đầu ra. Kết quả của các mô hình được đánh giá thông qua nhiều độ đo như Accuracy, Precision, Recall, F1-score, Balanced Accuracy, AUC và Matthews Correlation Coefficient (MCC).

Mục tiêu của bài toán là xây dựng mô hình có khả năng học được các đặc trưng phân biệt giữa ảnh X-quang phổi bình thường và ảnh X-quang viêm phổi, từ đó hỗ trợ quá trình phát hiện bệnh tự động trên dữ liệu hình ảnh y khoa.

1.2 Xu hướng trích xuất đặc trưng trong ảnh y tế

1.2.1 Các phương pháp truyền thống

Trước khi các phương pháp học sâu được áp dụng rộng rãi trong lĩnh vực xử lý ảnh y tế, các bài toán phân tích và chẩn đoán hình ảnh thường được thực hiện bằng các phương pháp học máy truyền thống (Traditional Machine Learning). Các phương pháp này thường được xây dựng theo quy trình gồm nhiều giai đoạn riêng biệt như tiền xử lý dữ liệu, trích xuất đặc trưng và phân loại dữ liệu.

Trong các phương pháp truyền thống, giai đoạn tiền xử lý thường được sử dụng nhằm cải thiện chất lượng ảnh, giảm nhiễu hoặc tăng độ tương phản để làm nổi bật các vùng chứa thông tin cần thiết. Sau đó, dữ liệu ảnh được chuyển đổi thành các đặc trưng số học để phục vụ cho quá trình phân tích và phân loại. Việc trích xuất đặc trưng có thể được thực hiện thông qua các phương pháp xử lý ảnh hoặc được thiết kế thủ công dựa trên đặc điểm của dữ liệu.

Nhiều nghiên cứu trước đây đã áp dụng các phương pháp học máy truyền thống cho bài toán phân tích ảnh X-quang lồng ngực. Một số kỹ thuật trích xuất đặc trưng thường được sử dụng gồm Gray-Level Co-occurrence Matrix (GLCM), Gray-Level Run Length Matrix (GLRLM), Histogram of Oriented Gradients (HOG), đặc trưng kết cấu (Texture Features), đặc trưng hình dạng (Shape Features), đặc trưng cường độ ảnh (Intensity Features) và các đặc trưng thống kê. Các đặc trưng này được sử dụng nhằm biểu diễn thông tin của ảnh dưới dạng dữ liệu số, hỗ trợ quá trình học và phân loại dữ

liệu.

Sau giai đoạn trích xuất đặc trưng, các thuật toán học máy được sử dụng để thực hiện phân loại dữ liệu. Một số phương pháp thường được áp dụng gồm KNN, SVM, LR, Decision Tree (DT) và Random Forest (RF). Các mô hình này sử dụng tập đặc trưng đầu vào để học sự khác biệt giữa các nhóm dữ liệu, từ đó đưa ra dự đoán đối với các mẫu chưa xuất hiện trong quá trình huấn luyện.(3)

Đối với bài toán chẩn đoán viêm phổi từ ảnh X-quang, các phương pháp truyền thống có thể hỗ trợ phát hiện các đặc điểm bất thường trong nhu mô phổi thông qua các đặc trưng được xây dựng trước. Một số nghiên cứu cho thấy các phương pháp này có thể hỗ trợ phân loại các bệnh lý trên ảnh X-quang lồng ngực. Tuy nhiên, kết quả đạt được thường phụ thuộc vào chất lượng của quá trình trích xuất đặc trưng. Việc thiết kế đặc trưng thủ công có thể yêu cầu kiến thức chuyên môn và trong một số trường hợp khó mô tả đầy đủ các đặc điểm phức tạp của dữ liệu ảnh y khoa.

Sự phát triển của các phương pháp học sâu cho phép mô hình tự động học đặc trưng trực tiếp từ dữ liệu đầu vào, giúp giảm sự phụ thuộc vào quá trình thiết kế đặc trưng thủ công. Tuy nhiên, các phương pháp truyền thống vẫn được sử dụng trong nhiều nghiên cứu như một phương pháp cơ sở nhằm đánh giá và so sánh với các mô hình hiện đại.

1.2.2 Các phương pháp học sâu

Sự phát triển của học sâu (Deep Learning) đã tạo ra nhiều thay đổi trong lĩnh vực xử lý ảnh và thị giác máy tính. Khác với các phương pháp học máy truyền thống thường yêu cầu quá trình thiết kế và trích xuất đặc trưng thủ công, các mô hình học sâu có khả năng tự động học đặc trưng trực tiếp từ dữ liệu đầu vào thông qua nhiều tầng xử lý khác nhau. Điều này giúp giảm sự phụ thuộc vào kiến thức thiết kế đặc trưng, đồng thời hỗ trợ khai thác các đặc điểm phức tạp của dữ liệu ảnh.(4)

Trong lĩnh vực ảnh y khoa, các phương pháp học sâu đã được áp dụng trong nhiều bài toán như phân loại ảnh, phát hiện tổn thương, phân đoạn ảnh và hỗ trợ chẩn đoán bệnh. Đối với ảnh X-quang lồng ngực, các mô hình học sâu thường được xây dựng dựa trên các kiến trúc mạng nơ-ron tích chập (Convolutional Neural Networks – CNN) như AlexNet, VGGNet, ResNet, DenseNet và Inception, hoặc các mô hình được huấn luyện theo hướng transfer learning từ các bộ dữ liệu lớn như ImageNet. Những mô hình này giúp học được các đặc trưng quan trọng liên quan đến cấu trúc giải phẫu và các dấu hiệu bất thường trong vùng phổi.

Bên cạnh các kiến trúc CNN truyền thống, các mô hình hiện đại dựa trên cơ chế Attention cũng ngày càng được quan tâm trong lĩnh vực xử lý ảnh y tế. Tiêu biểu là mô hình ViT, được xây dựng dựa trên kiến trúc Transformer, trong đó hình ảnh

được chia thành các patch và xử lý thông qua cơ chế self-attention để học mối quan hệ giữa các vùng khác nhau trong ảnh. Ngoài ra, một số hướng tiếp cận khác như hybrid CNN-Transformer cũng được nghiên cứu nhằm kết hợp ưu điểm của cả hai mô hình.

Đối với bài toán chẩn đoán viêm phổi từ ảnh X-quang, các phương pháp học sâu có khả năng học và biểu diễn đặc trưng trực tiếp từ dữ liệu ảnh, hỗ trợ phân biệt giữa ảnh bình thường và ảnh có dấu hiệu bệnh lý. Tuy nhiên, hiệu quả của các mô hình này phụ thuộc vào nhiều yếu tố như kiến trúc mạng, số lượng dữ liệu huấn luyện, chất lượng dữ liệu và phương pháp tiền xử lý.

Trong đề tài này, các đặc trưng được trích xuất từ nhiều phương pháp khác nhau được kết hợp nhằm xây dựng biểu diễn dữ liệu đầy đủ hơn trước khi thực hiện quá trình phân loại bệnh viêm phổi.

1.2.3 Xu hướng kết hợp đặc trưng

Trong những năm gần đây, bên cạnh việc nghiên cứu và phát triển các mô hình học sâu đơn lẻ, xu hướng kết hợp nhiều nguồn đặc trưng (feature fusion) đã được quan tâm trong nhiều bài toán thị giác máy tính và phân tích ảnh y khoa. Thay vì chỉ dựa vào một loại biểu diễn dữ liệu duy nhất, phương pháp này hướng đến việc tích hợp thông tin từ nhiều nguồn đặc trưng khác nhau nhằm khai thác tốt hơn các khía cạnh đa dạng của dữ liệu.(5)

Trong bài toán phân tích hình ảnh X-quang, các đặc trưng có thể được khai thác từ nhiều hướng tiếp cận khác nhau, bao gồm đặc trưng học sâu (deep features) trích xuất từ các mô hình như CNN hoặc Transformer, kết hợp với các đặc trưng truyền thống như đặc trưng kết cấu, đặc trưng thống kê hoặc các đặc trưng dựa trên biến đổi tín hiệu. Mỗi nhóm đặc trưng thường phản ánh một khía cạnh riêng của dữ liệu, do đó việc kết hợp chúng có thể giúp cải thiện khả năng biểu diễn tổng thể của mô hình.

Một số phương pháp kết hợp đặc trưng thường được sử dụng bao gồm phép nối đặc trưng (concatenation), kết hợp có trọng số (weighted fusion) hoặc các cơ chế học trọng số tự động dựa trên mạng nơ-ron. Trong đó, các phương pháp học trọng số cho phép mô hình tự động điều chỉnh mức độ đóng góp của từng nguồn đặc trưng trong quá trình huấn luyện, từ đó giúp biểu diễn dữ liệu phù hợp hơn với từng bài toán cụ thể.

Đối với bài toán chẩn đoán viêm phổi từ ảnh X-quang, xu hướng kết hợp đặc trưng được áp dụng nhằm tận dụng đồng thời thông tin từ nhiều cách biểu diễn khác nhau. Điều này giúp mô hình có thể khai thác cả đặc trưng cục bộ và đặc trưng mang tính tổng quát của ảnh, từ đó hỗ trợ quá trình phân loại giữa các nhóm dữ liệu.

Trong đề tài này, các đặc trưng được trích xuất từ nhiều phương pháp như ViT và các nhóm đặc trưng tính toán khác (Radiomics, Statistical, WST) được kết hợp thông

qua cơ chế học hợp nhất (feature fusion mechanism), nhằm xây dựng một biểu diễn đặc trưng thống nhất trước khi đưa vào các mô hình phân loại.

1.2.4 Một số nghiên cứu liên quan

Trong bối cảnh nhu cầu tự động hóa các hệ thống hỗ trợ chẩn đoán ngày càng gia tăng, việc khai thác thông tin từ ảnh X-quang ngược đã trở thành một hướng nghiên cứu quan trọng trong lĩnh vực y sinh. Các phương pháp hiện đại tập trung vào việc xây dựng các biểu diễn đặc trưng có khả năng phản ánh đồng thời thông tin cục bộ và thông tin toàn cục của ảnh, từ đó hỗ trợ nâng cao hiệu quả của bài toán phân loại bệnh.

Trong nhóm các mô hình học sâu, nhiều kiến trúc đã được áp dụng cho bài toán phân tích ảnh X-quang như VGG16, DenseNet-169, ViT và Swin-T. Các mô hình CNN như VGG16 và DenseNet-169 có khả năng trích xuất đặc trưng theo hướng phân cấp, từ các đặc trưng mức thấp như cạnh và kết cấu đến các đặc trưng mức cao mang tính ngữ nghĩa. Trong đó, DenseNet-169 với cơ chế kết nối dày đặc giúp cải thiện khả năng truyền gradient và khai thác đặc trưng hiệu quả hơn trong các bài toán ảnh y khoa.

Bên cạnh đó, các mô hình dựa trên Transformer như ViT và Swin Transformer đã mở ra hướng tiếp cận mới trong thị giác máy tính. ViT sử dụng cơ chế self-attention để mô hình hóa mối quan hệ toàn cục giữa các vùng ảnh, trong khi Swin Transformer cải tiến bằng cách áp dụng attention theo cửa sổ trượt (shifted window), giúp cân bằng giữa khả năng biểu diễn toàn cục và chi phí tính toán. Các mô hình này đã được ứng dụng trong nhiều nghiên cứu liên quan đến phân tích ảnh X-quang và hỗ trợ chẩn đoán bệnh.

Song song với các đặc trưng học sâu, các phương pháp trích xuất đặc trưng thủ công vẫn đóng vai trò quan trọng trong phân tích ảnh y khoa. Radiomics cho phép trích xuất các đặc trưng định lượng như kết cấu (texture), hình dạng (shape) và cường độ (intensity), giúp mô tả chi tiết đặc điểm vùng mô. Ngoài ra, các đặc trưng kết cấu thống kê dựa trên ma trận đồng xuất hiện mức xám (GLCM) vẫn được sử dụng rộng rãi nhờ khả năng biểu diễn cấu trúc cục bộ của ảnh. Bên cạnh đó, WST cung cấp đặc trưng ổn định với các biến dạng nhỏ của tín hiệu và không yêu cầu quá trình huấn luyện, do đó thường được sử dụng như một nguồn đặc trưng bổ trợ.

Nhằm tận dụng ưu điểm của các nhóm đặc trưng khác nhau, nhiều nghiên cứu gần đây đã tập trung vào hướng kết hợp đặc trưng (feature fusion). Các phương pháp đơn giản như nối đặc trưng (concatenation) hoặc tổng hợp tuyến tính có ưu điểm về tính dễ triển khai, tuy nhiên chưa phản ánh được mức độ đóng góp khác nhau của từng nguồn thông tin. Do đó, các phương pháp kết hợp thích nghi đã được đề xuất, trong đó cơ chế Gated Fusion cho phép mô hình tự động học trọng số cho từng nhóm đặc

trưng, giúp cân bằng ảnh hưởng của từng nguồn dữ liệu trong quá trình học.

Các nghiên cứu về học sâu đa nguồn (multimodal / multi-feature learning) cho thấy rằng việc kết hợp đặc trưng ở mức biểu diễn (feature-level fusion) có thể cải thiện khả năng phân biệt giữa các lớp dữ liệu trong nhiều bài toán y sinh. Tuy nhiên, phần lớn các nghiên cứu hiện tại thường chỉ khai thác một số ít nguồn đặc trưng hoặc một nhóm mô hình học sâu đơn lẻ.

Trong đề tài này, các đặc trưng được trích xuất từ nhiều mô hình học sâu gồm VGG16, DenseNet-169, ViT và Swin-T, kết hợp với các đặc trưng truyền thống như Radiomics (Rad), Statistical và WST. Sau đó, các đặc trưng được chuẩn hóa và giảm chiều bằng PCA, trước khi đưa vào cơ chế Gated Fusion để tạo biểu diễn hợp nhất. Biểu diễn này được sử dụng làm đầu vào cho các mô hình phân loại nhằm phục vụ bài toán chẩn đoán viêm phổi từ ảnh X-quang lồng ngực.

1.3 Mô tả tập dữ liệu

1.3.1 Nguồn dữ liệu

Trong nghiên cứu này, dữ liệu được sử dụng cho quá trình huấn luyện và kiểm thử được lấy từ bộ dữ liệu Chest X-Ray Images (Pneumonia) do National Institutes of Health (NIH) phát hành và được tổng hợp bởi nhóm nghiên cứu tại Guangzhou Women and Children's Medical Center, Trung Quốc. Đây là một trong những bộ dữ liệu phổ biến và được sử dụng rộng rãi trong các nghiên cứu về học máy, học sâu và thị giác máy tính cho bài toán chẩn đoán viêm phổi dựa trên ảnh X-quang lồng ngực.

Bộ dữ liệu bao gồm các ảnh X-quang lồng ngực của trẻ em trong độ tuổi từ 1 đến 5 tuổi, được chia thành hai lớp chính là Normal và Pneumonia. Các hình ảnh trong tập dữ liệu đã được các chuyên gia y tế kiểm tra và xác nhận nhãn nhằm đảm bảo độ tin cậy cho quá trình nghiên cứu và thực nghiệm.

Cụ thể, tập dữ liệu bao gồm:

- Lớp Normal: Bao gồm 1.583 ảnh X-quang lồng ngực của các trường hợp phổi bình thường, không xuất hiện dấu hiệu bất thường hay tổn thương liên quan đến viêm phổi.
- Lớp Pneumonia: Bao gồm 4.273 ảnh X-quang lồng ngực có xuất hiện các vùng mờ hoặc tổn thương đặc trưng của bệnh viêm phổi.

Tổng cộng, bộ dữ liệu gồm 5.856 ảnh X-quang lồng ngực với tỷ lệ phân bố giữa hai lớp được trình bày trong Bảng 1.1.

Bảng 1.1: Thống kê tập dữ liệu

Lớp	Tổng số	Tỷ lệ (%)
Pneumonia	4,273	73
Normal	1,583	27
Tổng	5,856	100

Có thể nhận thấy rằng tập dữ liệu có sự mất cân bằng giữa hai lớp khi số lượng ảnh thuộc lớp Pneumonia chiếm tỷ lệ lớn hơn đáng kể so với lớp Normal. Điều này đặt ra thách thức trong quá trình huấn luyện mô hình và cần được xem xét trong quá trình đánh giá hiệu quả hệ thống.

1.3.2 Tiền xử lý dữ liệu

Trong nghiên cứu này, dữ liệu ảnh X-quang lồng ngực được tiền xử lý nhằm phục vụ cho quá trình trích xuất và kết hợp đa đặc trưng trong bài toán chẩn đoán viêm phổi. Tất cả các ảnh đều được chuẩn hóa về kích thước cố định 128×128 nhằm đảm bảo tính đồng nhất giữa các tập huấn luyện và kiểm thử, đồng thời giảm chi phí tính toán cho mô hình.

Trên cơ sở đó, dữ liệu được xử lý theo nhiều nhánh đặc trưng khác nhau tương ứng với từng phương pháp trích xuất đặc trưng.

- **Nhánh RadSta:** Ảnh được chuyển sang dạng grayscale để phục vụ quá trình trích xuất các đặc trưng truyền thống như Radiomics và Statistical Features.
- **Nhánh WST:** Ảnh grayscale sau khi resize được đưa trực tiếp vào mô hình Wavelet Scattering Transform (WST) để trích xuất đặc trưng tần số và kết cấu. Sau đó, phương pháp PCA được áp dụng nhằm giảm số chiều của vector đặc trưng và tối ưu quá trình huấn luyện.
- **Nhánh Transformer:** Đối với các mô hình Transformer như Vision Transformer (ViT) và Swin Transformer-T, ảnh grayscale được chuyển đổi sang ảnh RGB bằng cách lặp lại ba kênh ảnh để phù hợp với định dạng đầu vào của mô hình.
- **Nhánh CNN:** Đối với các mô hình học sâu dựa trên CNN như VGG16 và DenseNet169, ảnh cũng được chuyển sang dạng RGB ba kênh nhằm tương thích với kiến trúc mạng được huấn luyện trước.

Như vậy, cùng một dữ liệu đầu vào nhưng được xử lý theo nhiều hướng biểu diễn khác nhau, tương ứng với đặc trưng thống kê (RadSta), đặc trưng tần số – kết cấu (WST), đặc trưng ngữ nghĩa dựa trên Transformer (ViT, Swin-T) và đặc trưng học sâu dựa trên CNN (VGG16, DenseNet169). Các đặc trưng này đóng vai trò làm đầu vào cho mô hình kết hợp đa đặc trưng trong bài toán phân loại viêm phổi.


1.3.3 Phân chia tập dữ liệu

Bộ dữ liệu ban đầu được chia thành ba phần: tập huấn luyện (train set) 5.216 ảnh, tập thẩm định (validation set) 16 ảnh và tập kiểm thử (test set) 624 ảnh, tương ứng với 88,7%, 0,3% và 10% tổng số mẫu. Tuy nhiên, do tập thẩm định có kích thước quá nhỏ và không đảm bảo tính đại diện, phần dữ liệu này được gộp vào tập huấn luyện. Sau khi gộp, tập huấn luyện mới gồm 5.232 ảnh, bao gồm 1.349 mẫu NORMAL và 3.883 mẫu PNEUMONIA. Tiếp đó, tập này được chia lại thành hai phần train và validation theo tỉ lệ 90%–10%, tương ứng với 4.708 ảnh cho huấn luyện và 524 ảnh cho thẩm định. Chi tiết về bộ dữ liệu này được mô tả ở Bảng 1.2 :

Lớp (Class)	Số mẫu Train	Số mẫu Test	Số mẫu Val	Tổng số	Tỷ lệ (%)
Pneumonia	3,494	390	389	4,273	73
Normal	1,214	234	135	1,583	27
Tổng	4708	624	524	5,856	100

Bảng 1.2: Bảng phân chia tập dữ liệu chẩn đoán viêm phổi.

Hình 1.1 đưa ra một số hình ảnh mẫu từ bộ dữ liệu chẩn đoán viêm phổi, minh họa sự khác biệt về mô hình hình ảnh giữa các trường hợp mắc bệnh và không mắc bệnh.



Hình 1.1: Một số hình ảnh từ bộ dữ liệu chẩn đoán viêm phổi.

1.4 Các chỉ số đánh giá mô hình

1.4.1 Định nghĩa các khái niệm cơ bản

Các độ đo được tính toán dựa trên ma trận nhầm lẫn (confusion matrix), bao gồm bốn thành phần:

- **TP (True Positives):** Số lượng mẫu được dự đoán là lớp dương (mắc bệnh) và thực sự là dương.

- **FP (False Positives):** Số lượng mẫu được dự đoán là lớp dương (mắc bệnh) nhưng thực tế lại là lớp âm (không mắc bệnh).
- **TN (True Negatives):** Số lượng mẫu được dự đoán là lớp âm (không mắc bệnh) và thực sự là âm.
- **FN (False Negatives):** Số lượng mẫu được dự đoán là lớp âm (không mắc bệnh) nhưng thực tế lại là lớp dương (mắc bệnh).

1.4.2 Các chỉ số đánh giá

- **Accuracy (Độ chính xác):** Đo lường tỷ lệ các dự đoán đúng trong tổng số mẫu.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

- **Precision (Độ chính xác lớp dương):** Đo lường tỷ lệ các dự đoán dương thực sự đúng.

$$\text{Precision} = \frac{TP}{TP + FP}$$

- **FDR (False Discovery Rate):** Đo lường tỷ lệ các mẫu dự đoán là dương nhưng thực tế lại là âm.

$$\text{FDR} = \frac{FP}{TP + FP} = 1 - \text{Precision}$$

- **Recall (Khả năng nhận diện dương):** Đo lường khả năng mô hình nhận diện đúng các mẫu dương.

$$\text{Recall} = \frac{TP}{TP + FN}$$

- **FNR (False Negative Rate):** Đo lường tỷ lệ các mẫu dương thực sự nhưng bị mô hình phân loại sai thành âm tính.

$$\text{FNR} = \frac{FN}{TP + FN} = 1 - \text{Recall}$$

- **Specificity (Khả năng nhận diện âm):** Đo lường khả năng mô hình nhận diện đúng các mẫu âm.

$$\text{Specificity} = \frac{TN}{TN + FP}$$

- **NPV (Negative Predictive Value):** Đo lường xác suất một mẫu được dự đoán là âm tính thực sự là âm tính.

$$\text{NPV} = \frac{TN}{TN + FN}$$

- **F1-Score (Điểm F1):** Là chỉ số kết hợp giữa Precision và Recall, đặc biệt hữu ích khi làm việc với dữ liệu không cân bằng.

$$\text{F1-score} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2 \times TP}{2 \times TP + FP + FN}$$

- **BAcc (Balanced Accuracy):** Là trung bình cộng của Recall (TPR) và Specificity (TNR), giúp đánh giá hiệu suất mô hình công bằng hơn khi dữ liệu mất cân bằng.

$$\text{BAcc} = \frac{\text{Recall} + \text{Specificity}}{2}$$

- **AUC (Area Under the ROC Curve):** AUC đo lường khả năng phân biệt giữa hai lớp của mô hình, với giá trị từ 0.5 (đoán ngẫu nhiên) đến 1.0 (mô hình hoàn hảo).

$$\text{AUC} = \int_0^1 \text{TPR}(x) d\text{FPR}(x)$$

- **MCC (Matthews Correlation Coefficient):** Matthews Correlation Coefficient (MCC) đo lường chất lượng của mô hình phân loại nhị phân, cân bằng giữa tất cả các loại lỗi (TP, FP, TN, FN).

$$\text{MCC} = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

1.5 Tiểu kết chương 1

Trong chương này, khóa luận đã trình bày tổng quan về bài toán chẩn đoán viêm phổi dựa trên ảnh X-quang lồng ngực, bao gồm các đặc điểm của hình ảnh X-quang và vai trò của trí tuệ nhân tạo trong hỗ trợ chẩn đoán bệnh. Đồng thời, chương cũng giới thiệu xu hướng trích xuất đặc trưng trong ảnh y tế với các phương pháp truyền thống, học sâu và các hướng kết hợp đặc trưng đang được nghiên cứu hiện nay.

Bên cạnh đó, chương đã mô tả bộ dữ liệu Chest X-Ray Images (Pneumonia), các bước tiền xử lý dữ liệu và phương pháp phân chia tập dữ liệu phục vụ cho quá trình huấn luyện và đánh giá mô hình. Ngoài ra, các chỉ số đánh giá như Accuracy, Precision, Recall và F1-Score cũng được trình bày nhằm làm cơ sở đánh giá hiệu quả của các phương pháp trong các chương tiếp theo.

Những nội dung trình bày trong chương này là nền tảng lý thuyết quan trọng để triển khai các phương pháp trích xuất đặc trưng và kết hợp đặc trưng phục vụ bài toán chẩn đoán viêm phổi trong các chương tiếp theo của khóa luận.

CHƯƠNG 2

PHƯƠNG PHÁP TRÍCH XUẤT ĐẶC TRƯNG

2.1 Các phương pháp trích xuất đặc trưng truyền thống

2.1.1 Mô hình WST

Giới thiệu Wavelet Transform

Wavelet Transform là một phương pháp phân tích tín hiệu trong miền thời gian - tần số được sử dụng rộng rãi trong xử lý tín hiệu và xử lý ảnh. Khác với Fourier Transform chỉ cung cấp thông tin tần số tổng quát của tín hiệu, Wavelet Transform cho phép phân tích đồng thời cả thông tin thời gian (hoặc không gian) và tần số. Nhờ đó, phương pháp này có khả năng biểu diễn hiệu quả các đặc trưng cục bộ cũng như các biến đổi không ổn định của tín hiệu.

Wavelet Transform thực hiện phân tích tín hiệu ở nhiều mức độ phân giải khác nhau thông qua quá trình co giãn và tịnh tiến hàm wavelet mẹ. Điều này cho phép mô hình vừa quan sát được đặc trưng tổng quát, vừa khai thác được các chi tiết cục bộ của tín hiệu hoặc hình ảnh tại nhiều thang đo khác nhau.

Các dạng Wavelet Transform phổ biến bao gồm:

- Continuous Wavelet Transform (CWT): Phân tích tín hiệu liên tục trong miền thời gian - tần số với độ phân giải cao;
- Discrete Wavelet Transform (DWT): Phiên bản rời rạc của Wavelet Transform, có chi phí tính toán thấp và được ứng dụng rộng rãi trong xử lý ảnh và video;
- Multi-Level 2D DWT: Phương pháp phân rã ảnh hai chiều theo nhiều cấp độ

nhằm xây dựng biểu diễn đa phân giải của ảnh.

Trong xử lý ảnh, Discrete Wavelet Transform thường phân rã ảnh thành bốn thành phần tần số gồm:

- LL (Low-Low): Thành phần tần số thấp, chứa thông tin tổng quát của ảnh;
- LH (Low-High): Thành phần chi tiết theo chiều ngang;
- HL (High-Low): Thành phần chi tiết theo chiều dọc;
- HH (High-High): Thành phần chi tiết theo đường chéo.

Sau mỗi lần phân rã, thành phần LL tiếp tục được phân tích ở các cấp độ tiếp theo nhằm tạo ra biểu diễn đa phân giải (multi-resolution representation). Cơ chế này cho phép Wavelet Transform mô tả đồng thời cả cấu trúc tổng thể và các chi tiết cục bộ của ảnh.

Nhờ khả năng phân tích cục bộ và biểu diễn đa thang đo, Wavelet Transform có thể phát hiện hiệu quả các cạnh biên, texture và các đặc trưng nhỏ trong ảnh. Bên cạnh đó, phương pháp này còn được ứng dụng rộng rãi trong nén ảnh, nén video, xử lý ảnh y khoa và nhận dạng mẫu nhờ khả năng giữ lại các vùng thông tin quan trọng trong khi giảm kích thước dữ liệu.

Nguyên lý hoạt động của Wavelet Transform

Wavelet Transform thực hiện việc phân tích tín hiệu ở nhiều mức độ phân giải khác nhau thông qua quá trình co giãn và tịnh tiến hàm wavelet cơ sở (Morlet, Haar,...). Nhờ cơ chế này, phương pháp có khả năng khai thác đồng thời cả các đặc trưng tổng quát và các chi tiết cục bộ của tín hiệu hoặc hình ảnh. Nói cách khác, Wavelet Transform cho phép quan sát tín hiệu tại nhiều thang đo khác nhau, từ đó mô tả hiệu quả các đặc trưng biến đổi theo không gian và tần số, thay vì chỉ cung cấp thông tin tần số tổng quát như Fourier Transform.

Biến đổi Wavelet liên tục (Continuous Wavelet Transform – CWT) được xác định theo công thức:

$$W(a, b) = \int_{-\infty}^{\infty} f(t) \psi_{a,b}(t) dt \quad (2.1)$$

Trong đó, hàm wavelet được biểu diễn như sau:

$$\psi_{a,b}(t) = \frac{1}{\sqrt{a}} \psi\left(\frac{t-b}{a}\right) \quad (2.2)$$

Với:

- $f(t)$ là tín hiệu hoặc ảnh đầu vào;
- $\psi(t)$ là hàm wavelet mẹ (mother wavelet);
- a là hệ số tỉ lệ (scale), điều khiển mức độ co giãn của wavelet;
- b là hệ số tịnh tiến (translation), xác định vị trí phân tích trên tín hiệu;
- $W(a, b)$ là hệ số wavelet, biểu diễn thông tin của tín hiệu tại từng thang đo và vị trí cụ thể.

Wavelet Scattering Transform

Dựa trên nền tảng của Wavelet Transform, Stéphane Mallat đã đề xuất phương pháp Wavelet Scattering Transform (WST) nhằm nâng cao khả năng biểu diễn đặc trưng của tín hiệu và hình ảnh. WST kết hợp giữa phép biến đổi wavelet, các phép toán phi tuyến và phép làm mượt để tạo ra các đặc trưng ổn định, bất biến đối với các phép tịnh tiến nhỏ và có khả năng chống nhiễu tốt. Nhờ những đặc tính này, WST được ứng dụng hiệu quả trong các bài toán phân loại tín hiệu, xử lý ảnh và đặc biệt là xử lý ảnh y khoa.

Về bản chất, WST được xây dựng theo kiến trúc tương tự một mạng tích chập sâu (deep convolutional network), bao gồm các bước lặp lại của phép tích chập wavelet, phép toán phi tuyến modulus và bộ lọc thông thấp. Tuy nhiên, khác với Convolutional Neural Network (CNN), các bộ lọc trong WST được xác định trước dựa trên lý thuyết wavelet thay vì được học từ dữ liệu huấn luyện. Điều này giúp WST giảm số lượng tham số cần tối ưu, hạn chế hiện tượng overfitting và hoạt động hiệu quả ngay cả khi dữ liệu huấn luyện bị hạn chế.

Một trong những đóng góp quan trọng nhất của WST là khả năng xây dựng biểu diễn đặc trưng vừa bất biến đối với phép tịnh tiến, vừa ổn định trước các biến dạng nhỏ của tín hiệu. Theo Mallat, một hệ biểu diễn tín hiệu tốt không chỉ cần giữ lại thông tin quan trọng mà còn phải đảm bảo rằng các thay đổi nhỏ trên dữ liệu đầu vào chỉ gây ra các thay đổi nhỏ trong không gian đặc trưng. Nhờ vậy, WST có khả năng chống nhiễu và duy trì độ ổn định cao trong các bài toán xử lý ảnh thực tế.

Đối với một tín hiệu đầu vào x , quá trình tính toán WST được thực hiện qua các bước sau:

1. Tín hiệu đầu vào được tích chập với hàm wavelet ψ_λ tại các thang đo và tần số khác nhau:

$$x * \psi_\lambda \tag{2.3}$$

Trong đó, λ biểu diễn tần số trung tâm của wavelet.

2. Sau phép tích chập, một phép toán phi tuyến modulus được áp dụng nhằm loại bỏ dao động pha và giữ lại thông tin biên độ:

$$|x * \psi_\lambda| \quad (2.4)$$

Phép modulus đóng vai trò tương tự hàm kích hoạt trong CNN, giúp tăng tính ổn định của biểu diễn đặc trưng và chuyển năng lượng từ miền tần số cao sang miền tần số thấp.

3. Cuối cùng, bộ lọc thông thấp ϕ được sử dụng để thực hiện phép lấy trung bình cục bộ:

$$|x * \psi_\lambda| * \phi \quad (2.5)$$

Bước này giúp tạo tính bất biến đối với các phép tịnh tiến nhỏ của tín hiệu.

Từ các bước trên, hệ số scattering bậc nhất được xác định như sau:

$$S_1x = |x * \psi_{\lambda_1}| * \phi \quad (2.6)$$

Hệ số scattering bậc nhất chủ yếu biểu diễn các đặc trưng cục bộ như biên, kết cấu và các thành phần tần số quan trọng của tín hiệu.

Tuy nhiên, quá trình lấy trung bình cục bộ có thể làm mất đi một phần thông tin tần số cao. Để khôi phục các thành phần này, phép biến đổi scattering tiếp tục được áp dụng lên đầu ra của lớp trước. Khi đó, hệ số scattering bậc hai được xác định bởi:

$$S_2x = ||x * \psi_{\lambda_1}| * \psi_{\lambda_2}| * \phi \quad (2.7)$$


Scattering bậc hai cho phép mô hình khai thác các tương tác phức tạp hơn giữa các thành phần tần số, từ đó cải thiện khả năng biểu diễn đặc trưng của tín hiệu và hình ảnh.

Tổng quát, các hệ số scattering bậc cao hơn được xây dựng bằng cách lặp lại quá trình tích chập wavelet, modulus và lọc thông thấp. Tập đặc trưng cuối cùng của WST được hình thành bằng cách kết hợp các hệ số scattering từ bậc 0 đến bậc m :

$$Sx = \{S_0x, S_1x, S_2x, \dots, S_mx\} \quad (2.8)$$

Trong đó:

- S_0x biểu diễn hệ số scattering bậc không, chứa thông tin tần số thấp của tín hiệu;
- S_1x biểu diễn các đặc trưng cục bộ bậc nhất;
- S_2x biểu diễn các đặc trưng tương tác phức tạp hơn của tín hiệu.



Hình 2.1: Sơ đồ quy trình trích xuất đặc trưng bằng phương pháp WST bậc hai

Một ưu điểm quan trọng của WST là khả năng biểu diễn đặc trưng đa thang đo (multi-scale representation). Các wavelet filter được xây dựng ở nhiều tần số và nhiều tỉ lệ khác nhau, cho phép mô hình đồng thời khai thác: các đặc trưng cục bộ nhỏ, cấu trúc trung bình và các mẫu hình toàn cục của tín hiệu.

Trong xử lý ảnh y khoa, khả năng đa thang đo này đặc biệt hữu ích vì tổn thương có thể xuất hiện ở nhiều kích thước khác nhau, từ các nốt mờ nhỏ cho đến các vùng tổn thương lan rộng. WST giúp giữ lại thông tin đặc trưng ở nhiều mức khác nhau mà không cần học bộ lọc trực tiếp từ dữ liệu.

Ngoài ra, WST còn có tính ổn định Lipschitz đối với các biến dạng cục bộ. Điều này có nghĩa là nếu tín hiệu đầu vào chỉ bị thay đổi nhỏ do nhiễu hoặc biến dạng hình học, đặc trưng scattering cũng chỉ thay đổi với biên độ nhỏ tương ứng. Tính chất này giúp WST hoạt động ổn định trong các bài toán xử lý ảnh thực tế, đặc biệt là ảnh y khoa vốn thường chứa nhiều nhiễu trong quá trình thu nhận ảnh.

Theo nhiều nghiên cứu trước đây, phần lớn năng lượng scattering tập trung ở hai bậc đầu tiên. Cụ thể: scattering bậc 0 chứa thông tin tổng quát của tín hiệu, scattering bậc 1 mô tả các đặc trưng cục bộ, scattering bậc 2 mô tả mối quan hệ giữa các thành phần tần số. Các bậc scattering cao hơn thường đóng góp rất ít năng lượng nhưng lại làm tăng đáng kể chi phí tính toán. Do đó, trong hầu hết các nghiên cứu thực tế, các hệ số scattering bậc một và bậc hai thường được sử dụng để đảm bảo hiệu quả biểu diễn đặc trưng và giảm độ phức tạp tính toán.

Ưu điểm và hạn chế của mô hình WST

Wavelet Scattering Transform (WST) là một phương pháp trích xuất đặc trưng hiệu quả trong xử lý tín hiệu và xử lý ảnh, đặc biệt phù hợp với các bài toán ảnh y khoa. Bằng cách kết hợp giữa Wavelet Transform và cơ chế tích chập đa tầng, WST có khả năng tạo ra các đặc trưng ổn định, bất biến đối với các phép tịnh tiến nhỏ và có khả năng chống nhiễu tốt. Ngoài ra, phương pháp này còn cho phép biểu diễn đặc trưng ở nhiều thang đo khác nhau, giúp mô hình khai thác hiệu quả cả thông tin tổng quát lẫn các chi tiết cục bộ của ảnh. Một ưu điểm quan trọng của WST là không cần huấn luyện các bộ lọc như CNN, nhờ đó giảm chi phí huấn luyện và hạn chế hiện tượng overfitting khi làm việc với các tập dữ liệu nhỏ.

Bên cạnh những ưu điểm nổi bật, WST vẫn tồn tại một số hạn chế nhất định. Do sử dụng các bộ lọc wavelet được xác định trước bằng toán học, mô hình có tính linh hoạt thấp hơn so với CNN trong việc học đặc trưng trực tiếp từ dữ liệu. Ngoài ra, vector đặc trưng scattering thường có kích thước lớn, dẫn đến tăng chi phí lưu trữ và tính toán. Hiệu quả của WST cũng phụ thuộc đáng kể vào việc lựa chọn tham số wavelet và số bậc scattering phù hợp cho từng bài toán cụ thể.

Trong lĩnh vực xử lý ảnh y khoa, WST cho thấy hiệu quả cao trong việc phát hiện các bất thường trên ảnh X-quang phổi. Phương pháp này giúp tăng khả năng phân biệt giữa vùng tổn thương và mô lành, đồng thời giảm ảnh hưởng của nhiễu và sự khác biệt trong điều kiện chụp ảnh. Nhờ khả năng biểu diễn đặc trưng ổn định và có cơ sở toán học rõ ràng, WST được xem là cầu nối giữa các phương pháp xử lý tín hiệu truyền thống và các mô hình học sâu hiện đại, mở ra nhiều tiềm năng ứng dụng trong các bài toán phân tích ảnh y khoa.

2.1.2 Mô hình Statistical Features

Giới Thiệu

Đặc trưng thống kê (Statistical Features) là phương pháp biểu diễn thông tin của dữ liệu thông qua các đại lượng thống kê được tính toán từ tập dữ liệu ban đầu. Trong xử lý ảnh, các đặc trưng này thường được sử dụng để mô tả sự phân bố giá trị mức xám của ảnh dưới dạng các thông số định lượng. Thay vì sử dụng trực tiếp toàn bộ dữ liệu điểm ảnh, ảnh sẽ được chuyển đổi thành một tập các đặc trưng nhằm giảm kích thước dữ liệu và hỗ trợ quá trình phân tích.

Các đặc trưng thống kê có khả năng phản ánh một số đặc điểm của ảnh như độ sáng trung bình, mức độ phân tán dữ liệu, tính đối xứng của phân bố và mức độ phức tạp của ảnh. Một số đặc trưng thống kê thường được sử dụng bao gồm giá trị trung bình (Mean), độ lệch chuẩn (Standard Deviation), phương sai (Variance), độ lệch

(Skewness), độ nhọn (Kurtosis), năng lượng (Energy) và Entropy.

Trong lĩnh vực xử lý ảnh y tế, đặc trưng thống kê được sử dụng nhằm biểu diễn các đặc điểm của ảnh dưới dạng số liệu để phục vụ cho các mô hình học máy. Việc sử dụng các đặc trưng này giúp giảm số chiều của dữ liệu đầu vào, đồng thời giữ lại các thông tin cần thiết phục vụ cho quá trình phân loại và nhận dạng.

Đặc trưng thống kê thường được chia thành hai nhóm chính là đặc trưng thống kê bậc một (First-order Statistical Features) và đặc trưng thống kê bậc hai (Second-order Statistical Features). Đặc trưng thống kê bậc một được tính toán trực tiếp từ histogram của ảnh và chỉ phản ánh sự phân bố mức xám của các điểm ảnh. Trong khi đó, đặc trưng thống kê bậc hai sử dụng thông tin về mối quan hệ giữa các điểm ảnh lân cận thông qua ma trận đồng xuất hiện mức xám (Gray-Level Co-occurrence Matrix – GLCM) để mô tả cấu trúc của ảnh chi tiết hơn.

Trong nghiên cứu này, các đặc trưng thống kê bậc một sẽ được sử dụng để trích xuất thông tin từ ảnh X-quang lồng ngực nhằm xây dựng vector đặc trưng phục vụ cho quá trình huấn luyện và phân loại dữ liệu.

Quy trình trích xuất đặc trưng thống kê

Quá trình trích xuất đặc trưng thống kê được thực hiện nhằm chuyển đổi dữ liệu ảnh đầu vào thành tập các đặc trưng số có khả năng biểu diễn những thông tin quan trọng của ảnh. Thay vì sử dụng trực tiếp toàn bộ dữ liệu điểm ảnh với số chiều lớn, phương pháp này sử dụng các đại lượng thống kê để mô tả đặc điểm của ảnh thông qua sự phân bố các mức xám. Việc biểu diễn ảnh dưới dạng vector đặc trưng không chỉ giúp giảm kích thước dữ liệu mà còn hỗ trợ quá trình học và phân loại của mô hình đạt hiệu quả tốt hơn.

Trong nghiên cứu này, quá trình trích xuất đặc trưng thống kê được thực hiện thông qua một số bước chính. Trước hết, ảnh X-quang từ dữ liệu đầu vào được đưa về cùng một kích thước nhằm đảm bảo tính đồng nhất giữa các mẫu dữ liệu. Việc chuẩn hóa kích thước ảnh giúp giảm ảnh hưởng của sự khác biệt về độ phân giải giữa các ảnh, đồng thời tạo điều kiện thuận lợi cho quá trình xử lý ở các bước tiếp theo.

Sau quá trình chuẩn hóa, ảnh được chuyển đổi từ dạng ma trận hai chiều sang dạng vector một chiều bằng phương pháp trải phẳng (Flatten). Giả sử ảnh đầu vào có kích thước:

$$M \times N \tag{2.9}$$

thì dữ liệu ảnh sau khi chuyển đổi có thể được biểu diễn dưới dạng:

$$X = \{x_1, x_2, x_3, \dots, x_n\} \quad (2.10)$$

Trong đó:

- x_i là giá trị mức xám của điểm ảnh thứ i ;
- $n = M \times N$.


Việc chuyển đổi ảnh sang dạng vector giúp quá trình tính toán các đặc trưng thống kê được thực hiện thuận lợi hơn.

Tiếp theo, histogram của ảnh được xây dựng để mô tả sự phân bố của các mức xám xuất hiện trong ảnh. Histogram sẽ phản ánh số lượng điểm ảnh tương ứng với từng mức cường độ sáng và được sử dụng để xác định xác suất xuất hiện của các mức xám. Trong đó, xác suất xuất hiện của mức xám được xác định theo công thức:

$$P(i) = \frac{I(m)}{N} \quad (2.11)$$

Trong đó:

- $I(m)$ là số lượng điểm ảnh tại mức xám m ;
- N là tổng số điểm ảnh trong ảnh;
- $P(i)$ là xác suất xuất hiện của mức xám tương ứng.



Hình 2.2: Ví dụ histogram mức xám của ảnh X-quang lồng ngực

Các đặc trưng thống kê sử dụng

Từ phân bố xác suất của histogram, các đặc trưng thống kê được tính toán nhằm mô tả những đặc điểm của ảnh dưới dạng định lượng. Trong nghiên cứu này, các đặc trưng được sử dụng bao gồm giá trị trung bình (Mean), độ lệch chuẩn (Standard Deviation), phương sai (Variance), giá trị nhỏ nhất (Minimum), giá trị lớn nhất (Maximum), trung vị (Median), khoảng biến thiên (Range), độ lệch (Skewness), độ nhọn (Kurtosis), năng lượng (Energy), căn trung bình bình phương (Root Mean Square – RMS) và Entropy.


Sau khi tính toán, các giá trị đặc trưng được kết hợp thành một vector đặc trưng đại diện cho ảnh đầu vào:

$$F = \{f_1, f_2, f_3, \dots, f_k\} \quad (2.12)$$

Trong đó:

- f_i là đặc trưng thứ i ;
- k là tổng số đặc trưng được sử dụng.

Vector đặc trưng này được sử dụng làm dữ liệu đầu vào cho các mô hình học máy trong quá trình huấn luyện và phân loại. Việc sử dụng vector đặc trưng giúp giảm số chiều dữ liệu nhưng vẫn giữ lại các thông tin cần thiết phục vụ cho quá trình nhận dạng và phân tích ảnh.



Hình 2.3: Quy trình trích xuất đặc trưng Statistical

Các đặc trưng thống kê sử dụng

Tập đặc trưng thống kê được xây dựng gồm 12 đặc trưng nhằm mô tả các đặc điểm của ảnh X-quang lồng ngực dưới dạng các giá trị định lượng. Các đặc trưng này được tính toán từ phân bố mức xám của ảnh và được sử dụng để biểu diễn những thông tin liên quan đến độ sáng, mức độ biến thiên và đặc điểm phân bố của dữ liệu ảnh.

Giá trị trung bình (*Mean*) được sử dụng để xác định cường độ sáng trung bình của ảnh. Đặc trưng này phản ánh xu hướng phân bố chung của các giá trị mức xám trong ảnh và được tính theo công thức:

$$Mean = \frac{1}{N} \sum_{i=1}^N x_i \quad (2.13)$$

Trong đó:

- x_i là giá trị mức xám của điểm ảnh thứ i ;
- N là tổng số điểm ảnh trong ảnh.

Độ lệch chuẩn (*Standard Deviation*) được sử dụng để đánh giá mức độ phân tán của các giá trị mức xám quanh giá trị trung bình. Giá trị độ lệch chuẩn lớn cho thấy dữ liệu có sự biến đổi cao, trong khi giá trị nhỏ thể hiện dữ liệu phân bố tập trung hơn.

$$Std = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2} \quad (2.14)$$

Trong đó:

- μ là giá trị trung bình của dữ liệu.

Phương sai (*Variance*) phản ánh mức độ biến thiên của dữ liệu so với giá trị trung bình. Đặc trưng này giúp xác định mức độ thay đổi của các mức xám trong ảnh.

$$Var = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2 \quad (2.15)$$

Giá trị nhỏ nhất (*Minimum*) được sử dụng để xác định mức cường độ thấp nhất xuất hiện trong ảnh:

$$Minimum = \min(x_i) \quad (2.16)$$

Giá trị lớn nhất (*Maximum*) được sử dụng để xác định mức cường độ lớn nhất xuất hiện trong ảnh:

$$Maximum = \max(x_i) \quad (2.17)$$

Trung vị (*Median*) phản ánh giá trị nằm giữa của tập dữ liệu sau khi các phần tử được sắp xếp theo thứ tự tăng dần:

$$Median = \text{median}(x_i) \quad (2.18)$$

Khoảng biến thiên (*Range*) được sử dụng để xác định độ chênh lệch giữa giá trị lớn nhất và giá trị nhỏ nhất trong dữ liệu:

$$Range = Maximum - Minimum \quad (2.19)$$

Độ lệch (*Skewness*) được sử dụng để xác định mức độ bất đối xứng của phân bố dữ liệu. Giá trị dương hoặc âm của đặc trưng này phản ánh xu hướng lệch phải hoặc lệch trái của histogram.

$$Skewness = \frac{1}{N} \sum_{i=1}^N \left(\frac{x_i - \mu}{\sigma} \right)^3 \quad (2.20)$$

Trong đó:

- σ là độ lệch chuẩn của dữ liệu.

Độ nhọn (*Kurtosis*) phản ánh mức độ tập trung của dữ liệu quanh giá trị trung bình. Đặc trưng này cho biết phân bố dữ liệu có xu hướng tập trung cao hay phân tán rộng.

$$Kurtosis = \frac{1}{N} \sum_{i=1}^N \left(\frac{x_i - \mu}{\sigma} \right)^4 \quad (2.21)$$

Năng lượng (*Energy*) được sử dụng để đánh giá mức độ đồng nhất của dữ liệu ảnh. Giá trị năng lượng cao thường cho thấy dữ liệu có xu hướng tập trung vào một số mức xám nhất định.

$$Energy = \sum_{i=1}^N x_i^2 \quad (2.22)$$

Căn trung bình bình phương (*Root Mean Square - RMS*) phản ánh giá trị cường độ trung bình của dữ liệu dưới dạng bình phương và được xác định theo công thức:

$$RMS = \sqrt{\frac{1}{N} \sum_{i=1}^N x_i^2} \quad (2.23)$$

Entropy được sử dụng để phản ánh mức độ ngẫu nhiên của dữ liệu ảnh. Giá trị Entropy lớn cho thấy sự phân bố mức xám phức tạp hơn, trong khi giá trị nhỏ thể hiện dữ liệu có xu hướng tập trung hơn.

$$Entropy = - \sum_{i=1}^N P(i) \log_2 P(i) \quad (2.24)$$

Trong đó:

- $P(i)$ là xác suất xuất hiện của mức xám thứ i trong histogram.

Bảng 2.1: Các đặc trưng thống kê sử dụng trong nghiên cứu

STT	Đặc trưng	Ký hiệu	Ý nghĩa
1	Mean	Mean	Xác định cường độ sáng trung bình của ảnh
2	Standard Deviation	Std	Đánh giá mức độ phân tán của dữ liệu
3	Variance	Var	Đo mức độ biến thiên dữ liệu
4	Minimum	Min	Giá trị mức xám nhỏ nhất
5	Maximum	Max	Giá trị mức xám lớn nhất
6	Median	Med	Giá trị trung vị của dữ liệu
7	Range	Range	Khoảng chênh lệch giữa giá trị lớn nhất và nhỏ nhất
8	Skewness	Skew	Mức độ bất đối xứng của dữ liệu
9	Kurtosis	Kurt	Mức độ tập trung quanh giá trị trung bình
10	Energy	Energy	Mức độ đồng nhất của dữ liệu ảnh
11	RMS	RMS	Giá trị cường độ trung bình theo bình phương
12	Entropy	Entropy	Mức độ ngẫu nhiên của dữ liệu

Sau khi tính toán, toàn bộ các đặc trưng được kết hợp thành một vector đặc trưng đại diện cho ảnh đầu vào và được sử dụng làm dữ liệu đầu vào cho mô hình học máy trong quá trình huấn luyện và phân loại.

Chuẩn hóa dữ liệu đặc trưng

Sau quá trình trích xuất, các đặc trưng thống kê thu được thường có phạm vi giá trị khác nhau. Một số đặc trưng có thể có giá trị lớn như Energy, trong khi các đặc trưng khác như Skewness hoặc Entropy có thể có phạm vi giá trị nhỏ hơn. Sự khác

biệt về thang đo giữa các đặc trưng có thể làm ảnh hưởng đến quá trình huấn luyện mô hình học máy, khiến một số đặc trưng chiếm ưu thế hơn so với các đặc trưng còn lại.

Để giảm ảnh hưởng của sự khác biệt về phạm vi giá trị giữa các đặc trưng, quá trình chuẩn hóa dữ liệu được thực hiện trước khi đưa dữ liệu vào mô hình phân loại. Phương pháp chuẩn hóa StandardScaler được sử dụng để chuyển đổi dữ liệu về cùng thang đo với giá trị trung bình gần bằng 0 và độ lệch chuẩn gần bằng 1.

Quá trình chuẩn hóa được thực hiện theo công thức:

$$z = \frac{x - \mu}{\sigma} \quad (2.25)$$

Trong đó:

- x là giá trị đặc trưng ban đầu;
- μ là giá trị trung bình của đặc trưng;
- σ là độ lệch chuẩn của đặc trưng;
- z là giá trị đặc trưng sau khi chuẩn hóa.

Sau quá trình chuẩn hóa, dữ liệu được đưa về cùng phạm vi biểu diễn, giúp giảm ảnh hưởng của sự khác biệt về đơn vị đo giữa các đặc trưng. Điều này hỗ trợ quá trình học của mô hình trở nên ổn định hơn, đồng thời cải thiện khả năng hội tụ và hiệu quả phân loại.

Dữ liệu đặc trưng của tập huấn luyện được sử dụng để tính toán giá trị trung bình và độ lệch chuẩn. Các tham số này sau đó được áp dụng cho tập kiểm tra nhằm đảm bảo tính nhất quán trong quá trình xử lý dữ liệu.

Ưu điểm và hạn chế của Statistical Features

Phương pháp trích xuất đặc trưng thống kê sử dụng các thông tin từ phân bố mức xám của ảnh nhằm biểu diễn dữ liệu dưới dạng các giá trị định lượng. Phương pháp này có một số ưu điểm như khả năng tính toán đơn giản, thời gian xử lý thấp và không yêu cầu quá trình huấn luyện phức tạp. Ngoài ra, số chiều của vector đặc trưng thường nhỏ hơn đáng kể so với dữ liệu ảnh ban đầu, giúp giảm chi phí tính toán trong quá trình huấn luyện mô hình học máy.

Bên cạnh các ưu điểm, phương pháp này cũng tồn tại một số hạn chế. Các đặc trưng thống kê chủ yếu phản ánh thông tin về phân bố cường độ sáng và mức độ biến thiên của ảnh nên chưa khai thác đầy đủ thông tin về cấu trúc không gian hoặc mối

quan hệ giữa các vùng trong ảnh. Đối với ảnh y tế có đặc điểm phức tạp như ảnh X-quang lồng ngực, việc chỉ sử dụng đặc trưng thống kê có thể làm giảm khả năng biểu diễn các đặc điểm bệnh lý chi tiết. Vì vậy, trong nhiều nghiên cứu hiện nay, đặc trưng thống kê thường được kết hợp với các phương pháp khác như Radiomics hoặc các mô hình học sâu nhằm nâng cao hiệu quả phân loại.

2.1.3 Mô hình Radiomics

Giới thiệu

Radiomics là phương pháp trích xuất các đặc trưng định lượng từ ảnh y tế nhằm chuyển đổi thông tin từ hình ảnh thành dữ liệu số có thể xử lý và phân tích bằng máy tính. Thay vì sử dụng trực tiếp dữ liệu ảnh ban đầu, phương pháp này biểu diễn ảnh thông qua các đặc trưng định lượng nhằm mô tả những đặc điểm về cường độ, kết cấu và cấu trúc của vùng cần phân tích.

Trong lĩnh vực xử lý ảnh y tế, Radiomics được sử dụng để khai thác các thông tin tiềm ẩn từ ảnh dưới dạng các tham số định lượng, từ đó hỗ trợ mô tả đặc điểm của mô hoặc vùng tổn thương. Các thông tin này có thể được sử dụng làm dữ liệu đầu vào cho các mô hình học máy trong quá trình phân tích và phân loại dữ liệu ảnh.

Đối với bài toán chẩn đoán viêm phổi từ ảnh X-quang lồng ngực, việc áp dụng phương pháp Radiomics cho phép biểu diễn đặc điểm của vùng phổi thông qua các giá trị số thay vì sử dụng trực tiếp ma trận điểm ảnh. Cách tiếp cận này giúp chuyển đổi dữ liệu ảnh có số chiều lớn thành tập đặc trưng có khả năng mô tả thông tin của ảnh dưới dạng ngắn gọn hơn, đồng thời vẫn giữ lại các đặc điểm cần thiết phục vụ quá trình học của mô hình.

Trong nghiên cứu này, quá trình trích xuất đặc trưng Radiomics được thực hiện bằng thư viện *PyRadiomics*. Dựa trên đặc điểm của dữ liệu và mục tiêu nghiên cứu, ba nhóm đặc trưng được sử dụng bao gồm:

- Đặc trưng bậc một (*First-order Features*);
- Đặc trưng ma trận đồng xuất hiện mức xám (*Gray Level Co-occurrence Matrix – GLCM*);
- Đặc trưng ma trận vùng mức xám (*Gray Level Size Zone Matrix – GLSZM*).

Mỗi nhóm đặc trưng cung cấp những thông tin khác nhau về ảnh đầu vào. Trong đó, đặc trưng *First-order* được sử dụng để mô tả sự phân bố của các mức xám trong ảnh; đặc trưng *GLCM* phản ánh mối quan hệ không gian giữa các điểm ảnh lân cận;

trong khi đó, đặc trưng *GLSZM* mô tả kích thước và sự phân bố của các vùng có cùng mức xám trong ảnh.

Sau khi được trích xuất, toàn bộ các đặc trưng được kết hợp thành một vector đặc trưng đại diện cho ảnh đầu vào và được sử dụng làm dữ liệu đầu vào cho mô hình học máy phục vụ trong quá trình huấn luyện và phân loại.

Quy trình trích xuất Radiomics

Quá trình trích xuất đặc trưng Radiomics được thực hiện nhằm chuyển đổi dữ liệu ảnh X-quang thành các đặc trưng định lượng phục vụ cho bài toán phân loại. Thay vì sử dụng trực tiếp toàn bộ dữ liệu điểm ảnh đầu vào, phương pháp này biểu diễn ảnh thông qua tập các đặc trưng mô tả đặc điểm cường độ và kết cấu của vùng cần phân tích.

Trong nghiên cứu này, quá trình trích xuất đặc trưng được thực hiện bằng thư viện PyRadiomics trên vùng phổi được xác định từ ảnh phân đoạn (mask). Quy trình thực hiện gồm các bước như sau:

1. Tiền xử lý ảnh

Ảnh X-quang đầu vào được chuẩn hóa kích thước và chuyển đổi về định dạng phù hợp để phục vụ cho quá trình xử lý. Việc tiền xử lý giúp đảm bảo dữ liệu có tính đồng nhất trước khi tiến hành trích xuất đặc trưng.

2. Xác định vùng quan tâm (Region of Interest – ROI)

Để tập trung vào khu vực chứa thông tin cần phân tích, ảnh phân đoạn (mask) được sử dụng để xác định vùng phổi trên ảnh X-quang. Các vùng ngoài khu vực phổi không được sử dụng trong quá trình tính toán đặc trưng.

3. Chuyển đổi dữ liệu sang định dạng xử lý

Sau khi xác định vùng quan tâm, dữ liệu ảnh và mask được chuyển sang định dạng *SimpleITK Image*. Đây là định dạng được thư viện PyRadiomics sử dụng để tính toán các đặc trưng định lượng.

4. Trích xuất đặc trưng Radiomics

Sau khi xác định vùng quan tâm, các đặc trưng Radiomics được tính toán thông qua thư viện PyRadiomics. Trong nghiên cứu này, các nhóm đặc trưng được sử dụng bao gồm:

- Đặc trưng bậc một (*First-order Features*);
- Đặc trưng ma trận đồng xuất hiện mức xám (*Gray Level Co-occurrence Matrix – GLCM*);

- Đặc trưng ma trận vùng mức xám (*Gray Level Size Zone Matrix – GLSZM*).

Các đặc trưng này được sử dụng để mô tả phân bố cường độ sáng, mối quan hệ giữa các điểm ảnh lân cận và sự phân bố của các vùng có cùng mức xám trong ảnh.

5. Xây dựng vector đặc trưng


Sau khi hoàn tất quá trình tính toán, toàn bộ các đặc trưng được kết hợp thành một vector đặc trưng đại diện cho mỗi ảnh:

$$F = \{f_1, f_2, f_3, \dots, f_n\} \quad (2.26)$$

Trong đó:

- f_i là đặc trưng thứ i ;
- n là tổng số đặc trưng được trích xuất.

Các đặc trưng thu được từ quá trình này được sử dụng làm đầu vào cho các mô hình học máy trong giai đoạn thực nghiệm của nghiên cứu.



Hình 2.4: Quy trình trích xuất đặc trưng Radiomics

Các đặc trưng Radiomics sử dụng

Trong nghiên cứu này, các đặc trưng Radiomics được trích xuất nhằm mô tả thông tin định lượng của vùng phổi trong ảnh X-quang. Các đặc trưng được sử dụng bao gồm ba nhóm chính: đặc trưng bậc một (First-order), ma trận đồng xuất hiện mức xám (Gray Level Co-occurrence Matrix – GLCM) và ma trận vùng mức xám (Gray Level Size Zone Matrix – GLSZM). Các nhóm đặc trưng này phản ánh thông tin về phân bố cường độ và cấu trúc của ảnh trong vùng quan tâm.

Đặc trưng First-order

Nhóm đặc trưng First-order mô tả phân bố thống kê của giá trị mức xám trong vùng quan sát mà không xét đến mối quan hệ không gian giữa các điểm ảnh. Các đặc trưng này phản ánh đặc tính cường độ tổng quát của ảnh và được sử dụng để mô tả mức độ phân bố sáng tối trong vùng phổi.

Trong nghiên cứu, các đặc trưng First-order được trích xuất bao gồm các đại lượng thống kê cơ bản như giá trị trung bình (Mean), phương sai (Variance), độ lệch (Skewness), độ nhọn (Kurtosis), năng lượng (Energy), entropy (Entropy), giá trị nhỏ nhất (Minimum) và giá trị lớn nhất (Maximum).

Đặc trưng GLCM

Ma trận đồng xuất hiện mức xám (GLCM) mô tả mối quan hệ giữa các cặp điểm ảnh có mức xám khác nhau theo một khoảng cách và hướng xác định. Từ ma trận này, các đặc trưng được tính toán nhằm phản ánh mức độ tương quan và cấu trúc không gian của vùng ảnh.

Các đặc trưng GLCM được sử dụng trong nghiên cứu bao gồm Contrast, Correlation, Homogeneity và Energy. Những đặc trưng này thể hiện mức độ biến thiên cường độ cũng như sự đồng nhất trong cấu trúc của vùng phổi.

Đặc trưng GLSZM

Ma trận vùng mức xám (GLSZM) mô tả sự phân bố của các vùng liên thông có cùng mức xám trong ảnh. Nhóm đặc trưng này phản ánh mức độ đồng nhất hoặc không đồng nhất của cấu trúc mô trong vùng quan sát.

Các đặc trưng GLSZM cung cấp thông tin về kích thước và sự phân bố của các vùng có cùng mức xám, từ đó hỗ trợ mô tả đặc điểm cấu trúc của vùng phổi trong ảnh X-quang.

Chuẩn hóa dữ liệu đặc trưng Radiomics

Sau khi trích xuất, tập đặc trưng Radiomics thu được bao gồm nhiều nhóm đặc trưng khác nhau như First-order, GLCM và GLSZM. Các đặc trưng này có bản chất và thang đo khác nhau, dẫn đến sự chênh lệch đáng kể về phạm vi giá trị giữa các chiều đặc trưng.

Cụ thể, một số đặc trưng phản ánh cường độ trung bình hoặc năng lượng của ảnh có thể mang giá trị lớn, trong khi các đặc trưng mô tả mức độ phân bố hoặc cấu trúc không gian như entropy, correlation hoặc các đặc trưng từ GLSZM có thể nằm trong khoảng giá trị nhỏ hơn hoặc biến thiên mạnh. Sự không đồng nhất này có thể ảnh hưởng đến quá trình học của các mô hình phân loại, đặc biệt đối với các thuật toán nhạy cảm với thang đo dữ liệu.

Do đó, để đảm bảo các đặc trưng có cùng mức độ đóng góp trong quá trình huấn

luyện, bước chuẩn hóa dữ liệu được áp dụng trước khi đưa vào mô hình học máy. Trong nghiên cứu này, phương pháp *StandardScaler* được sử dụng nhằm chuẩn hóa dữ liệu về phân phối có trung bình bằng 0 và độ lệch chuẩn bằng 1.

Quá trình chuẩn hóa được thực hiện theo công thức:

$$z = \frac{x - \mu}{\sigma} \quad (2.27)$$

Trong đó:

- x là giá trị của đặc trưng ban đầu;
- μ là giá trị trung bình của đặc trưng trên tập huấn luyện;
- σ là độ lệch chuẩn của đặc trưng trên tập huấn luyện;
- z là giá trị sau khi chuẩn hóa.

Trong quá trình thực nghiệm, các tham số μ và σ chỉ được tính toán trên tập huấn luyện Radiomics. Sau đó, cùng một phép biến đổi được áp dụng cho cả tập huấn luyện và tập kiểm tra nhằm đảm bảo tính nhất quán và tránh rò rỉ dữ liệu.

Sau khi chuẩn hóa, các đặc trưng Radiomics được đưa về cùng một thang đo, giúp mô hình học máy khai thác hiệu quả hơn thông tin từ từng nhóm đặc trưng và cải thiện tính ổn định trong quá trình huấn luyện.

Ưu điểm và hạn chế của phương pháp Radiomics

Phương pháp Radiomics cho phép chuyển đổi ảnh X-quang thành các đặc trưng định lượng, giúp khai thác thông tin về cường độ, kết cấu và cấu trúc của vùng phổi. Các đặc trưng thu được có tính giải thích rõ ràng, do mỗi nhóm đặc trưng đều mang ý nghĩa thống kê cụ thể. Khi kết hợp với các mô hình học máy như Random Forest, SVM hoặc KNN, phương pháp này có thể đạt hiệu quả phân loại ổn định, đặc biệt trong các bài toán với tập dữ liệu không quá lớn.

Phương pháp Radiomics phụ thuộc nhiều vào chất lượng phân đoạn vùng quan tâm (ROI), do sai lệch trong bước này có thể ảnh hưởng đến kết quả đặc trưng. Ngoài ra, số lượng đặc trưng lớn có thể gây dư thừa hoặc tương quan cao giữa các đặc trưng, làm tăng độ phức tạp của mô hình nếu không có bước xử lý phù hợp. Bên cạnh đó, phương pháp cũng phụ thuộc vào cấu hình trích xuất và chưa tự động học được đặc trưng như các phương pháp học sâu hiện đại.

2.2 Các mô hình trích xuất đặc trưng dựa trên Transformer

2.2.1 Tổng quan về Transformer

Giới thiệu về Transformer

Sự ra đời của kiến trúc Transformer đã đánh dấu một bước tiến quan trọng trong lĩnh vực trí tuệ nhân tạo và xử lý dữ liệu. Năm 2017, bài báo *Attention Is All You Need* của Vaswani và các cộng sự đã giới thiệu mô hình Transformer dựa hoàn toàn trên cơ chế attention, không còn phụ thuộc vào các mạng nơ-ron hồi tiếp (RNN, LSTM) hay mạng tích chập (CNN). Ban đầu, Transformer được phát triển cho các bài toán xử lý ngôn ngữ tự nhiên, tuy nhiên nhờ khả năng học mối quan hệ toàn cục hiệu quả, kiến trúc này nhanh chóng được mở rộng sang nhiều lĩnh vực khác, đặc biệt là xử lý ảnh.

Trong xử lý ảnh, Convolutional Neural Network (CNN) là mô hình được sử dụng phổ biến nhờ khả năng học đặc trưng hiệu quả thông qua các phép tích chập cục bộ. Tuy nhiên, CNN vẫn gặp hạn chế trong việc khai thác mối quan hệ dài hạn giữa các vùng ảnh do phạm vi tiếp nhận (receptive field) bị giới hạn. Để khắc phục hạn chế này, kiến trúc Transformer đã được ứng dụng vào lĩnh vực thị giác máy tính thông qua cơ chế self-attention. Khác với CNN chỉ tập trung vào đặc trưng cục bộ, self-attention cho phép mô hình học mối quan hệ giữa mọi vị trí trong ảnh, từ đó khai thác hiệu quả cả thông tin cục bộ và toàn cục.

Nhờ khả năng học đặc trưng toàn cục và xử lý song song hiệu quả, Transformer đã trở thành nền tảng cho nhiều mô hình thị giác máy tính hiện đại, đặc biệt trong các bài toán phân loại ảnh và xử lý ảnh y khoa.

Cơ chế Attention trong Transformer

Cơ chế Attention được xem là thành phần cốt lõi và quan trọng nhất trong kiến trúc Transformer. Khác với các mô hình tuần tự truyền thống như Recurrent Neural Network (RNN) hay Long Short-Term Memory (LSTM), Transformer không xử lý dữ liệu theo từng bước thời gian tuần tự mà khai thác cơ chế attention để học trực tiếp mối quan hệ giữa các token trong toàn bộ chuỗi đầu vào. Nhờ đó, Transformer có khả năng xử lý song song hiệu quả và học được ngữ cảnh dài hạn tốt hơn.

Trong Transformer, cơ chế được sử dụng chủ yếu là Self-Attention. Cơ chế này cho phép mỗi token trong câu có thể chú ý đến tất cả các token còn lại nhằm thu thập thông tin ngữ cảnh liên quan. Thay vì chỉ phụ thuộc vào các token lân cận như trong các mô hình tuần tự, self-attention giúp mô hình xây dựng biểu diễn ngữ nghĩa toàn


cục cho từng token trong câu. Khác với attention truyền thống, vốn được tính toán dựa trên trạng thái của decoder ở time-step hiện tại và các trạng thái ẩn của encoder, self-attention hoạt động trực tiếp bên trong cùng một chuỗi dữ liệu. Điều này giúp Transformer hiểu rõ hơn mối quan hệ ngữ nghĩa và sự phụ thuộc giữa các từ, kể cả khi chúng nằm cách xa nhau trong câu.

Trong Transformer, self-attention được hiện thực thông qua cơ chế scaled dot-product attention. Đối với mỗi token đầu vào, mô hình xây dựng ba vector đặc trưng gồm:

- Query (Q): biểu diễn thông tin mà token đang tìm kiếm;
- Key (K): biểu diễn thông tin mà token có thể cung cấp;
- Value (V): biểu diễn nội dung thông tin thực sự được truyền đi.

Các vector này được tạo ra thông qua các phép biến đổi tuyến tính từ embedding đầu vào. Sau đó, độ tương đồng giữa Query và các Key được tính toán nhằm xác định mức độ liên quan giữa các token. Giá trị attention score càng lớn thì token hiện tại càng chú ý nhiều hơn đến token tương ứng.

Scaled Dot-Product Attention



Hình 2.5: Scaled Dot-Product Attention

Công thức tính attention được mô tả như sau:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

Trong đó:

- Q là ma trận Query;
- K là ma trận Key;
- V là ma trận Value;
- d_k là số chiều của vector Key.

Tích vô hướng QK^T được sử dụng để đo độ tương đồng giữa Query và Key. Sau đó, kết quả được chia cho $\sqrt{d_k}$ nhằm tránh giá trị quá lớn khi số chiều tăng cao, giúp quá trình huấn luyện ổn định hơn. Hàm softmax được áp dụng để chuẩn hóa các attention score thành phân phối xác suất, từ đó xác định mức độ quan trọng của từng token đối với token hiện tại. Cuối cùng, các trọng số attention này được sử dụng để kết hợp các vector Value nhằm tạo ra biểu diễn mới cho token đầu vào.

Một ưu điểm quan trọng của self-attention là khả năng mô hình hóa quan hệ phụ thuộc dài hạn giữa các token mà không gặp hiện tượng suy giảm thông tin như trong RNN hoặc LSTM. Đồng thời, vì toàn bộ chuỗi có thể được xử lý song song nên Transformer có tốc độ huấn luyện nhanh hơn đáng kể.

Trong decoder của Transformer, cơ chế masked self-attention được sử dụng để đảm bảo tính nhân quả khi sinh chuỗi đầu ra. Cụ thể, token tại vị trí hiện tại chỉ được phép chú ý đến các token ở những vị trí trước đó và không được sử dụng thông tin từ các token ở tương lai. Điều này giúp tránh hiện tượng nhìn trước trong quá trình dự đoán và đảm bảo tính đúng đắn của bài toán sinh chuỗi.


Để tăng khả năng biểu diễn ngữ nghĩa, Transformer sử dụng cơ chế multi-head attention. Thay vì chỉ thực hiện một phép attention duy nhất, mô hình thực hiện nhiều attention head song song. Mỗi head sẽ học một không gian biểu diễn con khác nhau, từ đó cho phép mô hình khai thác đồng thời nhiều loại quan hệ ngữ nghĩa và cú pháp giữa các token.

Về mặt tổng quát, cơ chế multi-head attention được biểu diễn như sau:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O, \quad \text{head}_i = \text{Attention}(Q_i, K_i, V_i)$$

Trong đó:

- h là số lượng attention head;
- head_i là attention head thứ i ;
- W^O là ma trận biến đổi tuyến tính đầu ra.



Hình 2.6: Multi-Head Attention

Mỗi attention head thực hiện phép attention trên các phiên bản chiếu tuyến tính khác nhau của Query, Key và Value. Các đầu ra từ nhiều attention head sau đó được ghép nối (concatenate) và tiếp tục đi qua một phép biến đổi tuyến tính để tạo ra biểu diễn cuối cùng có cùng kích thước với đầu vào.


Nhờ cơ chế multi-head attention, Transformer có khả năng học được nhiều loại thông tin ngữ nghĩa khác nhau cùng lúc, chẳng hạn như: mối quan hệ cú pháp giữa các từ, sự phụ thuộc ngữ nghĩa dài hạn, hoặc thông tin vị trí và ngữ cảnh toàn cục.

Bên cạnh đó, do Transformer không sử dụng cấu trúc tuần tự như RNN mà xử lý toàn bộ câu cùng lúc do đó mô hình cần bổ sung thông tin vị trí của các token thông qua cơ chế Positional Encoding. Thành phần này giúp mô hình nhận biết được thứ tự xuất hiện của các token trong chuỗi đầu vào, từ đó duy trì được ý nghĩa ngữ pháp và ngữ cảnh của câu.

Nhìn chung, cơ chế attention nói chung và self-attention nói riêng đóng vai trò trung tâm trong Transformer. Nhờ khả năng học quan hệ phụ thuộc toàn cục, xử lý song song hiệu quả và biểu diễn ngữ nghĩa mạnh mẽ, Transformer đã trở thành nền tảng cho nhiều mô hình hiện đại trong lĩnh vực xử lý ngôn ngữ tự nhiên và thị giác máy tính như BERT, GPT, Vision Transformer (ViT) và nhiều kiến trúc học sâu tiên tiến khác.

Kiến trúc tổng thể của Transformer

Kiến trúc Transformer bao gồm hai thành phần chính là encoder và decoder như minh họa trong Hình 2.7.



Hình 2.7: Kiến trúc tổng thể của mô hình Transformer

Encoder được xây dựng từ nhiều lớp giống nhau, mỗi lớp bao gồm hai thành phần chính là multi-head self-attention và feed-forward network. Cơ chế self-attention cho phép mô hình học mối quan hệ giữa các phần tử trong dữ liệu đầu vào, trong khi mạng feed-forward giúp tăng khả năng biểu diễn phi tuyến của mô hình. Ngoài ra, mỗi khối đều được kết hợp với residual connection và layer normalization nhằm ổn định quá trình huấn luyện.

Decoder có cấu trúc tương tự encoder nhưng được bổ sung thêm encoder-decoder attention nhằm kết hợp thông tin từ đầu ra của encoder trong quá trình sinh đầu ra. Đồng thời, cơ chế masking được áp dụng trong decoder để ngăn mô hình truy cập vào thông tin của các vị trí tương lai.

Do Transformer không sử dụng cấu trúc tuần tự như RNN hay LSTM, positional encoding được thêm vào embedding nhằm cung cấp thông tin về vị trí của các phần tử trong chuỗi dữ liệu.

Nhờ khả năng học quan hệ toàn cục thông qua cơ chế attention và xử lý song song

hiệu quả, Transformer đã trở thành nền tảng cho nhiều mô hình hiện đại trong xử lý ngôn ngữ tự nhiên và thị giác máy tính.

2.2.2 Mô hình Vision Transformer (ViT)

Giới thiệu Vision Transformer

Vision Transformer (ViT) là một kiến trúc học sâu được đề xuất bởi Dosovitskiy và cộng sự nhằm áp dụng mô hình Transformer vào lĩnh vực thị giác máy tính [6]. Khác với các mô hình Convolutional Neural Network (CNN) truyền thống sử dụng phép tích chập để trích xuất đặc trưng ảnh, ViT sử dụng cơ chế self-attention để học mối quan hệ giữa các vùng khác nhau trong ảnh. Nhờ đó, mô hình có khả năng khai thác thông tin toàn cục hiệu quả hơn và mô hình hóa được các phụ thuộc xa giữa các đặc trưng ảnh.

Theo Han và cộng sự[7], Transformer có khả năng nắm bắt các đặc trưng phụ thuộc xa tốt hơn CNN, nhờ đó cải thiện khả năng biểu diễn ngữ cảnh toàn cục của ảnh. Bên cạnh đó, cơ chế tính toán song song của Transformer cũng giúp quá trình huấn luyện đạt hiệu quả cao hơn so với kiến trúc tuần tự như RNN.

Một ưu điểm quan trọng của ViT là khả năng mở rộng mô hình theo quy mô dữ liệu và số lượng tham số. Dựa trên kích thước mô hình, ViT thường được chia thành nhiều phiên bản khác nhau như:

- ViT-Base (ViT-B);
- ViT-Large (ViT-L);
- ViT-Huge (ViT-H).

Các phiên bản này chủ yếu khác nhau ở:

- số lượng lớp Transformer Encoder;
- kích thước embedding;
- số lượng attention heads;
- tổng số tham số của mô hình.

Cụ thể:

- ViT-Base thường gồm 12 encoder layers với embedding dimension 768;
- ViT-Large gồm 24 encoder layers với embedding dimension 1024;

- ViT-Huge gồm 32 encoder layers với embedding dimension 1280.

Khi kích thước mô hình tăng lên, khả năng học biểu diễn đặc trưng của ViT cũng được cải thiện đáng kể. Tuy nhiên, điều này đồng thời làm tăng chi phí tính toán, bộ nhớ GPU và thời gian huấn luyện. Theo Dosovitskiy và cộng sự, các mô hình ViT lớn thường đạt hiệu suất cao hơn khi được huấn luyện trên các tập dữ liệu quy mô rất lớn như JFT-300M [6].

Nguyên lý hoạt động của Vision Transformer

Ý tưởng cốt lõi của Vision Transformer là xem ảnh như một chuỗi các token tương tự như chuỗi từ trong bài toán xử lý ngôn ngữ tự nhiên. Thay vì đưa trực tiếp toàn bộ ảnh vào mạng, ảnh đầu vào sẽ được chia thành nhiều patch có kích thước cố định, ví dụ 16×16 pixels. Giả sử ảnh đầu vào có kích thước $H \times W \times C$, trong đó H và W lần lượt là chiều cao và chiều rộng của ảnh, còn C là số kênh màu. Sau khi chia patch, số lượng patch được xác định bởi:

$$N = \frac{H \times W}{P^2} \quad (2.28)$$

Trong đó:


- N là số lượng patch;
- P là kích thước của mỗi patch;
- H, W là kích thước ảnh đầu vào.

Mỗi patch sau đó được làm phẳng (flatten) thành vector một chiều và ánh xạ sang không gian đặc trưng thông qua lớp tuyến tính (linear projection), tạo thành các patch embeddings:

$$z_0^i = x_p^i E \quad (2.29)$$

Trong đó:

- x_p^i là patch thứ i sau khi flatten;
- E là ma trận embedding;
- z_0^i là vector biểu diễn của patch.



Hình 2.8: Kiến trúc tổng quát của Vision Transformer (ViT)

Hình 2.8 mô tả quy trình xử lý của Vision Transformer. Ảnh đầu vào được chia thành các patch có kích thước cố định, sau đó được chuyển thành patch embeddings và bổ sung positional embeddings trước khi đưa vào Transformer Encoder. Cuối cùng, vector class token được sử dụng để thực hiện tác vụ phân loại thông qua MLP Head.

Để giữ lại thông tin vị trí không gian của các patch trong ảnh, ViT bổ sung positional embedding vào patch embeddings:

$$z_0 = [x_{class}; x_p^1 E; x_p^2 E; \dots; x_p^N E] + E_{pos} \quad (2.30)$$

Trong đó:

- x_{class} là class token dùng cho bài toán phân loại;
- E_{pos} là vector positional embedding.

Sau khi tạo embedding, chuỗi patch embeddings được đưa vào Transformer Encoder. Mỗi encoder bao gồm hai thành phần chính:

- Multi-Head Self-Attention (MHSA);
- Feed Forward Network (FFN).

Trong đó, cơ chế self-attention đóng vai trò quan trọng nhất vì cho phép mô hình học mối quan hệ giữa tất cả các patch trong ảnh. Cơ chế này giúp mô hình xác định mức độ liên quan giữa các patch ảnh khác nhau, từ đó học được cả thông tin cục bộ và thông tin toàn cục của ảnh. Khác với CNN chỉ quan sát vùng lân cận nhỏ thông

qua kernel tích chập, ViT có thể trực tiếp mô hình hóa mối quan hệ xa giữa các vùng ảnh ngay từ những lớp đầu tiên.

Sau nhiều lớp Transformer Encoder, vector class token sẽ chứa thông tin biểu diễn toàn bộ ảnh và được sử dụng cho tác vụ phân loại thông qua lớp Multi-Layer Perceptron (MLP).

Ưu điểm và hạn chế của Vision Transformer

Vision Transformer (ViT) có khả năng khai thác hiệu quả mối quan hệ giữa các vùng khác nhau trong ảnh thông qua cơ chế self-attention, từ đó giúp mô hình học tốt thông tin ngữ cảnh toàn cục. Ngoài ra, kiến trúc Transformer hỗ trợ tính toán song song hiệu quả trên GPU và có khả năng mở rộng tốt khi được huấn luyện trên các tập dữ liệu lớn.

Tuy nhiên, Vision Transformer vẫn tồn tại một số hạn chế. Do không tận dụng được các đặc tính vốn có của mạng CNN như khả năng học đặc trưng cục bộ và tính bất biến đối với sự dịch chuyển của ảnh, ViT thường cần lượng dữ liệu huấn luyện lớn để đạt hiệu quả cao. Ngoài ra, cơ chế self-attention trên toàn bộ ảnh làm chi phí tính toán và bộ nhớ tăng nhanh khi kích thước hoặc độ phân giải ảnh tăng lên.

2.2.3 Mô hình Swin Transformer-T

Giới thiệu Swin Transformer

Swin Transformer là một biến thể của Vision Transformer được đề xuất bởi Liu và cộng sự nhằm cải tiến khả năng xử lý ảnh và tối ưu chi phí tính toán của kiến trúc Transformer trong thị giác máy tính [11]. Mô hình kế thừa nền tảng self-attention của Vision Transformer, đồng thời bổ sung thêm cơ chế attention cục bộ và kiến trúc phân cấp nhằm tăng tính linh hoạt trong quá trình trích xuất đặc trưng ảnh.

Khác với Vision Transformer sử dụng global self-attention trên toàn bộ patch của ảnh, Swin Transformer áp dụng cơ chế self-attention cục bộ theo từng cửa sổ (window-based self-attention). Cơ chế này giúp giảm lượng tính toán khi xử lý ảnh có độ phân giải lớn trong khi vẫn duy trì khả năng học mối quan hệ giữa các vùng ảnh.

Mặc dù Vision Transformer đạt hiệu suất rất cao trong bài toán phân loại ảnh, mô hình này vẫn tồn tại một số hạn chế nhất định. Do sử dụng global self-attention, độ phức tạp tính toán của ViT tăng theo bình phương số lượng patch đầu vào, dẫn đến chi phí xử lý lớn đối với ảnh có độ phân giải cao. Bên cạnh đó, ViT thiếu một số đặc tính vốn có của CNN như khả năng học đặc trưng cục bộ và xây dựng đặc trưng theo nhiều mức độ khác nhau, khiến mô hình thường yêu cầu lượng dữ liệu huấn luyện lớn để đạt khả năng tổng quát hóa tốt.

Để cải thiện các vấn đề trên, Swin Transformer được thiết kế với kiến trúc phân cấp (hierarchical architecture) tương tự CNN. Thay vì giữ nguyên kích thước feature map trong toàn bộ mạng như ViT, Swin Transformer giảm dần kích thước không gian của đặc trưng thông qua các lớp Patch Merging. Đồng thời, số chiều đặc trưng được tăng lên theo từng stage nhằm giúp mô hình học được biểu diễn đặc trưng ở nhiều mức độ khác nhau.

Một trong những cải tiến quan trọng của Swin Transformer là cơ chế Shifted Window Multi-Head Self-Attention (SW-MSA). Trong Vision Transformer, mỗi patch có thể attention tới toàn bộ patch khác trong ảnh, dẫn đến chi phí tính toán lớn khi số lượng patch tăng lên. Trong khi đó, Swin Transformer chỉ tính attention bên trong các cửa sổ cục bộ có kích thước cố định. Ở lớp kế tiếp, vị trí các cửa sổ sẽ được dịch chuyển nhằm tạo kết nối thông tin giữa các vùng lân cận. Nhờ đó, mô hình vẫn có thể trao đổi thông tin giữa các vùng ảnh mà không cần sử dụng global attention trên toàn bộ ảnh.

Nhờ cơ chế shifted window, Swin Transformer bổ sung khả năng khai thác thông tin cục bộ tốt hơn so với cơ chế global attention truyền thống của Vision Transformer, đồng thời vẫn duy trì khả năng học mối quan hệ giữa các vùng ảnh. Điều này đặc biệt hữu ích trong các bài toán xử lý ảnh có nhiều chi tiết cục bộ như ảnh y khoa hoặc ảnh X-quang.

Ngoài ra, Swin Transformer còn hỗ trợ xây dựng biểu diễn đa tỉ lệ (multi-scale representation). Các feature maps ở các stage khác nhau chứa thông tin ở nhiều mức độ chi tiết khác nhau, tương tự như cách CNN xây dựng pyramid features. Cơ chế này giúp Swin Transformer hỗ trợ tốt hơn cho các bài toán cần biểu diễn đặc trưng ở nhiều mức độ khác nhau như phân đoạn ảnh, phát hiện đối tượng và phân tích ảnh y khoa.

Các phiên bản phổ biến của Swin Transformer bao gồm:

- Swin-Tiny (Swin-T);
- Swin-Small (Swin-S);
- Swin-Base (Swin-B);
- Swin-Large (Swin-L).

Các phiên bản này chủ yếu khác nhau ở:

- số lượng Swin Transformer blocks;
- số chiều embedding;
- số lượng attention heads;

- kích thước mô hình và tổng số tham số.

Trong đó:

- Swin-T là phiên bản nhẹ với chi phí tính toán thấp;
- Swin-S và Swin-B có số lượng tham số lớn hơn và khả năng biểu diễn đặc trưng mạnh hơn;
- Swin-L là phiên bản lớn với số lượng tham số rất cao, thường được huấn luyện trên các tập dữ liệu quy mô lớn.

Theo Liu và cộng sự [11], Swin Transformer đạt kết quả tốt trên nhiều benchmark thị giác máy tính như ImageNet, COCO và ADE20K, đồng thời duy trì chi phí tính toán hợp lý đối với ảnh có độ phân giải cao. Những cải tiến của Swin Transformer góp phần mở rộng khả năng ứng dụng của kiến trúc Transformer trong nhiều bài toán thị giác máy tính hiện đại.

Nguyên lý hoạt động của Swin Transformer

Tương tự Vision Transformer, Swin Transformer bắt đầu bằng việc chia ảnh đầu vào thành các patch có kích thước cố định. Giả sử ảnh đầu vào có kích thước $H \times W \times C$, ảnh sẽ được chia thành các patch không chồng lấp và chuyển thành các patch embeddings trước khi đưa vào Transformer blocks.

Tuy nhiên, khác với ViT sử dụng global self-attention trên toàn bộ patch, Swin Transformer chỉ thực hiện attention trong từng cửa sổ cục bộ có kích thước $M \times M$. Cơ chế này được gọi là Window-based Multi-Head Self-Attention (W-MSA).

Độ phức tạp tính toán của global self-attention trong Vision Transformer được xác định bởi:

$$\Omega(MSA) = 4hwC^2 + 2(hw)^2C \quad (2.31)$$

Trong khi đó, độ phức tạp của Window-based Self-Attention trong Swin Transformer là:

$$\Omega(W-MSA) = 4hwC^2 + 2M^2hwC \quad (2.32)$$

Trong đó:

- h, w là kích thước feature map;
- C là số chiều đặc trưng;

- M là kích thước của sổ attention.

Có thể thấy rằng độ phức tạp của Vision Transformer tăng theo bình phương số lượng patch, trong khi Swin Transformer chỉ tăng tuyến tính theo kích thước ảnh. Điều này giúp Swin Transformer giảm chi phí tính toán khi xử lý ảnh có độ phân giải cao.

Mỗi Swin Transformer block bao gồm hai thành phần attention chính:

- Window-based Multi-Head Self-Attention (W-MSA);
- Shifted Window Multi-Head Self-Attention (SW-MSA).

Trong W-MSA, attention chỉ được tính toán giữa các patch bên trong cùng một cửa sổ cục bộ. Tuy nhiên, nếu chỉ sử dụng W-MSA, thông tin giữa các cửa sổ khác nhau sẽ khó được trao đổi với nhau. Để giải quyết vấn đề này, Swin Transformer sử dụng SW-MSA bằng cách dịch chuyển vị trí cửa sổ ở lớp tiếp theo. Nhờ cơ chế shifted window, các patch thuộc các cửa sổ khác nhau ở lớp trước có thể tương tác với nhau ở lớp sau.

Ngoài attention mechanism, Swin Transformer còn sử dụng Patch Merging để giảm kích thước feature map giữa các stage của mạng. Quá trình này tương tự phép pooling trong CNN, giúp:

- giảm số lượng token;
- giảm chi phí tính toán;
- tăng receptive field;
- xây dựng biểu diễn đa tỉ lệ cho ảnh.

Kiến trúc tổng thể của Swin Transformer thường gồm nhiều stage liên tiếp. Ở mỗi stage:

- kích thước feature map giảm dần;
- số chiều đặc trưng tăng lên;
- receptive field của mô hình được mở rộng.

Nhờ cơ chế này, Swin Transformer có thể học được cả:

- các đặc trưng cục bộ nhỏ;
- cấu trúc trung bình;
- và các đặc trưng ngữ nghĩa toàn cục của ảnh.

Ưu điểm và hạn chế của Swin Transformer

Swin Transformer kế thừa khả năng học quan hệ toàn cục của Transformer, đồng thời bổ sung cơ chế attention cục bộ và kiến trúc phân cấp nhằm hỗ trợ biểu diễn đặc trưng đa tỉ lệ cho ảnh. Nhờ cơ chế shifted window, mô hình có thể trao đổi thông tin giữa các vùng ảnh lân cận trong khi vẫn giảm chi phí tính toán đối với ảnh có độ phân giải cao. Ngoài ra, Swin Transformer hỗ trợ tốt cho nhiều bài toán thị giác máy tính như phân loại ảnh, phát hiện đối tượng và phân đoạn ảnh.

Tuy nhiên, Swin Transformer vẫn có chi phí tính toán và yêu cầu phần cứng cao hơn so với nhiều mô hình CNN truyền thống. Bên cạnh đó, mặc dù attention cục bộ giúp giảm độ phức tạp tính toán, mô hình vẫn cần lượng dữ liệu huấn luyện tương đối lớn để phát huy hiệu quả. Kiến trúc của Swin Transformer cũng phức tạp hơn Vision Transformer do sử dụng nhiều stage, cơ chế shifted window và patch merging trong quá trình xử lý ảnh.

2.3 Các mô hình trích xuất đặc trưng dựa trên Mạng nơ-ron tích chập CNN

2.3.1 Tổng quan về Mạng nơ-ron tích chập CNN

Giới thiệu

Mạng nơ-ron tích chập (Convolutional Neural Network – CNN) là một kiến trúc học sâu được thiết kế đặc biệt để xử lý dữ liệu dạng lưới như hình ảnh hoặc chuỗi thời gian. CNN sử dụng các phép tích chập để tự động trích xuất đặc trưng từ dữ liệu đầu vào mà không cần thiết kế thủ công. Nhờ khả năng khai thác thông tin cục bộ thông qua các bộ lọc tích chập, CNN có thể phát hiện hiệu quả các đặc trưng như cạnh, kết cấu và hình dạng trong ảnh. Đồng thời, mô hình giúp giảm số lượng tham số cần huấn luyện và tăng khả năng tổng quát hóa so với mạng nơ-ron truyền thống. Với hiệu quả cao trong xử lý ảnh, CNN được ứng dụng rộng rãi trong các bài toán như phân loại ảnh, nhận dạng khuôn mặt và đặc biệt là hỗ trợ chẩn đoán bệnh trong ảnh y khoa.

Kiến trúc tổng thể của CNN


Kiến trúc của mạng nơ-ron tích chập (CNN) thường được chia thành hai thành phần chính gồm: bộ phận trích xuất đặc trưng (Feature Extraction) và bộ phận phân loại (Classification). CNN có khả năng tự động học và trích xuất các đặc trưng quan trọng từ dữ liệu đầu vào, đặc biệt hiệu quả trong các bài toán xử lý ảnh.

Convolutional Layer (Lớp tích chập)

Convolutional Layer là thành phần cốt lõi của CNN, thực hiện phép tích chập giữa dữ liệu đầu vào và các bộ lọc (filter/kernel) nhằm trích xuất đặc trưng của ảnh. Mỗi bộ lọc sẽ di chuyển trên toàn bộ ảnh để phát hiện các đặc trưng cục bộ như cạnh, góc, đường nét hoặc kết cấu. Kết quả của quá trình này là các bản đồ đặc trưng (feature maps), giúp mô hình nhận diện các thông tin quan trọng trong ảnh.

Một số thành phần quan trọng trong lớp tích chập bao gồm:


- Filter/Kernel: Ma trận kích thước nhỏ dùng để phát hiện và trích xuất đặc trưng từ ảnh đầu vào;
- Stride: Bước di chuyển của bộ lọc trên ảnh, ảnh hưởng đến kích thước của đặc trưng đầu ra;
- Padding: Phương pháp bổ sung các giá trị xung quanh ảnh nhằm bảo toàn kích thước dữ liệu và hạn chế mất thông tin ở vùng biên;
- ReLU (Rectified Linear Unit): Hàm kích hoạt phi tuyến được sử dụng nhằm tăng khả năng học các đặc trưng phức tạp và giảm hiện tượng mất gradient.



Hình 2.9: Minh họa lớp Convolutional Layer

Pooling Layer


Pooling Layer có chức năng giảm kích thước không gian của các bản đồ đặc trưng, từ đó làm giảm số lượng tham số và chi phí tính toán của mô hình. Đồng thời, lớp này cũng giúp hạn chế hiện tượng overfitting và tăng khả năng khái quát hóa dữ liệu. Hai phương pháp pooling phổ biến là Max Pooling và Average Pooling. Trong đó, Max Pooling thường được sử dụng nhiều hơn do khả năng giữ lại các đặc trưng nổi bật của ảnh.



Hình 2.10: Minh hoạ lớp Pooling Layer

Fully Connected Layer (FC Layer)

Sau quá trình trích xuất đặc trưng, dữ liệu đầu ra sẽ được chuyển đổi thành vector một chiều thông qua phép Flatten. Các lớp Fully Connected sẽ tiếp nhận vector này để thực hiện quá trình phân loại. Trong lớp này, các nơ-ron được kết nối đầy đủ với nhau nhằm học mối quan hệ giữa các đặc trưng đã trích xuất. Cuối cùng, hàm Softmax thường được sử dụng tại lớp đầu ra để tính toán xác suất và đưa ra kết quả phân loại cho từng lớp dữ liệu.



Hình 2.11: Minh hoạ lớp Fully Connected Layer


Quy trình hoạt động của CNN

Hình 2.12 minh hoạ quy trình hoạt động tổng thể của mạng nơ-ron tích chập (CNN). Đầu tiên, ảnh đầu vào được đưa qua các lớp tích chập (Convolutional Layer) để trích xuất các đặc trưng cơ bản như cạnh, đường nét, màu sắc hoặc kết cấu của đối tượng.

Các bộ lọc (filters/kernels) sẽ tự động học và phát hiện những đặc trưng quan trọng thông qua quá trình huấn luyện.

Sau mỗi lớp tích chập, lớp Pooling được sử dụng nhằm giảm kích thước không gian của bản đồ đặc trưng (feature map), từ đó giảm số lượng tham số và chi phí tính toán, đồng thời vẫn giữ lại các thông tin đặc trưng quan trọng nhất. Khi mạng càng sâu, các lớp tích chập tiếp theo sẽ học được các đặc trưng ở mức độ phức tạp hơn, chẳng hạn như hình dạng hoặc cấu trúc của đối tượng trong ảnh.

Tiếp theo, toàn bộ đặc trưng được chuyển đổi thành vector một chiều thông qua phép Flatten và đưa vào các lớp Fully Connected để thực hiện quá trình phân loại. Cuối cùng, hàm Softmax tại lớp đầu ra sẽ tính toán xác suất của từng lớp và đưa ra kết quả dự đoán cho ảnh đầu vào.




Hình 2.12: Minh họa quy trình hoạt động CNN

2.3.2 Mô hình VGG-16

Giới thiệu

Kiến trúc VGG-16 là một trong những mô hình mạng nơ-ron tích chập sâu (Deep Convolutional Neural Network) nổi bật trong lĩnh vực thị giác máy tính, được đề xuất bởi Karen Simonyan và Andrew Zisserman thuộc Đại học Oxford vào năm 2014. Mô hình này đạt hiệu suất rất cao tại cuộc thi ImageNet Large Scale Visual Recognition Challenge (ILSVRC) và nhanh chóng trở thành một kiến trúc nền tảng trong các bài toán phân loại hình ảnh.


VGG-16 gồm tổng cộng 16 lớp có trọng số, bao gồm 13 lớp tích chập (Convolutional Layer) và 3 lớp kết nối đầy đủ (Fully Connected Layer). Kiến trúc của mô hình được xây dựng theo dạng tuần tự với nhiều khối tích chập được xếp chồng lên nhau. Trong mỗi khối, các lớp convolution sử dụng bộ lọc kích thước nhỏ 3×3 kết hợp với hàm kích hoạt ReLU nhằm tăng khả năng học đặc trưng phi tuyến của mô hình. Sau mỗi khối tích chập là một lớp Max Pooling có nhiệm vụ giảm kích thước dữ liệu đặc trưng và giảm chi phí tính toán.



Hình 2.13: Kiến trúc mô hình VGG-16

Khi dữ liệu đi sâu hơn vào mạng, các lớp convolution sẽ học được các đặc trưng ngày càng phức tạp, từ các cạnh và đường nét cơ bản đến các cấu trúc và hình dạng của đối tượng trong ảnh. Sau giai đoạn trích xuất đặc trưng, dữ liệu sẽ được chuyển thành vector một chiều thông qua lớp Flatten và đưa vào các lớp Fully Connected để thực hiện phân loại. Cuối cùng, hàm Softmax được sử dụng tại lớp đầu ra để dự đoán xác suất của từng lớp đối tượng.

Quy trình hoạt động



Hình 2.14: Quy trình hoạt động mô hình VGG-16

Luồng xử lý mô hình VGG-16 bắt đầu từ việc tiếp nhận ảnh đầu vào với kích thước cố định, sau đó ảnh sẽ lần lượt đi qua 5 khối tích chập (Convolution Block) liên tiếp để thực hiện quá trình trích xuất đặc trưng. Mỗi block bao gồm nhiều lớp Convolution sử dụng bộ lọc kích thước 3×3 , kết hợp với hàm kích hoạt ReLU nhằm tăng khả năng học các đặc trưng phi tuyến. Sau mỗi block, lớp Max Pooling 2×2 với stride bằng 2 được sử dụng để giảm kích thước không gian của dữ liệu nhưng vẫn giữ lại các đặc trưng quan trọng nhất.

Trong Block 1, ảnh đầu vào được đưa qua hai lớp Convolution và một lớp Max Pooling, tạo ra tensor đặc trưng có kích thước $(H/2, W/2, 64)$. Ở giai đoạn này, mô hình chủ yếu học các đặc trưng cơ bản như cạnh, đường nét hoặc kết cấu đơn giản của

ảnh.

Tiếp theo, Block 2 tiếp tục sử dụng hai lớp Convolution và một lớp Max Pooling để tạo ra tensor kích thước $(H/4, W/4, 128)$. Khi đi sâu hơn vào mạng, số lượng kênh đặc trưng tăng lên giúp mô hình học được các đặc trưng phức tạp hơn của đối tượng.

Trong Block 3, dữ liệu được đưa qua ba lớp Convolution kết hợp với Max Pooling, tạo ra tensor kích thước $(H/8, W/8, 256)$. Tại đây, mô hình bắt đầu trích xuất các đặc trưng ở mức cao hơn như hình dạng hoặc cấu trúc của đối tượng trong ảnh.

Block 4 tiếp tục thực hiện ba lớp Convolution và một lớp Max Pooling, giúp tensor giảm xuống còn $(H/16, W/16, 512)$. Các đặc trưng thu được ở giai đoạn này mang tính cô đọng cao hơn và hỗ trợ mô hình nhận diện rõ hơn các vùng quan trọng hoặc bất thường trong ảnh.

Cuối cùng, Block 5 tạo ra tensor đầu ra kích thước $(H/32, W/32, 512)$. Đây là tầng chứa các đặc trưng trừu tượng và quan trọng nhất của ảnh đầu vào, đóng vai trò như biểu diễn đặc trưng tổng quát của dữ liệu.

Sau giai đoạn trích xuất đặc trưng, tensor đầu ra sẽ được chuyển đổi thành vector một chiều thông qua lớp Flatten. Vector này tiếp tục được đưa qua các lớp Fully Connected kết hợp với hàm kích hoạt ReLU để tổng hợp thông tin và thực hiện phân loại. Cuối cùng, hàm Softmax tại lớp đầu ra sẽ tính toán xác suất cho từng lớp và đưa ra kết quả dự đoán cuối cùng.

Nhờ khả năng học đặc trưng hiệu quả và cấu trúc sâu ổn định, VGG16 đã được chứng minh là một mô hình phù hợp cho nhiều bài toán phân loại ảnh, đặc biệt trong lĩnh vực y tế như phân tích và chẩn đoán hình ảnh X-quang phổi.


2.3.3 Mô hình DenseNet-169

Giới thiệu

DenseNet-169 là một biến thể tiêu biểu thuộc họ mạng DenseNet (Convolutional Network), được đề xuất bởi Gao Huang và cộng sự vào năm 2017. Kiến trúc này nổi bật nhờ cơ chế kết nối dày đặc (dense connectivity), trong đó mỗi lớp không chỉ nhận dữ liệu từ lớp liền kề trước đó mà còn tiếp nhận toàn bộ thông tin đặc trưng từ tất cả các lớp phía trước. Cách kết nối này giúp tăng cường khả năng lan truyền thông tin và gradient trong toàn mạng, từ đó làm giảm hiện tượng mất mát gradient, đồng thời nâng cao khả năng tái sử dụng đặc trưng đã học.

DenseNet-169 bao gồm 169 lớp, bao gồm các lớp convolution, batch normalization, ReLU và pooling. Các lớp này được tổ chức thành nhiều dense block và liên kết với nhau thông qua các transition layer. Trong mỗi dense block, đầu ra của các lớp trước sẽ được nối (concatenate) với đầu vào của lớp hiện tại theo chiều sâu của tensor đặc

trưng, thay vì thực hiện phép cộng trực tiếp như trong ResNet. Nhờ vậy, mạng có thể khai thác hiệu quả các đặc trưng ở nhiều mức độ khác nhau, đồng thời giảm số lượng tham số cần huấn luyện nhưng vẫn duy trì hiệu suất phân loại cao.



Hình 2.15: Minh họa Dense Block và Transition Layer trong DenseNet-169

Với cơ chế kết nối đặc biệt này, DenseNet-169 được đánh giá là một trong những kiến trúc mạng học sâu hiệu quả cho các bài toán thị giác máy tính, đặc biệt trong những tác vụ yêu cầu khả năng khai thác đặc trưng sâu, ổn định và tối ưu tài nguyên tính toán.

Trong kiến trúc ResNet, hàm ánh xạ được biểu diễn dưới dạng:

$$f(x) = x + g(x) \quad (2.33)$$

Trong đó, $g(x)$ biểu diễn phần ánh xạ dư (residual mapping). Công thức này có nét tương đồng với khai triển Taylor của hàm số tại $x = 0$:

$$f(x) = f(0) + f'(0)x + \frac{f''(0)}{2!}x^2 + \dots + \frac{f^{(n)}(0)}{n!}x^n + O(x^n) \quad (2.34)$$

Có thể nhận thấy rằng ResNet tương tự như việc xấp xỉ hàm số thông qua khai triển Taylor ở bậc nhất, trong đó thành phần $g(x)$ đóng vai trò như phần sai số còn lại. Khi phần dư này được biểu diễn bởi các ánh xạ phi tuyến sâu hơn, khả năng mô hình hóa dữ liệu của mạng sẽ trở nên mạnh mẽ và chính xác hơn.

DenseNet kế thừa ý tưởng đó nhưng mở rộng theo hướng tăng cường kết nối giữa các lớp. Thay vì cộng trực tiếp các đặc trưng như ResNet, DenseNet thực hiện kết nối dày đặc nhằm duy trì và tái sử dụng toàn bộ thông tin đã được trích xuất trước đó.


Từ đầu vào ban đầu x , mạng sẽ thực hiện liên tiếp các phép biến đổi với mức độ trừu tượng ngày càng cao:

$$x \rightarrow f_1(x) \rightarrow f_2(x, f_1(x)) \rightarrow \cdots \rightarrow f_4(x, f_3(x, f_2(x, f_1(x)))) \quad (2.35)$$

Điểm khác biệt cốt lõi của DenseNet nằm ở việc đầu ra của các lớp có cùng kích thước không gian sẽ được nối với nhau theo chiều sâu của tensor đặc trưng. Nhờ đó, mỗi lớp đều có thể trực tiếp truy cập thông tin từ toàn bộ các lớp trước, giúp tăng khả năng truyền đặc trưng và hạn chế sự mất mát thông tin trong quá trình lan truyền.

Sau mỗi dense block, mạng sử dụng transition layer để giảm kích thước dữ liệu trước khi chuyển sang khối tiếp theo. Transition layer thường bao gồm một lớp tích chập 1×1 nhằm giảm số lượng kênh đặc trưng, kết hợp với lớp average pooling để giảm kích thước chiều dài và chiều rộng của đặc trưng đầu ra. Cơ chế này giúp kiểm soát độ phức tạp của mô hình, giảm chi phí tính toán và hạn chế sự gia tăng quá mức số lượng đặc trưng trong mạng.

Quy trình hoạt động



Hình 2.16: Minh họa quy trình hoạt động DenseNet-169

Quy trình xử lý của DenseNet-169 bắt đầu từ ảnh đầu vào, dữ liệu sẽ đi qua lớp tích chập (convolution) đầu tiên với kernel kích thước lớn nhằm trích xuất các đặc trưng cơ bản như cạnh, góc và kết cấu. Sau đó, đặc trưng tiếp tục được đưa qua lớp max pooling để giảm kích thước không gian và giảm chi phí tính toán.

Tiếp theo, dữ liệu được truyền qua chuỗi các dense block. Trong mỗi dense block, đầu ra của một lớp sẽ được nối (concatenate) với tất cả đầu ra của các lớp trước đó

theo chiều sâu của tensor đặc trưng. Điều này có nghĩa là lớp thứ l sẽ nhận đầu vào bao gồm toàn bộ đặc trưng được tạo ra từ các lớp $0, 1, \dots, l - 1$. Nhờ đó, mỗi lớp có thể trực tiếp khai thác cả đặc trưng mức thấp và mức cao, giúp tăng khả năng học biểu diễn của mô hình.

Bên trong mỗi dense block, một lớp thường bao gồm chuỗi thao tác: hàm kích hoạt ReLU, Batch Normalization (BN), tích chập 1×1 và tích chập 3×3 . Trong đó, lớp tích chập 1×1 đóng vai trò giảm số lượng kênh đặc trưng trước khi thực hiện tích chập 3×3 , giúp giảm chi phí tính toán và số lượng tham số của mô hình.

Sau mỗi dense block, DenseNet-169 sử dụng một transition layer để giảm kích thước dữ liệu trước khi chuyển sang khối tiếp theo. Transition layer bao gồm Batch Normalization, lớp tích chập 1×1 và lớp average pooling. Lớp tích chập 1×1 giúp giảm số lượng feature maps, trong khi average pooling làm giảm kích thước chiều dài và chiều rộng của đặc trưng đầu ra. Cơ chế này giúp kiểm soát sự gia tăng số lượng đặc trưng và tối ưu bộ nhớ tính toán.

DenseNet-169 bao gồm bốn dense block chính, được kết nối với nhau thông qua ba transition layer. Số lượng lớp trong từng dense block lần lượt là 6, 12, 32 và 32 lớp. Trong suốt quá trình lan truyền, số lượng feature maps sẽ tăng dần nhờ cơ chế kết nối dày đặc, giúp mạng học được các biểu diễn đặc trưng phong phú và đa dạng hơn.

Ở giai đoạn cuối, đầu ra của dense block cuối cùng sẽ được đưa qua lớp global average pooling nhằm chuyển tensor đặc trưng thành vector đặc trưng có kích thước cố định. Vector này sau đó được truyền qua lớp fully connected kết hợp hàm Softmax để thực hiện phân loại ảnh.

Nhờ cơ chế kết nối đặc biệt và khả năng tái sử dụng đặc trưng hiệu quả, DenseNet-169 vừa đạt độ chính xác cao trong các bài toán thị giác máy tính vừa giảm đáng kể số lượng tham số so với nhiều kiến trúc mạng học sâu truyền thống.

2.4 Thực nghiệm và thảo luận

2.4.1 Thực nghiệm

Môi trường thực nghiệm

Quá trình cài đặt, huấn luyện và đánh giá các mô hình được thực hiện trên môi trường Notebook của nền tảng Kaggle, với sự hỗ trợ của GPU nhằm tăng tốc độ xử lý và tối ưu thời gian huấn luyện mô hình. Nền tảng này cung cấp sẵn nhiều thư viện và công cụ phục vụ cho các bài toán học máy và học sâu, giúp quá trình thực nghiệm được triển khai thuận lợi và ổn định.

Trong nghiên cứu này, các thư viện chính được sử dụng bao gồm OpenCV cho xử lý ảnh, NumPy cho tính toán ma trận và thao tác dữ liệu số, cùng với các thư viện hỗ trợ xây dựng mô hình học sâu và học máy như TensorFlow, Keras và Scikit-learn.

Toàn bộ quá trình thực nghiệm được triển khai trên môi trường Python nhằm đảm bảo tính linh hoạt, khả năng tái lập và thuận tiện trong việc đánh giá hiệu năng giữa các mô hình khác nhau.


Xây dựng mô hình

Mô hình WST

Mô hình WST nhận đầu vào là ảnh X-quang lồng ngực có kích thước 128×128 pixel. Trước khi đưa vào mô hình, ảnh được chuẩn hóa về cùng kích thước nhằm đảm bảo tính đồng nhất của dữ liệu và hỗ trợ quá trình trích xuất đặc trưng diễn ra hiệu quả hơn.

Trong nghiên cứu này, phép biến đổi Wavelet Scattering Transform được triển khai thông qua thư viện Kymatio kết hợp với PyTorch để tự động trích xuất đặc trưng từ ảnh đầu vào.

Trong quá trình xây dựng mô hình, các tham số scattering được thiết lập với số scale $J=2$ và số hướng wavelet $L=8$. Cấu hình này cho phép mô hình khai thác hiệu quả thông tin về kết cấu và hình dạng xuất hiện trong ảnh X-quang phổi. Sau khi thực hiện phép biến đổi scattering, mỗi ảnh được biểu diễn dưới dạng một vector đặc trưng có kích thước lớn, chứa nhiều thông tin mô tả đặc điểm của ảnh đầu vào.



Hình 2.17: Minh họa xây dựng mô hình WST

Để nâng cao hiệu quả xử lý dữ liệu, các vector đặc trưng sau khi trích xuất được chuẩn hóa bằng phương pháp StandardScaler. Quá trình này giúp đưa các đặc trưng về cùng miền giá trị, từ đó cải thiện khả năng hội tụ và hiệu suất của các mô hình phân loại ở giai đoạn tiếp theo.

Tuy nhiên, vector đặc trưng thu được từ WST có số chiều rất lớn, lên tới 82944 đặc trưng cho mỗi ảnh. Vì vậy, nghiên cứu sử dụng phương pháp Linear Discriminant Analysis(LDA) để giảm chiều dữ liệu đồng thời tăng khả năng phân biệt giữa các lớp. Việc áp dụng LDA không chỉ giúp tối ưu hóa khả năng tách biệt dữ liệu mà còn làm giảm đáng kể chi phí tính toán và thời gian huấn luyện mô hình.

Cuối cùng, các vector đặc trưng được trích xuất từ mô hình WST được sử dụng làm đầu vào cho các bộ phân loại học máy gồm K-Nearest Neighbors (KNN), Logistic Regression (LR) và Multi-Layer Perceptron (MLP) nhằm thực hiện bài toán phân loại bệnh từ ảnh X-quang phổi.

Mô hình Statistical


Mô hình Statistical sử dụng các đặc trưng thống kê thủ công (handcrafted features) để biểu diễn thông tin của ảnh X-quang lồng ngực. Trong nghiên cứu này, ảnh đầu vào được chuẩn hóa về kích thước 128×128 pixel nhằm đảm bảo tính đồng nhất trước khi tiến hành trích xuất đặc trưng.

Sau khi tiền xử lý, mỗi ảnh được chuyển thành vector một chiều bằng phép làm phẳng (flatten) để thuận tiện cho việc tính toán các đại lượng thống kê. Từ vector ảnh này, mô hình tiến hành trích xuất nhiều đặc trưng thống kê quan trọng nhằm mô tả phân bố cường độ sáng và cấu trúc của ảnh X-quang.

Các đặc trưng được sử dụng trong nghiên cứu bao gồm: Giá trị trung bình (Mean), Độ lệch chuẩn (Standard Deviation), Phương sai (Variance), Giá trị nhỏ nhất và lớn nhất (Min/Max), Trung vị (Median), Khoảng giá trị (Range), Độ lệch phân bố (Skewness), Độ nhọn phân bố (Kurtosis), Năng lượng ảnh (Energy), Giá trị RMS (Root Mean Square), Entropy của histogram

Sau quá trình trích xuất đặc trưng, mỗi ảnh được biểu diễn dưới dạng một vector đặc trưng thống kê có kích thước nhỏ gọn. Để nâng cao hiệu quả học của mô hình phân loại, các đặc trưng tiếp tục được chuẩn hóa bằng phương pháp StandardScaler. Quá trình chuẩn hóa giúp đưa các đặc trưng về cùng miền giá trị, hạn chế ảnh hưởng của sự chênh lệch thang đo giữa các đặc trưng và cải thiện khả năng hội tụ của mô hình học máy.

Cuối cùng, các vector đặc trưng được trích xuất từ mô hình Statistical được sử dụng làm đầu vào cho các bộ phân loại học máy gồm K-Nearest Neighbors (KNN), Logistic Regression (LR) và Multi-Layer Perceptron (MLP) nhằm thực hiện bài toán phân loại bệnh từ ảnh X-quang phổi.



Hình 2.18: Xây dựng mô hình Statistical


Mô hình Radiomics

Mô hình Radiomics được xây dựng nhằm khai thác các đặc trưng định lượng từ ảnh X-quang phổi để phục vụ bài toán phân loại viêm phổi. Khác với các phương pháp học sâu tự động học đặc trưng từ dữ liệu, Radiomics tập trung trích xuất các đặc trưng mô tả cường độ, kết cấu và cấu trúc hình học của vùng tổn thương trong ảnh y khoa.

Trong nghiên cứu này, ảnh X-quang lồng ngực được chuẩn hóa về kích thước 128×128 pixel và lưu dưới dạng mảng NumPy. Đồng thời, các ảnh phân đoạn (segmentation mask) tương ứng cũng được sử dụng để xác định vùng quan tâm (Region of Interest - ROI) trên phổi. Việc sử dụng mặt nạ giúp mô hình chỉ tập trung trích xuất đặc trưng tại vùng có ý nghĩa y khoa, hạn chế ảnh hưởng của các vùng nền không liên quan.

Quá trình trích xuất đặc trưng được thực hiện bằng thư viện PyRadiomics kết hợp với SimpleITK. Trong đó, ảnh và mặt nạ được chuyển sang định dạng của SimpleITK trước khi đưa vào bộ trích xuất đặc trưng Radiomics. Mô hình được cấu hình với tham số binWidth = 25 và sử dụng chuẩn hóa cường độ ảnh nhằm tăng tính ổn định của đặc trưng. Nghiên cứu tập trung khai thác ba nhóm đặc trưng chính gồm: Đặc trưng bậc một (First-order features), Đặc trưng ma trận đồng xuất hiện mức xám (GLCM - Gray Level Co-occurrence Matrix), Đặc trưng ma trận vùng mức xám (GLSZM - Gray Level Size Zone Matrix). Sau quá trình trích xuất, mỗi ảnh được biểu diễn bởi vector gồm 93 đặc trưng Radiomics.

Để đảm bảo chất lượng dữ liệu đầu vào, các ảnh hoặc mặt nạ không hợp lệ như ảnh không đúng định dạng hoặc mặt nạ rỗng sẽ được loại bỏ trong quá trình xử lý. Sau đó, toàn bộ đặc trưng Radiomics được chuẩn hóa bằng phương pháp StandardScaler



Hình 2.19: Minh họa xây dựng mô hình Radiomics

nhằm đưa các đặc trưng về cùng miền giá trị, giúp cải thiện hiệu quả học của mô hình phân loại.

Cuối cùng, các vector đặc trưng được trích xuất từ mô hình Radiomics được sử dụng làm đầu vào cho các bộ phân loại học máy gồm K-Nearest Neighbors (KNN), Logistic Regression (LR) và Multi-Layer Perceptron (MLP) nhằm thực hiện bài toán phân loại bệnh từ ảnh X-quang phổi.


Mô hình Vision Transformer (ViT)

Mô hình Vision Transformer (ViT) được xây dựng nhằm khai thác khả năng học đặc trưng toàn cục từ ảnh X-quang phổi thông qua cơ chế self-attention của Transformer.

Trong nghiên cứu này, dữ liệu đầu vào bao gồm ảnh X-quang phổi. Các ảnh ban đầu ở dạng ảnh xám được chuyển đổi sang ảnh RGB bằng cách nhân bản kênh xám thành ba kênh màu. Việc chuyển đổi này nhằm phù hợp với cấu trúc đầu vào của mô hình Vision Transformer được huấn luyện trước trên tập dữ liệu ImageNet.

Sau đó, toàn bộ ảnh được chuẩn hóa về kích thước 128×128 pixel bằng thư viện TensorFlow. Dữ liệu tiếp tục được chuyển sang kiểu float32 nhằm đảm bảo khả năng tương thích trong quá trình xử lý và suy luận đặc trưng.

Mô hình sử dụng kiến trúc Vision Transformer (ViT) của Hugging Face Transformers với phiên bản tiền huấn luyện google/vit-large-patch16-224-in21k. Đây là một mô hình Transformer lớn được huấn luyện trước trên tập dữ liệu ImageNet-21k, giúp mô hình có khả năng học được các đặc trưng hình ảnh tổng quát trước khi áp dụng cho bài toán phân tích ảnh X-quang.



Hình 2.20: Minh họa xây dựng mô hình ViT

Trong quá trình trích xuất đặc trưng, ảnh đầu vào được chia thành các patch kích thước nhỏ và đưa qua các khối Transformer encoder. Mỗi patch được biểu diễn dưới dạng vector embedding và được xử lý thông qua cơ chế self-attention nhằm học mối quan hệ giữa các vùng ảnh khác nhau.

Đặc trưng cuối cùng được sử dụng trong nghiên cứu là vector CLS token tại đầu ra của mô hình Transformer. Vector này đại diện cho thông tin tổng quát của toàn bộ ảnh và có kích thước 1024 chiều đối với mô hình ViT-Large.

Sau khi trích xuất đặc trưng, toàn bộ vector đặc trưng được chuẩn hóa bằng phương pháp StandardScaler. Quá trình chuẩn hóa giúp đưa các đặc trưng về cùng miền giá trị, giảm ảnh hưởng của sự khác biệt thang đo và cải thiện hiệu quả của các mô hình phân loại ở bước tiếp theo.

Cuối cùng, các vector đặc trưng được trích xuất từ mô hình ViT được sử dụng làm đầu vào cho các bộ phân loại học máy gồm K-Nearest Neighbors (KNN), Logistic Regression (LR) và Multi-Layer Perceptron (MLP) nhằm thực hiện bài toán phân loại bệnh từ ảnh X-quang phổi.

Mô hình Swin Transformer (Swin-T)

Mô hình Swin Transformer (Swin-T) được xây dựng nhằm khai thác khả năng học đặc trưng phân cấp từ ảnh X-quang phổi thông qua cơ chế self-attention theo cửa sổ trượt (Shifted Window).

Trong nghiên cứu này, dữ liệu đầu vào là ảnh X-quang phổi. Các ảnh ban đầu ở dạng ảnh xám được chuyển sang ảnh RGB bằng cách nhân bản kênh xám thành ba

kênh màu nhằm phù hợp với đầu vào của mô hình Swin Transformer được huấn luyện trước trên tập dữ liệu ImageNet.

Sau đó, toàn bộ ảnh được chuẩn hóa về kích thước 128×128 pixel và chuyển sang kiểu dữ liệu float32. Quá trình này giúp đảm bảo tính đồng nhất của dữ liệu đầu vào và tăng khả năng tương thích với mô hình Transformer.

Nghiên cứu sử dụng mô hình Swin Transformer Large của Hugging Face với phiên bản tiền huấn luyện microsoft/swin-large-patch4-window7-224. Đây là mô hình Transformer phân cấp được thiết kế chuyên biệt cho bài toán thị giác máy tính với khả năng trích xuất đặc trưng mạnh mẽ và hiệu quả.

Trong quá trình xử lý, ảnh đầu vào được chia thành các patch kích thước nhỏ 4×4 pixel. Các patch này tiếp tục được gom thành các cửa sổ (window) để thực hiện cơ chế self-attention cục bộ. Đặc biệt, Swin Transformer sử dụng cơ chế dịch chuyển cửa sổ (shifted window) giữa các lớp liên tiếp nhằm tăng cường khả năng trao đổi thông tin giữa các vùng ảnh khác nhau.

Sau khi ảnh được đưa qua các khối Swin Transformer encoder, mô hình sinh ra tensor đặc trưng ở tầng cuối cùng. Để thu được vector đặc trưng đại diện cho toàn bộ ảnh, nghiên cứu áp dụng phép Global Average Pooling trên chiều không gian của tensor đầu ra.



Hình 2.21: Minh họa xây dựng mô hình Swin-T

Vector đặc trưng cuối cùng thu được có kích thước 1536 chiều cho mỗi ảnh. Sau quá trình trích xuất đặc trưng, dữ liệu tiếp tục được chuẩn hóa bằng phương pháp StandardScaler. Việc chuẩn hóa giúp đưa các đặc trưng về cùng miền giá trị, giảm sự chênh lệch giữa các đặc trưng và cải thiện hiệu quả của các bộ phân loại học máy ở

giai đoạn tiếp theo.

Cuối cùng, các vector đặc trưng được trích xuất từ mô hình Swin Transformer được sử dụng làm đầu vào cho các bộ phân loại học máy gồm K-Nearest Neighbors (KNN), Logistic Regression (LR) và Multi-Layer Perceptron (MLP) nhằm thực hiện bài toán phân loại bệnh từ ảnh X-quang phổi. Việc kết hợp Swin Transformer với các mô hình phân loại truyền thống giúp tận dụng khả năng học đặc trưng mạnh mẽ của Transformer đồng thời nâng cao hiệu quả nhận diện và phân loại bệnh.

Mô hình VGG16

Mô hình VGG16 được xây dựng nhằm khai thác khả năng học đặc trưng sâu từ ảnh X-quang phổi thông qua mạng nơ-ron tích chập (Convolutional Neural Network - CNN). Trong nghiên cứu này, VGG16 được sử dụng như một bộ trích xuất đặc trưng (feature extractor) thay vì huấn luyện toàn bộ mạng từ đầu.

Dữ liệu đầu vào là ảnh X-quang phổi. Các ảnh ban đầu ở dạng ảnh xám được chuyển đổi sang ảnh RGB bằng cách nhân bản kênh xám thành ba kênh màu nhằm phù hợp với cấu trúc đầu vào của mô hình VGG16 được huấn luyện trước trên tập dữ liệu ImageNet.

Sau đó, toàn bộ ảnh được chuẩn hóa về kích thước 128×128 pixel trước khi đưa vào mô hình. Việc chuẩn hóa kích thước giúp đảm bảo tính đồng nhất của dữ liệu và hỗ trợ quá trình trích xuất đặc trưng diễn ra hiệu quả hơn.

Nghiên cứu sử dụng mô hình VGG16 với trọng số tiền huấn luyện ImageNet. Mô hình được thiết lập với tham số `include_top=False` nhằm loại bỏ các lớp fully connected ở cuối mạng và chỉ giữ lại phần trích xuất đặc trưng convolutional.

Trong quá trình xử lý, ảnh đầu vào được đưa qua các khối convolution và pooling của VGG16 để học các đặc trưng từ mức thấp đến mức cao như cạnh, kết cấu và cấu trúc vùng phổi. Đầu ra cuối cùng của mạng convolution được làm phẳng (flatten) để tạo thành vector đặc trưng cho mỗi ảnh.

Sau khi trích xuất đặc trưng, mỗi ảnh được biểu diễn bởi vector có kích thước 8192 chiều. Các vector đặc trưng tiếp tục được sử dụng làm đầu vào cho các bộ phân loại học máy nhằm thực hiện bài toán phân loại bệnh từ ảnh X-quang phổi. Trong nghiên cứu này, các mô hình phân loại được sử dụng gồm: K-Nearest Neighbors (KNN), Logistic Regression (LR), Multi-Layer Perceptron (MLP).

Việc kết hợp VGG16 với các mô hình phân loại truyền thống giúp tận dụng khả năng học đặc trưng mạnh mẽ của mạng CNN đồng thời nâng cao hiệu quả nhận diện và phân loại bệnh trên ảnh X-quang phổi. **Mô hình Densetnet169**

Mô hình DenseNet169 được xây dựng nhằm khai thác khả năng học đặc trưng sâu từ ảnh X-quang phổi thông qua kiến trúc mạng Dense Convolutional Network (DenseNet).

Picture/Xõây dòềềng VGG16.png

Hình 2.22: Minh hoạ xây dựng mô hình VGG16

Trong nghiên cứu này, dữ liệu đầu vào là ảnh X-quang phổi. Các ảnh ban đầu ở dạng ảnh xám được chuyển đổi sang ảnh RGB bằng cách nhân bản kênh xám thành ba kênh màu nhằm phù hợp với cấu trúc đầu vào của mô hình DenseNet169 đã được huấn luyện trước trên tập dữ liệu ImageNet.

Sau đó, toàn bộ ảnh được chuẩn hóa về kích thước 128×128 pixel trước khi đưa vào mô hình. Việc chuẩn hóa kích thước giúp đảm bảo tính đồng nhất của dữ liệu đầu vào và hỗ trợ quá trình trích xuất đặc trưng diễn ra hiệu quả hơn.

Nghiên cứu sử dụng mô hình DenseNet169 với trọng số tiền huấn luyện ImageNet. Mô hình được thiết lập với tham số `include_top=False` nhằm loại bỏ các lớp fully connected cuối cùng và chỉ giữ lại phần mạng convolution dùng cho quá trình trích xuất đặc trưng.

Picture/XÃy dõềng DenseNet169.png

Hình 2.23: Minh hoạ xây dựng mô hình DenseNet169

Trong quá trình xử lý, ảnh đầu vào được đưa qua các Dense Block và Transition Layer của DenseNet169 để học các đặc trưng từ mức thấp đến mức cao như cạnh, kết cấu và cấu trúc vùng phổi. Nhờ cơ chế kết nối dày đặc, mỗi lớp có thể tận dụng thông tin đặc trưng từ toàn bộ các lớp trước đó, giúp mô hình học được biểu diễn đặc trưng hiệu quả hơn.

Đầu ra cuối cùng của mạng convolution được làm phẳng (flatten) để tạo thành vector đặc trưng cho mỗi ảnh. Sau quá trình trích xuất, mỗi ảnh được biểu diễn bởi vector đặc trưng có kích thước 26624 chiều. Các vector đặc trưng tiếp tục được sử dụng làm đầu vào cho các bộ phân loại học máy nhằm thực hiện bài toán phân loại bệnh từ ảnh X-quang phổi. Trong nghiên cứu này, các mô hình phân loại được sử dụng gồm: K-Nearest Neighbors (KNN), Logistic Regression (LR), Multi-Layer Perceptron (MLP)

Việc kết hợp DenseNet169 với các mô hình phân loại truyền thống giúp tận dụng khả năng học đặc trưng mạnh mẽ của mạng CNN đồng thời nâng cao hiệu quả nhận diện và phân loại bệnh trên ảnh X-quang phổi.

2.4.2 Thảo luận

2.5 Tiểu kết chương 2

CHƯƠNG 3

PHƯƠNG PHÁP KẾT HỢP ĐẶC TRƯNG

3.1 Phương pháp Feature Concatenation

Giới thiệu về Feature Concatenation

Feature Concatenation là phương pháp kết hợp nhiều vector đặc trưng thành một vector đặc trưng thống nhất nhằm tăng khả năng biểu diễn dữ liệu đầu vào. Phương pháp này được thực hiện bằng cách nối các vector đặc trưng theo chiều đặc trưng (*feature dimension*) để tạo thành vector mới chứa thông tin từ nhiều nguồn đặc trưng khác nhau.

Trong bài toán phân tích ảnh y tế, mỗi phương pháp trích xuất đặc trưng thường chỉ mô tả một khía cạnh nhất định của dữ liệu ảnh. Vì vậy, việc kết hợp nhiều nhóm đặc trưng có thể giúp bổ sung thông tin giữa các phương pháp và hỗ trợ mô hình học máy khai thác dữ liệu hiệu quả hơn.

Trong nghiên cứu này, phương pháp Feature Concatenation được sử dụng để kết hợp đặc trưng Radiomics và đặc trưng Statistical. Trong đó:

- Đặc trưng Statistical mô tả các thông tin liên quan đến phân bố mức xám của ảnh;
- Đặc trưng Radiomics biểu diễn các đặc điểm định lượng liên quan đến cường độ và kết cấu của ảnh X-quang lồng ngực.

Việc kết hợp hai nhóm đặc trưng này nhằm tạo ra vector đặc trưng chứa đồng thời thông tin thống kê cơ bản và thông tin kết cấu của dữ liệu ảnh.

Các nhóm đặc trưng sử dụng trong quá trình kết hợp

Trong quá trình thực nghiệm, nghiên cứu sử dụng hai nhóm đặc trưng chính gồm:

- Đặc trưng Statistical (*Statistical Features*);
- Đặc trưng Radiomics (*Radiomics Features*).

Các đặc trưng Statistical được tính toán trực tiếp từ dữ liệu mức xám của ảnh nhằm mô tả các thông tin như giá trị trung bình, độ lệch chuẩn, phương sai, entropy và năng lượng của ảnh.

Trong khi đó, các đặc trưng Radiomics được trích xuất bằng thư viện PyRadiomics nhằm mô tả các đặc điểm định lượng của vùng ảnh thông qua các nhóm đặc trưng như First-order, GLCM và GLSZM.

Hai nhóm đặc trưng này được sử dụng để tạo vector đặc trưng đầu vào cho mô hình học máy trong quá trình phân loại ảnh X-quang lồng ngực.

Quy trình kết hợp đặc trưng

Sau quá trình trích xuất đặc trưng, các vector đặc trưng được kết hợp nhằm tạo thành dữ liệu đầu vào cho mô hình phân loại.

Đầu tiên, đặc trưng Statistical và đặc trưng Radiomics được trích xuất độc lập từ tập dữ liệu ảnh X-quang lồng ngực. Mỗi phương pháp tạo ra một vector đặc trưng với số chiều khác nhau.

Sau đó, các vector đặc trưng được kết hợp bằng phương pháp nối vector theo chiều đặc trưng bằng hàm concatenate() trong thư viện NumPy. Quá trình kết hợp được biểu diễn như sau:

$$X_{concat} = [X_1, X_2] \quad (3.1)$$

Trong đó:


- X_1 là vector đặc trưng thứ nhất;
- X_2 là vector đặc trưng thứ hai;
- X_{concat} là vector đặc trưng sau khi kết hợp.

Trong nghiên cứu này, vector đặc trưng cuối cùng được tạo thành bằng cách kết hợp đặc trưng Radiomics và Statistical:

$$X_{RadSta} = [X_{Radiomics}, X_{Statistical}] \quad (3.2)$$

Sau khi kết hợp, vector đặc trưng thu được được sử dụng làm dữ liệu đầu vào hỗ trợ trong quá trình huấn luyện và phân loại ảnh X-quang lồng ngực.

Ngoài ra, nghiên cứu cũng tiến hành chuẩn bị các nhóm đặc trưng khác như Vision Transformer (ViT) và Wavelet Scattering Transform (WST) nhằm phục vụ cho các bước thực nghiệm mở rộng và đánh giá mô hình ở các giai đoạn tiếp theo.



Hình 3.1: Minh họa quá trình kết hợp đặc trưng

Minh họa vector đặc trưng sau kết hợp

Sau quá trình trích xuất đặc trưng, mỗi phương pháp sẽ tạo ra một vector đặc trưng riêng nhằm biểu diễn dữ liệu ảnh dưới các khía cạnh khác nhau. Trong nghiên cứu này, đặc trưng Statistical và Radiomics được kết hợp bằng phương pháp Feature Concatenation để tạo thành vector đặc trưng đầu vào cho mô hình phân loại.

Giả sử vector đặc trưng Statistical được biểu diễn dưới dạng:

$$X_{Statistical} = [s_1, s_2, s_3, \dots, s_m] \quad (3.3)$$

Trong đó:

- s_i là đặc trưng thống kê thứ i ;
- m là tổng số đặc trưng Statistical.

Tương tự, vector đặc trưng Radiomics được biểu diễn dưới dạng:

$$X_{Radiomics} = [r_1, r_2, r_3, \dots, r_n] \quad (3.4)$$

Trong đó:

- r_i là đặc trưng Radiomics thứ i ;
- n là tổng số đặc trưng Radiomics.


Sau khi thực hiện quá trình nối vector theo chiều đặc trưng, vector đặc trưng cuối cùng được biểu diễn như sau:

$$X_{RadSta} = [r_1, r_2, \dots, r_n, s_1, s_2, \dots, s_m] \quad (3.5)$$

Trong đó:

- X_{RadSta} là vector đặc trưng sau khi kết hợp;
- Các đặc trưng Radiomics và Statistical được giữ nguyên thứ tự và ghép nối liên tiếp với nhau.

Quá trình kết hợp này giúp vector đặc trưng cuối cùng đồng thời chứa thông tin về phân bố mức xám, cường độ và đặc điểm kết cấu của ảnh X-quang lồng ngực. Vector đặc trưng sau kết hợp được sử dụng làm dữ liệu đầu vào cho mô hình Random Forest trong quá trình huấn luyện và phân loại.



Hình 3.2: Minh họa quá trình kết hợp vector đặc trưng

3.2 Phương pháp Gated Fusion

Giới thiệu về Gated Fusion

Gated Fusion là phương pháp kết hợp nhiều nhóm đặc trưng khác nhau thông qua cơ chế điều chỉnh trọng số tự động (*gate mechanism*). Phương pháp này cho phép mô

hình học cách xác định mức độ đóng góp của từng nhóm đặc trưng trong quá trình kết hợp, từ đó tạo ra một biểu diễn tổng hợp phù hợp hơn cho bài toán học máy.

Trong các bài toán học máy, dữ liệu thường được biểu diễn thông qua nhiều nhóm đặc trưng khác nhau, trong đó mỗi nhóm có thể phản ánh một khía cạnh riêng của dữ liệu. Tuy nhiên, mỗi nhóm đặc trưng thường không có mức độ quan trọng như nhau và cũng không đóng góp như nhau vào hiệu quả của mô hình. Vì vậy, nếu sử dụng các phương pháp kết hợp đơn giản như nối vector đặc trưng (*feature concatenation*), mô hình sẽ coi tất cả các đặc trưng là như nhau, dẫn đến việc chưa khai thác được sự khác biệt về mức độ quan trọng giữa chúng.

Để giải quyết vấn đề này, Gated Fusion được sử dụng nhằm kết hợp đồng thời nhiều nhóm đặc trưng trong cùng một mô hình. Thay vì gộp trực tiếp các đặc trưng lại với nhau, phương pháp này sử dụng cơ chế cổng (*gate*) để điều chỉnh mức độ ảnh hưởng của từng nhóm đặc trưng trước khi thực hiện quá trình kết hợp. Nhờ đó, mô hình có thể tự động học và lựa chọn những thông tin quan trọng hơn, đồng thời giảm ảnh hưởng của những đặc trưng ít hữu ích hoặc có nhiễu.

Việc áp dụng Gated Fusion giúp mô hình có khả năng khai thác hiệu quả hơn sự bổ sung giữa các nhóm đặc trưng khác nhau, từ đó cải thiện chất lượng biểu diễn và hiệu quả của mô hình trong các bài toán học máy.

Cơ chế hoạt động của Gated Fusion

Gated Fusion được xây dựng nhằm kết hợp nhiều nhóm đặc trưng khác nhau thông qua cơ chế điều chỉnh trọng số tự động. Mục tiêu của phương pháp này là giúp mô hình không chỉ gộp các đặc trưng lại với nhau, mà còn học được mức độ quan trọng tương đối của từng đặc trưng trong quá trình kết hợp.

Trong mô hình, các vector đặc trưng đầu vào từ các nhóm khác nhau trước tiên được đưa qua các lớp chiếu tuyến tính (*linear projection*) để đưa về cùng một không gian đặc trưng. Điều này giúp đảm bảo các vector có cùng kích thước và có thể so sánh, kết hợp với nhau một cách thống nhất.

Giả sử các vector đặc trưng đầu vào được ký hiệu như sau:

$$X_1, X_2, \dots, X_n \quad (3.6)$$

Sau đó, mỗi vector được biến đổi tuyến tính:

$$F_i = W_i X_i + b_i, \quad i = 1, 2, \dots, n \quad (3.7)$$

Trong đó W_i và b_i là các tham số học được trong quá trình huấn luyện, còn F_i là vector đặc trưng sau khi chiếu về không gian chung.

Để giúp quá trình huấn luyện ổn định hơn, các đặc trưng này có thể được chuẩn hóa bằng Layer Normalization nhằm giảm sự chênh lệch về phân phối giá trị giữa các nhóm đặc trưng.

Tiếp theo, cơ chế gate được áp dụng để xác định mức độ quan trọng của từng đặc trưng. Cụ thể, mỗi vector đặc trưng sẽ được đưa qua một lớp tuyến tính kết hợp với hàm sigmoid để tạo ra vector trọng số:

$$G_i = \sigma(W_{g_i}F_i + b_{g_i}) \quad (3.8)$$

Trong đó:

- G_i là vector gate tương ứng với đặc trưng thứ i ;
- σ là hàm sigmoid đưa giá trị về khoảng $(0, 1)$;
- W_{g_i} và b_{g_i} là các tham số học được.

Vector gate này thể hiện mức độ đóng góp của từng đặc trưng, giúp mô hình có thể tự động điều chỉnh tầm quan trọng của chúng trong quá trình học.

Sau khi tính được gate, các đặc trưng được hiệu chỉnh như sau:

$$F'_i = F_i \odot (1 + G_i) \quad (3.9)$$

Trong đó $\odot$ là phép nhân theo từng phần tử. Cách cập nhật này giúp mô hình vừa có thể tăng cường các đặc trưng quan trọng, vừa có thể giảm ảnh hưởng của các đặc trưng ít hữu ích.

Cuối cùng, các đặc trưng sau khi đã được hiệu chỉnh sẽ được kết hợp lại bằng phép trung bình:

$$F_{fusion} = \frac{1}{n} \sum_{i=1}^n F'_i \quad (3.10)$$

Vector F_{fusion} thu được sẽ được sử dụng làm đầu vào cho lớp phân loại cuối cùng.

Nhìn chung, cơ chế Gated Fusion giúp mô hình có khả năng học được mức độ quan trọng của từng nhóm đặc trưng, thay vì coi tất cả các đặc trưng là như nhau. Nhờ đó, quá trình kết hợp trở nên linh hoạt hơn và giúp mô hình khai thác hiệu quả hơn thông tin từ nhiều nguồn đặc trưng khác nhau.

Cơ chế Gate

Trong mô hình Gated Fusion, cơ chế gate đóng vai trò quan trọng trong việc xác định mức độ đóng góp của từng nhóm đặc trưng trước khi thực hiện quá trình kết hợp.

Thay vì xem tất cả các đặc trưng đều có mức độ quan trọng như nhau, cơ chế này cho phép mô hình tự động học và điều chỉnh trọng số phù hợp cho từng đặc trưng trong quá trình huấn luyện.

Sau khi các vector đặc trưng được đưa về cùng không gian biểu diễn, mỗi vector sẽ được đưa qua một lớp tuyến tính kết hợp với hàm kích hoạt sigmoid để tạo ra vector gate tương ứng:

$$G_i = \sigma(W_{g_i}F_i + b_{g_i}) \quad (3.11)$$

Trong đó:

- G_i là vector gate của đặc trưng thứ i ;
- σ là hàm kích hoạt sigmoid;
- W_{g_i} và b_{g_i} là các tham số học được;
- F_i là vector đặc trưng đầu vào sau bước chiếu tuyến tính.

Hàm sigmoid được sử dụng nhằm đưa giá trị đầu ra về khoảng từ 0 đến 1. Giá trị này thể hiện mức độ quan trọng của từng chiều đặc trưng trong quá trình kết hợp dữ liệu. Những đặc trưng có giá trị gate lớn sẽ được tăng cường mức độ ảnh hưởng, trong khi các đặc trưng có giá trị nhỏ sẽ bị giảm mức đóng góp.

Sau khi tính toán gate, vector đặc trưng được cập nhật theo công thức:

$$F'_i = F_i \odot (1 + G_i) \quad (3.12)$$

Trong đó:

- F'_i là vector đặc trưng sau khi áp dụng gate;
- $\odot$ là phép nhân theo từng phần tử.

Cơ chế này giúp mô hình tự động tập trung vào các đặc trưng quan trọng trong quá trình học, đồng thời hạn chế ảnh hưởng của những đặc trưng ít liên quan hoặc chứa nhiễu. Nhờ đó, quá trình kết hợp đặc trưng trở nên linh hoạt hơn và giúp nâng cao hiệu quả biểu diễn dữ liệu của mô hình.

Quá trình hợp nhất đặc trưng

Sau khi các vector đặc trưng được điều chỉnh thông qua cơ chế gate, bước tiếp theo là thực hiện quá trình hợp nhất đặc trưng (*feature fusion*) nhằm tạo ra một biểu diễn tổng hợp cho toàn bộ dữ liệu đầu vào.

Trong Gated Fusion, các vector đặc trưng sau khi được cập nhật sẽ được kết hợp lại bằng phép trung bình:

$$F_{fusion} = \frac{1}{n} \sum_{i=1}^n F'_i \quad (3.13)$$

Trong đó:

- F_{fusion} là vector đặc trưng sau khi hợp nhất;
- F'_i là vector đặc trưng sau khi áp dụng cơ chế gate;
- n là số lượng nhóm đặc trưng đầu vào.

Phép hợp nhất này giúp mô hình tổng hợp thông tin từ nhiều nguồn đặc trưng khác nhau để tạo ra một biểu diễn đặc trưng đầy đủ và hiệu quả hơn. Do các đặc trưng đã được điều chỉnh trọng số trước đó thông qua cơ chế gate, quá trình hợp nhất sẽ ưu tiên nhiều hơn cho các đặc trưng quan trọng và giảm ảnh hưởng của các đặc trưng ít hữu ích.

Vector đặc trưng tổng hợp F_{fusion} sau đó sẽ được sử dụng làm đầu vào cho các tầng xử lý tiếp theo của mô hình, chẳng hạn như lớp phân loại hoặc lớp dự đoán đầu ra.

Nhìn chung, quá trình hợp nhất đặc trưng trong Gated Fusion giúp mô hình khai thác hiệu quả thông tin từ nhiều nguồn đặc trưng khác nhau, đồng thời cải thiện khả năng biểu diễn dữ liệu và hiệu suất của mô hình trong bài toán học máy.

Ưu điểm của Gated Fusion

Gated Fusion mang lại nhiều ưu điểm trong quá trình kết hợp đặc trưng của mô hình học sâu. Thay vì xem tất cả các đặc trưng đều có mức độ quan trọng như nhau, phương pháp này cho phép mô hình tự động học và điều chỉnh trọng số phù hợp cho từng đặc trưng thông qua cơ chế gate. Nhờ đó, mô hình có thể tập trung nhiều hơn vào những đặc trưng quan trọng và giảm ảnh hưởng của các đặc trưng ít hữu ích hoặc chứa nhiễu.

Một ưu điểm quan trọng của Gated Fusion là khả năng khai thác hiệu quả thông tin từ nhiều nguồn đặc trưng khác nhau. Mỗi nhóm đặc trưng thường phản ánh một khía cạnh riêng của dữ liệu, do đó việc kết hợp linh hoạt giữa chúng giúp mô hình tạo ra biểu diễn dữ liệu đầy đủ và giàu thông tin hơn.

Bên cạnh đó, cơ chế gate còn giúp quá trình kết hợp đặc trưng trở nên thích nghi hơn so với các phương pháp kết hợp truyền thống như nối vector đặc trưng (*feature concatenation*). Thay vì kết hợp trực tiếp tất cả các đặc trưng với mức đóng góp như nhau, Gated Fusion có khả năng học được mức độ ảnh hưởng phù hợp của từng đặc trưng trong quá trình huấn luyện.

Ngoài ra, việc sử dụng Gated Fusion còn góp phần cải thiện khả năng biểu diễn của mô hình, hỗ trợ tăng hiệu quả học và nâng cao độ chính xác trong các bài toán học máy, đặc biệt là các bài toán sử dụng nhiều nguồn đặc trưng khác nhau. “

3.3 Xây dựng mô hình kết hợp đặc trưng Gated Fusion

Kiến trúc mô hình Gated Fusion

Mô hình Gated Fusion trong nghiên cứu này được xây dựng nhằm kết hợp nhiều nhóm đặc trưng khác nhau để tạo ra vector biểu diễn dữ liệu đầu vào phục vụ cho bài toán phân loại ảnh X-quang lồng ngực. Kiến trúc mô hình sử dụng ba nhóm đặc trưng gồm Vision Transformer (ViT), Radiomics kết hợp Statistical Features (RadSta) và Wavelet Scattering Transform (WST).

Tổng quan kiến trúc mô hình Gated Fusion được minh họa trong Hình ??.

Các vector đặc trưng đầu vào được ký hiệu như sau:

$$X_{ViT}, X_{RadSta}, X_{WST} \quad (3.14)$$

Trong đó:

- X_{ViT} là vector đặc trưng được trích xuất từ mô hình Vision Transformer;
- X_{RadSta} là vector đặc trưng kết hợp giữa Radiomics và Statistical Features;
- X_{WST} là vector đặc trưng được trích xuất từ Wavelet Scattering Transform.

Do kích thước của các vector đặc trưng đầu vào khác nhau, mô hình sử dụng các lớp chiếu tuyến tính (*Linear Projection*) nhằm đưa các vector về cùng không gian đặc trưng trước khi thực hiện quá trình kết hợp dữ liệu.

Quá trình projection được thực hiện theo công thức:

$$F_i = W_i X_i + b_i \quad (3.15)$$

Trong đó:

- X_i là vector đặc trưng đầu vào;
- W_i là ma trận trọng số;

- b_i là vector bias;
- F_i là vector đặc trưng sau projection.

Sau bước projection, dữ liệu được chuẩn hóa bằng phương pháp Layer Normalization nhằm giảm sự chênh lệch giá trị giữa các đặc trưng và hỗ trợ quá trình huấn luyện mô hình ổn định hơn.

Tiếp theo, mô hình sử dụng cơ chế gate để điều chỉnh mức độ đóng góp của từng nhóm đặc trưng. Đối với mỗi vector đặc trưng, một vector gate được tính toán thông qua lớp tuyến tính kết hợp với hàm kích hoạt Sigmoid:

$$G_i = \sigma(W_g F_i + b_g) \quad (3.16)$$

Trong đó:

- G_i là vector gate;
- σ là hàm kích hoạt Sigmoid;
- W_g và b_g là các tham số học được của lớp gate.

Sau khi tính toán gate, vector đặc trưng được cập nhật như sau:

$$F'_i = F_i \odot (1 + G_i) \quad (3.17)$$

Trong đó:

- F'_i là vector đặc trưng sau khi áp dụng gate;
- $\odot$ là phép nhân từng phần tử.

Cơ chế gate giúp mô hình tự động điều chỉnh mức độ ảnh hưởng của từng nhóm đặc trưng trong quá trình kết hợp dữ liệu.

Sau khi áp dụng gate cho từng nhóm đặc trưng, các vector đặc trưng được kết hợp bằng phép lấy trung bình để tạo ra vector fusion cuối cùng:

$$F_{fusion} = \frac{F' * ViT + F' * RadSta + F'_{WST}}{3} \quad (3.18)$$

Vector đặc trưng sau kết hợp tiếp tục được đưa qua lớp Dropout nhằm giảm hiện tượng quá khớp (*overfitting*) trong quá trình huấn luyện mô hình.

Cuối cùng, vector fusion được sử dụng làm dữ liệu đầu vào cho lớp phân loại (*Classifier*) để thực hiện bài toán phân loại ảnh X-quang lồng ngực:

$$Y = Classifier(F_{fusion}) \quad (3.19)$$

Trong đó, đầu ra của mô hình là xác suất dự đoán tương ứng với các lớp phân loại của dữ liệu ảnh đầu vào.

3.4 Thực nghiệm và thảo luận

3.4.1 Thực nghiệm

3.4.2 Thảo luận

3.5 Tiểu kết chương 3

CHƯƠNG 4

XÂY DỰNG HỆ THỐNG CHẨN ĐOÁN VIÊM PHỔI

4.1 Giới thiệu hệ thống

4.1.1 Tổng quan hệ thống

Hệ thống web chẩn đoán viêm phổi trong đề tài được phát triển nhằm hỗ trợ bác sĩ và nhân viên y tế bằng cách tự động phân tích hình ảnh X-quang, cung cấp nhãn dự đoán kèm độ đo đáng tin cậy và các hình ảnh giải thích (Grad-CAM) để minh bạch hóa vùng mô hình tập trung. Thiết kế hướng tới hai mục tiêu chính :

- Tăng tốc độ quá trình sàng lọc và hỗ trợ đưa ra quyết định.
- Đảm bảo khả năng truy vết và kiểm định mô hình trong môi trường thực tế.

Sự hòa hợp giữa kiến thức y tế và thiết kế kỹ thuật được thể hiện qua những nguyên tắc sau :

- Là công cụ hỗ trợ, không thay thế chuyên môn: hệ thống cung cấp đầu vào tham chiếu, bác sĩ chịu trách nhiệm quyết định cuối cùng.
- Minh bạch và có thể giải thích: kèm theo mỗi dự đoán là thông tin độ tin cậy và ảnh Grad-CAM để hỗ trợ đối chiếu lâm sàng.
- Truy vết và lưu trữ: mỗi phiên chẩn đoán được ghi dưới dạng bản ghi có định danh cùng metadata (thời gian, mô hình, thông số), phục vụ kiểm định và phân tích sau này.

Về phạm vi ứng dụng, hệ thống phù hợp để dùng như công cụ sàng lọc ban đầu (triaging) trong cơ sở y tế, hỗ trợ tăng hiệu quả làm việc cho nhân viên y tế và giảm

thời gian chờ kết quả. Đồng thời, hệ thống được thiết kế để dễ dàng tích hợp với quy trình hiện có, cho phép xuất báo cáo lưu trữ và cung cấp dữ liệu để tiếp tục cải thiện mô hình thông qua vòng phản hồi thực tế.

Tuy nhiên, cần lưu ý một số hạn chế: hiệu năng phụ thuộc vào dữ liệu huấn luyện (có thể giảm trên quần thể khác biệt), mô hình có thể gặp khó với ảnh có chất lượng kém hoặc tổn thương nhẹ, và mọi kết luận lâm sàng phải được xác nhận bởi bác sĩ. Các chính sách bảo mật, riêng tư dữ liệu và thử nghiệm lâm sàng cần được tuân thủ khi triển khai thực tế.

4.1.2 Công nghệ sử dụng

Các công nghệ chính đang được sử dụng bao gồm :

- Frontend: React, Vite, MUI
- Backend: Java 21, Spring Boot (REST, JPA, Security), Maven
- AI service: Python, FastAPI, TensorFlow/Keras, NumPy
- Cơ sở dữ liệu: MySQL

4.1.3 Mô tả cơ sở dữ liệu của hệ thống

Để triển khai hệ thống web hỗ trợ chẩn đoán viêm phổi từ ảnh X-quang, chúng tôi thiết kế một cơ sở dữ liệu quan hệ ở mức vừa đủ để phục vụ các chức năng cốt lõi của hệ thống: xác thực người dùng, lưu lịch sử chẩn đoán, quản lý thông tin mô hình và hỗ trợ truy vết kết quả. Với phạm vi ứng dụng hiện tại, cơ sở dữ liệu được tổ chức gọn hơn so với các hệ thống lớn, nhưng vẫn bảo đảm được tính nhất quán và khả năng mở rộng khi cần bổ sung tính năng sau này.

- Thông tin người dùng - users: Lưu thông tin tài khoản người dùng và quản trị viên. Bảng này là cơ sở cho quá trình đăng nhập, phân quyền và kiểm soát trạng thái tài khoản trong hệ thống web.
- Dữ liệu lịch sử chẩn đoán - diagnosis_history: Lưu toàn bộ lịch sử chẩn đoán của người dùng. Bảng này giữ vai trò trung tâm trong chức năng xem lại kết quả, lọc theo thời gian và xuất lịch sử chẩn đoán.
- Dữ liệu mô hình và kết quả đánh giá - model_metrics: Lưu thông tin mô hình và các chỉ số tổng hợp của từng phiên bản. Bảng này giúp hệ thống hiển thị thông tin mô hình khi người dùng lựa chọn mô hình chẩn đoán và hỗ trợ quản trị viên theo dõi phiên bản mô hình đang sử dụng.


Quan hệ giữa các bảng:

- Mỗi người dùng trong users có thể tạo nhiều bản ghi trong diagnosis_history.
- Mỗi bản ghi trong diagnosis_history được gắn với một mô hình cụ thể thông qua model_id.
- Bảng model_metrics cung cấp dữ liệu tham chiếu cho mô hình đang được triển khai và các chỉ số đánh giá tương ứng.

Quan hệ giữa các bảng giúp hệ thống vừa truy xuất được lịch sử chẩn đoán theo người dùng, vừa đối chiếu được kết quả với phiên bản mô hình đã sử dụng.

Vai trò trong hệ thống web chẩn đoán:

Cơ sở dữ liệu đóng vai trò nền tảng cho toàn bộ hệ thống web: lưu trữ tài khoản người dùng, ghi nhận lịch sử chẩn đoán, cung cấp thông tin mô hình và hỗ trợ hiển thị kết quả trên giao diện. Nhờ cấu trúc chỉ gồm các bảng đúng với phạm vi chức năng hiện có, hệ thống giữ được sự gọn nhẹ, dễ triển khai và dễ bảo trì. Đồng thời, cách tổ chức này cũng bảo đảm việc tích hợp với backend và các mô hình học sâu trong AI service diễn ra nhất quán, vì mỗi phiên chẩn đoán đều được lưu lại đầy đủ thông tin cần thiết để tra cứu, kiểm định và xuất báo cáo khi cần.



Hình 4.1: Sơ đồ quan hệ thực thể của cơ sở dữ liệu hệ thống web chẩn đoán viêm phổi.

4.2 Quy trình tương tác người dùng với hệ thống

Quy trình tương tác giữa người dùng với hệ thống chẩn đoán X-quang được minh họa ở Hình 4.2 như sau:

Bắt đầu quá trình chẩn đoán:

- Người dùng truy cập vào hệ thống thông qua giao diện web.
- Người dùng tải ảnh X-quang lên hệ thống để thực hiện chẩn đoán.

Kiểm tra dữ liệu đầu vào:

- Hệ thống thực hiện kiểm tra dữ liệu ảnh trước khi xử lý, bao gồm:
 - Định dạng tệp.
 - Dung lượng ảnh.
 - Trạng thái dữ liệu bắt buộc.
 - Điều kiện kết nối.
- Nếu dữ liệu không hợp lệ:
 - Hệ thống hiển thị thông báo lỗi cho người dùng.
 - Yêu cầu người dùng kiểm tra và tải lại dữ liệu phù hợp.
- Nếu dữ liệu hợp lệ:
 - Người dùng tiếp tục lựa chọn phương thức chẩn đoán.

Lựa chọn phương thức chẩn đoán:

- Người dùng có thể lựa chọn:
 - Chẩn đoán bằng một mô hình.
 - Hoặc so sánh kết quả giữa nhiều mô hình.
- Sau khi lựa chọn, hệ thống tạo yêu cầu chẩn đoán và gửi đến backend để xử lý.

Tiếp nhận và xử lý yêu cầu:

- Backend tiếp nhận request từ frontend.
- Hệ thống thực hiện:
 - Xác thực quyền truy cập.
 - Tạo phiên chẩn đoán.
 - Chuẩn hóa dữ liệu theo schema thống nhất.
- Sau đó, request được chuyển đến AI service để thực hiện suy luận trên ảnh X-quang.

Xử lý chẩn đoán bằng AI:

- AI service tiến hành:


- Tiền xử lý ảnh.
- Thực hiện suy luận bằng mô hình AI.
- Trả kết quả chẩn đoán về backend.
- Nếu quá trình xử lý thất bại:
 - Hệ thống ghi log lỗi.
 - Cập nhật trạng thái phiên xử lý lỗi.
 - Hiển thị thông báo lỗi cho người dùng.
- Nếu xử lý thành công:
 - Backend tiếp nhận kết quả từ AI service.
 - Kiểm tra tính đầy đủ của dữ liệu trả về.
 - Lưu kết quả và metadata liên quan.

Trả kết quả cho người dùng:

- Hệ thống trả dữ liệu kết quả về frontend.
- Người dùng nhận được:
 - Kết quả chẩn đoán.
 - Hình ảnh trực quan minh họa.
 - Các thông tin liên quan phục vụ việc theo dõi và đánh giá kết quả.

Các chức năng hỗ trợ khác:

- Hệ thống hỗ trợ:
 - Xem lại lịch sử chẩn đoán.
 - Lọc và tìm kiếm kết quả.
 - Xuất báo cáo kết quả.
 - Ghi nhật ký và truy vết hoạt động hệ thống.



Hình 4.2: Quy trình tương tác giữa người dùng với hệ thống

4.3 Triển khai chức năng chính - chẩn đoán viêm phổi thông qua ảnh X-quang


4.3.1 Mô tả chức năng

Chức năng chẩn đoán ảnh X-quang là chức năng lõi quyết định giá trị sử dụng thực tiễn của hệ thống web. Mục đích của chức năng này không chỉ là trả về một dự đoán mà còn phải đảm bảo kết quả thể hiện theo ngữ cảnh nghiệp vụ, có thể kiểm chứng lại và có thể tích hợp vào quy trình làm việc của người dùng. Do đó, chức năng được thiết kế với đầu vào rõ ràng, đầu ra nhất quán và có cơ chế lưu vết đầy đủ.

Đầu vào của chức năng gồm ảnh X-quang do người dùng tải lên, thông tin mô hình được chọn và các tùy chọn liên quan như chế độ giải thích kết quả. Đầu ra gồm nhãn dự đoán, độ tin cậy, thông tin mô hình và hình ảnh trực quan. Quan trọng hơn, toàn bộ đầu ra đều được đồng bộ vào cơ sở dữ liệu để phục vụ truy xuất về sau. Cách thiết kế này đảm bảo mỗi lần chẩn đoán không phải là một tác vụ "tạm thời", mà là một phiên nghiệp vụ có thể tra cứu và kiểm chứng.

- Đầu vào (Input): Ảnh X-quang ngực của người dùng được tải lên hệ thống qua giao diện web tại thời điểm bắt đầu quá trình chẩn đoán.
- Đầu ra (Output): Kết quả chẩn đoán bệnh viêm phổi, độ tin cậy của mô hình, hình ảnh trực quan minh họa vùng bất thường và các thông tin liên quan được

trả về cho người dùng sau khi quá trình suy luận hoàn tất.



Hình 4.3: Minh họa đầu vào (input), đầu ra (output) của các chức năng chẩn đoán X-quang

Chức năng chẩn đoán X-quang được minh họa ở hình 4.3 gồm các chức năng chính như sau :

- Tiếp nhận ảnh X-quang từ người dùng thông qua giao diện hệ thống và thực hiện kiểm tra dữ liệu đầu vào như định dạng tệp, dung lượng ảnh và trạng thái dữ liệu bắt buộc.
- Tiền xử lý ảnh nhằm chuẩn hóa dữ liệu đầu vào trước khi đưa vào mô hình AI, bao gồm các bước như resize ảnh, chuẩn hóa giá trị pixel và chuyển đổi định dạng phù hợp với mô hình suy luận.
- Trích xuất đặc trưng ảnh bằng các mô hình nhằm học biểu diễn đặc trưng của vùng phổi trên ảnh X-quang.
- Thực hiện suy luận bằng mô hình AI để phân loại ảnh thành các nhóm bình thường hoặc viêm phổi, đồng thời tính toán xác suất dự đoán đặc trưng.
- Sinh kết quả trực quan bằng kỹ thuật giải thích mô hình Grad-CAM để làm nổi bật các vùng ảnh có ảnh hưởng lớn đến quyết định của mô hình.
- Trả kết quả chẩn đoán về frontend để hiển thị cho người dùng, bao gồm :
 - Nhận chẩn đoán
 - Mô hình chẩn đoán
 - Độ tin cậy của chẩn đoán
 - Ảnh trực quan minh họa vùng bất thường
 - Các thông tin liên quan phục vụ theo dõi và đánh giá kết quả

4.3.2 Quy trình chẩn đoán

Khi người dùng gửi yêu cầu chẩn đoán, hệ thống thực hiện các bước kiểm tra và chuẩn hóa :

- Xác thực dữ liệu đầu vào :

Hệ thống kiểm tra ảnh X-quang nhận được :

- Định dạng tệp : Chỉ chấp nhận JPEG và PNG
- Kích thước file : $\leq 50\text{MB}$
- Kích thước ảnh: 256x256 đến 2048x2048
- Tính toán vẹn : Kiểm tra dữ liệu không bị hỏng

Nếu có vi phạm, hệ thống từ chối ngay và báo cáo lỗi cho người dùng

- Tạo phiên bản chẩn đoán

Hệ thống tạo bản ghi phiên chẩn đoán để :


- Ghi mã phiên duy nhất
- Lưu thông tin : người dùng, mô hình chọn, thời gian bắt đầu
- Chuẩn bị cơ sở dữ liệu

4.3.3 Thiết kế giao diện chẩn đoán

Để dễ dàng trực quan quá trình chẩn đoán, giao diện đã được thiết kế cho từng bước tải ảnh X-quang, theo dõi tiến trình xử lý, và hiển thị kết quả chẩn đoán. Giao diện được chia thành 3 khu vực chính tương ứng với 3 giai đoạn : tải ảnh, chẩn đoán và xem kết quả.

Mô tả giao diện tải ảnh:


- Khu vực tải ảnh được thiết kế tối màu để làm nổi bật phần drop-zone và nút chọn tệp.
 - Biểu tượng upload (cloud icon) và văn bản "Tải ảnh X-quang lồng ngực" xuất hiện nhằm hướng dẫn người dùng.
 - Bên dưới biểu tượng upload là danh sách các tệp được hỗ trợ (PNG, JPEG).
- Bên dưới khu vực tải ảnh là nút "Chẩn đoán ngay" (hoặc là "So sánh mô hình" tùy chức năng sử dụng) để tiến hành chẩn đoán khi ảnh đã chuẩn bị xong. Và nút reload để load lại ảnh chẩn đoán khác.



Hình 4.4: Minh họa giao diện tải ảnh

Mô tả giao diện chẩn đoán (trong quá trình xử lý):


- Khi người dùng bấm nút "Chẩn đoán ngay", giao diện mở thêm một khu vực để hiển thị kết quả chẩn đoán và ảnh Grad-CAM đang load "Đang tạo bản đồ nhiệt".
- Nếu có lỗi xảy ra trong quá trình xử lý, một banner thông báo lỗi màu đỏ xuất hiện với thông điệp dễ hiểu.



Hình 4.5: Minh họa giao diện tải ảnh

Mô tả giao diện hiển thị kết quả :

- Khi chẩn đoán hoàn tất, giao diện hiển thị khu vực kết quả bao gồm :
 - Nhân dự đoán (NORMAL hoặc PNEUMONIA) in đậm và màu nổi bật (đỏ cho PNEUMONIA, xanh cho NORMAL).
 - Độ tin cậy dưới dạng phần trăm và thời gian xử lý được đặt ở bên cạnh.
 - Ở phía dưới thẻ kết quả hiển thị ảnh Grad-CAM để trực quan hóa kết quả chẩn đoán.



Hình 4.6: Minh họa giao diện hiển thị kết quả

Thiết kế giao diện như vậy làm tăng trải nghiệm người dùng bằng cách giảm thời gian hiểu biết cần thiết, cung cấp phản hồi trực quan rõ ràng và cho phép dễ dàng khảo sát lại kết quả thực nghiệm.

4.4 Triển khai các chức năng phụ

Bên cạnh chức năng chẩn đoán lỗi, hệ thống còn có một nhóm chức năng phụ nhằm hoàn thiện trải nghiệm sử dụng, tăng khả năng so sánh, truy vết và lưu lịch sử kết quả. Các chức năng phụ này không trực tiếp sinh ra kết quả dự đoán nhưng lại trong vai trò quan trọng trong việc biến hệ thống từ một mô-đun suy luận đơn lẻ thành một ứng dụng hỗ trợ chẩn đoán có thể sử dụng trong nghiệp vụ thực tế.

4.4.1 Chức năng chọn mô hình chẩn đoán

Mô tả chức năng


Chức năng chọn mô hình cho phép người dùng chỉ định mô hình sẽ dùng trong phiên chẩn đoán. Danh sách mô hình được lấy từ backend và hiển thị ngay trên giao diện chẩn đoán để người dùng dễ lựa chọn theo nhu cầu thực nghiệp hoặc theo tình huống sử dụng thực tế.

Việc cho phép chọn mô hình giúp hệ thống linh hoạt hơn, không bị phụ thuộc vào một mô hình cố định. Ngoài ra, thông tin mô hình được lưu kèm trong bảng ghi chẩn đoán để phục vụ đối chiếu và truy xuất về sau.

Quy trình thực hiện

Quy trình chẩn đoán diễn ra theo các bước sau :

- Người dùng truy cập màn hình chẩn đoán.



Hình 4.7: Minh họa giao diện lựa chọn mô hình chẩn đoán

- Hệ thống tự động tải danh sách mô hình và hiển thị.
- Người dùng xem tên mô hình, các độ đo đánh giá tổng thể cũng như thời gian chạy mô hình dự kiến.
- Người dùng chọn mô hình phù hợp.
- Hệ thống ghi nhận mô hình và sử dụng nó cho phiên chẩn đoán hiện tại.


Thiết kế giao diện minh họa

Giao diện chọn mô hình được bố trí ngay trong khu vực chẩn đoán để giảm số thao tác chuyển màn hình. Các mô hình được hiển thị dưới dạng danh sách hoặc thẻ lựa chọn, kèm theo trạng thái đang chọn để người dùng dễ nhận biết. Cách thiết kế này giúp thao tác chọn mô hình rõ ràng, trực quan và phù hợp với quy trình làm việc nhanh trong môi trường thực tế.

4.4.2 Chức năng so sánh các mô hình chẩn đoán

Mô tả chức năng

Chức năng so sánh mô hình được xây dựng để người dùng có thể quan sát đồng thời kết quả chẩn đoán của nhiều mô hình chẩn đoán. Trước khi chẩn đoán, hệ thống hiển thị các thông tin như độ chính xác, precision, recall, F1-score, AUC và thời gian suy luận trung bình, giúp người dùng có cái nhìn tổng quan hơn về hiệu năng của từng mô hình.



Hình 4.8: Minh họa giao diện so sánh các mô hình chẩn đoán.

Quy trình thực hiện:

Quy trình so sánh mô hình gồm các bước :

- Người dùng chọn chức năng so sánh mô hình trên giao diện. Sau đó nút "Chẩn đoán ngay" sẽ chuyển thành "So sánh các model".
- Hệ thống tải dữ liệu mô tả và các chỉ số đánh giá của từng mô hình.
- Các mô hình được hiển thị cùng các metric tương ứng để người dùng đối chiếu.
- Khi ấn nút "So sánh các model" thì các model hiện có sẽ đồng thời được chạy và đưa ra kết quả cho người dùng có cái nhìn tổng thể về các chẩn đoán của các mô hình.

Thiết kế giao diện minh họa


Giao diện so sánh trình bày theo dạng các khối thông tin song song để người dùng dễ theo dõi, so sánh và có cái nhìn đa chiều hơn về các mô hình chẩn đoán.

4.4.3 Chức năng xem lịch sử chẩn đoán

Mô tả chức năng:

Chức năng xem lịch sử chẩn đoán cho phép người dùng tra cứu lại các phiên chẩn đoán đã thực hiện trước đó. Dữ liệu được hiển thị theo dạng bảng và có thể lọc theo thời gian, mô hình, trạng thái xác minh hoặc nhãn dự đoán. Khi người dùng mở một bản ghi cụ thể, hệ thống hiển thị chi tiết ảnh X-quang, kết quả AI, thông tin mô hình và ghi chú liên quan.

Chức năng này giúp hệ thống không chỉ dừng ở việc chẩn đoán một lần mà còn hỗ trợ người dùng theo dõi quá trình làm việc theo thời gian, thuận tiện cho việc đối chiếu và kiểm tra lại khi cần.



Hình 4.9: Minh họa giao diện lịch sử khám và tra cứu kết quả chẩn đoán.

Quy trình thực hiện:

Quy trình thao tác với lịch sử khám gồm :

- Người dùng mở trang lịch sử chẩn đoán.
- Hệ thống hiển thị danh sách các bản ghi đã lưu.
- Người dùng tìm bản ghi mong muốn (có thể áp dụng các bộ lọc).
- Người dùng chọn một bản ghi để xem thông tin chi tiết.
- Nếu cần, người dùng có thể xuất lại báo cáo PDF từ chính bản ghi đó.

Thiết kế giao diện minh họa

Giao diện lịch sử được thiết kế dưới dạng bảng kết hợp bộ lọc và hộp thoại xem chi tiết. Bố cục này giúp người dùng vừa nhìn được tổng thể, vừa có thể đi sâu vào từng phiên chẩn đoán mà không bị rối thông tin. Đây là cách bố trí phù hợp với nhu cầu tra cứu thường xuyên trong thực tế.

4.4.4 Chức năng xuất kết quả chẩn đoán

Mô tả chức năng:

Chức năng xuất kết quả chẩn đoán dưới dạng file PDF cho phép người dùng lưu lại kết quả chẩn đoán dưới dạng báo cáo chuẩn hóa. Báo cáo này bao gồm thông tin thời gian, mã báo cáo, mô hình đã sử dụng, nhãn chẩn đoán, độ tin cậy và các hình ảnh minh họa liên quan như ảnh X-quang gốc và ảnh Grad-CAM. Tính năng này giúp người dùng dễ lưu trữ hồ sơ, in ấn và chia sẻ kết quả trong môi trường nghiệp vụ.

Quy trình thực hiện:

Quy trình xuất PDF được thực hiện như sau :

- Người dùng hoàn tất phiên bản chẩn đoán hoặc mở một bản ghi trong lịch sử.
- Người dùng bấm nút xuất báo cáo trên giao diện.
- Hệ thống thu thập dữ liệu chẩn đoán, hình ảnh và thông tin mô hình.
- Báo cáo PDF được sinh tự động với bố cục chuẩn hóa.
- Người dùng tải tệp PDF về máy hoặc lưu trữ theo nhu cầu.

4.5 Đánh giá hệ thống

4.6 Tiểu kết chương 4

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

TÀI LIỆU THAM KHẢO

Tài liệu tham khảo

CHƯƠNG A

PHỤ LỤC